自己动手写操作系统

基于 SZY-KERNEL 的 OS 开发实战教程

SZY

2026 年 3 月 24 日

目录

I 准备工作 **3**

1 前言 **4**

1.1 这本书要做什么 4
1.2 目标读者 4
1.3 项目愿景 4
1.4 全书路线图 5
1.5 如何阅读本书 5

2 开发环境搭建 **6**

2.1 本章目标 6
2.2 宿主机环境 6
2.3 必要工具安装 6
2.4 项目目录结构 7
2.5 构建与运行闭环 7
2.6 VS Code 调试集成 7
2.7 本章小结 7

II 裸机基础设施 **8**

3 Multiboot2 引导与串口输出 **9**

3.1 本章目标 9
3.2 背景知识：x86 开机流程 9
3.3 Multiboot2 Header 10
3.4 链接脚本 `linker.ld` 详解 11
3.5 `boot.asm` 详解：从物理地址到高半区 13
3.5.1 保存 Multiboot2 信息 13
3.5.2 PSE 页目录构造 13
3.5.3 双重映射：Identity + High-Half 14
3.5.4 开启 PSE 和分页 15

3.5.5 跳转到高半区 15
3.6 栈设置与 kmain 调用 16
3.7 UART 16550 串口输出 17
3.7.1 16550 寄存器表 17
3.7.2 serial_init() 初始化步骤 17
3.7.3 发送一个字符 18
3.8 printk 实现概述 18
3.8.1 核心结构 18
3.8.2 格式化选项 19
3.9 Multiboot2 信息结构解析 19
3.10 验证 20
3.11 思考与练习 21

4 GDT：全局描述符表 22
4.1 本章目标 22
4.2 背景知识：保护模式下的段式内存管理 22
4.2.1 从实模式到保护模式 22
4.2.2 段寄存器的”双面”结构 23
4.3 段选择子格式 23
4.4 GDT 描述符的 8 字节布局 24
4.4.1 内存中的字节布局 24
4.4.2 对应的 C 结构体 24
4.4.3 重组逻辑：gdt_set_entry 25
4.5 Access 字节：逐 bit 详解 26
4.6 Flags + Limit High 字节（gran） 27
4.7 GDTR 结构体 28
4.8 gdt_init()：填充三个描述符 29
4.9 汇编详解：gdt_flush.asm 30
4.10 验证 32
4.10.1 GDB 逐指令验证 33
4.11 思考与练习 33
4.12 本章小结 34

5 IDT：中断描述符表 35
5.1 本章目标 35
5.2 背景知识：中断与异常 35
5.2.1 异常的三种分类 36
5.2.2 向量号分配 36

5.3 IDT 门描述符的 8 字节布局 37
5.3.1 内存布局 37
5.3.2 C 结构体 37
5.3.3 `type_attr` 字节逐 bit 详解 38
5.3.4 `idt_set_gate`：填充一个门描述符 39
5.3.5 IDTR 结构体 39
5.4 ISR 汇编 Stub：`isr_stubs.asm` 40
5.4.1 问题：栈布局不统一 40
5.4.2 解决方案：ISR_NOERR 和 ISR_ERR 宏 40
5.4.3 `isr_common_stub`：逐指令详解 41
5.5 完整栈布局图（ISR 入口到 C handler） 42
5.6 `regs_t`：与汇编栈布局一一对应的 C 结构体 43
5.7 C 异常处理：`isr_handler_c` 44
5.7.1 Page Fault Handler：`CR2` 与错误码 44
5.8 `idt_init()`：安装所有 gate 45
5.9 验证：`int3` 自检 46
5.9.1 GDB 逐指令验证 47
5.10 思考与练习 47
5.11 本章小结 48

6 IRQ、PIC 与键盘驱动 49
6.1 本章目标 49
6.2 背景知识：8259 PIC 硬件架构 49
6.2.1 为什么必须 Remap? 50
6.3 PIC 初始化：ICW 序列详解 50
6.3.1 ICW1：开始初始化 50
6.3.2 ICW2：向量偏移 51
6.3.3 ICW3：级联关系 51
6.3.4 ICW4：模式设置 52
6.3.5 初始 Mask：全部关闭 52
6.4 EOI（End of Interrupt） 52
6.5 IRQ Mask 操作 53
6.6 IRQ 分发框架：`irq.c` 54
6.6.1 函数指针数组 54
6.6.2 统一 C 入口 54
6.6.3 IRQ 汇编 Stub 55
6.7 PS/2 键盘驱动：`keyboard.c` 55
6.7.1 Scancode Set 1 55

6.7.2 Shift 状态机 56
6.7.3 环形缓冲区 57
6.7.4 公开 API 58
6.7.5 `keyboard_init`：注册 + 开 IRQ 58
6.8 完整中断链路图 59
6.9 验证 59
6.10 思考与练习 60
6.11 本章小结 60

7 交互式 Shell 61
7.1 本章目标 61
7.2 架构设计 61
7.3 Console 输入层：`console.c` 62
7.4 命令接口：`cmd.h` 63
7.5 命令注册表与分发 64
7.5.1 注册表：静态指针数组 64
7.5.2 分发逻辑 64
7.6 行编辑器：`shell_readline` 65
7.6.1 命令分词：`shell_tokenize` 66
7.7 主循环：`shell_run` 67
7.8 命令实现示例 67
7.8.1 `cmd_cls`：清屏 67
7.8.2 `cmd_shutdown`：关机 68
7.9 添加新命令的完整流程 68
7.10 验证 68
7.11 思考与练习 69
7.12 本章小结 69

III 内存管理 70

8 PMM：物理内存管理 71
8.1 本章目标 71
8.2 背景知识：物理内存布局 71
8.2.1 Multiboot2 Memory Map Tag 格式 71
8.3 可插拔后端架构 72
8.3.1 `pmm_ops_t`：后端操作表 72
8.3.2 Dispatch 层：`pmm.c` 73

8.4 Bitmap 分配器：pmm_bitmap.c 74
8.4.1 核心数据结构 74
8.4.2 页 → bit 的映射 74
8.4.3 分配算法：Round-Robin + 线性扫描 75
8.4.4 释放算法 76
8.4.5 初始化流程 77
8.5 Buddy 分配器：pmm_buddy.c 77
8.5.1 核心思想 77
8.5.2 分配：分裂（Split） 78
8.5.3 释放：合并（Coalesce） 78
8.6 后端切换：kconfig.h 78
8.7 验证 79
8.8 思考与练习 80
8.9 本章小结 80

9 VMM：虚拟内存管理 81
9.1 本章目标 81
9.2 背景知识：x86 两级页表 81
9.3 PDE 与 PTE 位域格式 82
9.4 数据结构 83
9.4.1 page_directory_t 与 page_table_t 83
9.5 地址提取辅助函数 84
9.6 High-Half 地址转换宏 85
9.7 核心函数：vmm_ensure_page_table 85
9.8 核心函数：vmm_map_page 86
9.9 TLB 与 invlpg 87
9.10 汇编辅助：paging_flush.asm 88
9.11 vmm_init：初始化全流程 89
9.11.1 进入时的 CPU 状态 89
9.11.2 核心步骤 90
9.12 vmm_unmap_page 与 vmm_unmap_identity 91
9.12.1 解除单页映射 91
9.12.2 拆除 Identity Mapping 92
9.13 查询辅助函数 93
9.14 Shell 验证 93
9.15 思考与练习 94

10 High-Half Kernel：高半区内核 **95**
10.1 本章目标 95
10.2 背景知识：地址空间布局 95
10.3 直接映射区（Direct Mapping） 96
10.4 `PHYS_TO_VIRT` 与 `VIRT_TO_PHYS` 宏 97
10.5 boot.asm 中的 PSE 临时映射 98
10.6 vmm_init 后的双重映射 100
10.7 指针转换：拆除前的准备 100
10.7.1 `g_mb2_info`：Multiboot2 信息结构 100
10.7.2 PMM bitmap 指针 101
10.8 vmm_unmap_identity 实现 101
10.9 VGA text buffer 的特殊处理 103
10.10 kmain 中的初始化顺序 103
10.11 验证：查看映射状态 104
10.12 完整地址空间示意图 105
10.13 思考与练习 105

11 Kernel Heap：kmalloc 与 kfree **107**
11.1 本章目标 107
11.2 背景知识：为什么需要内核堆？ 107
11.3 堆的虚拟地址区域规划 108
11.4 可插拔后端：`heap_ops_t` 接口 108
11.5 First-Fit 空闲链表 109
11.5.1 `block_header_t` 结构 109
11.5.2 分配：遍历 + 拆分 110
11.5.3 释放与合并 111
11.6 堆的初始化与增长 111
11.6.1 `kmalloc_init`：映射初始物理页 111
11.6.2 `heap_brk`：按需增长 112
11.7 Slab 分配器概述 112
11.7.1 7 级 Cache 112
11.7.2 Slab 内存布局 113
11.8 统计信息：`kheap_stats_t` 113
11.9 验证：`heap` 命令 113
11.10 初始化顺序 114
11.11 思考与练习 115

12 VMA：虚拟内存区域管理 116
12.1 本章目标 116
12.2 背景知识：为什么需要 VMA? 116
12.3 vm_area_t 结构体 117
12.4 VMA 权限标志与 PTE 标志的关系 118
12.5 可插拔后端：vma_ops_t 接口 118
12.6 Dispatch 层：vma.c 实现 119
12.7 早期实现：排序数组后端 120
12.7.1 数据结构 120
12.7.2 二分查找辅助函数 121
12.7.3 插入：保持有序 + 重叠检测 122
12.7.4 查找：二分搜索 122
12.7.5 删除：前移覆盖 124
12.7.6 复杂度总结与适用阶段 124
12.8 红黑树后端：vma_rbtree.c 124
12.8.1 红黑树的 5 条性质 125
12.8.2 内部节点结构 125
12.8.3 旋转操作 125
12.8.4 插入与修复 126
12.8.5 删除与修复 127
12.8.6 区间查找 127
12.8.7 中序遍历 dump 127
12.9 Maple Tree 后端：vma_maple.c 127
12.9.1 节点结构 128
12.9.2 查找：从根下降到叶 129
12.9.3 插入：分裂上提 130
12.9.4 与红黑树的对比 130
12.10 静态节点池：打破循环依赖 130
12.11 Page Fault 集成 132
12.12 引导阶段区域注册 132
12.13 vmm_alloc_pages/free_pages 的 VMA 自动跟踪 133
12.14 验证：Shell 命令 134
12.14.1 vma list——列出所有 VMA 134
12.14.2 vma find <addr>——查找指定地址 134
12.14.3 vma test——自测试 135
12.15 内核虚拟地址空间全景与 VMA 覆盖 135
12.16 后端切换：kconfig.h 135

12.17思考与练习 136

IV 进程与用户态 138

13 TSS 与 Ring 3：进入用户态 139
13.1 本章目标 139
13.2 概念：x86 特权级模型 139
13.2.1 CPL、DPL、RPL 三级权限检查 140
13.2.2 特权级切换的硬件机制 141
13.3 TSS 的作用与结构 142
13.3.1 TSS 结构体定义 143
13.3.2 TSS 描述符在 GDT 中的格式 144
13.4 GDT 扩展：添加用户态段 144
13.4.1 用户代码段与用户数据段 145
13.4.2 段选择子的计算 145
13.4.3 代码实现：gdt_init() 扩展 145
13.5 TSS 初始化 146
13.5.1 ltr 指令封装 147
13.5.2 tss_set_kernel_stack() ——为进程切换预留 148
13.5.3 初始化时机与顺序 148
13.6 跳转到用户态：iret 148
13.6.1 iret 帧的构造 148
13.6.2 汇编实现：jump_to_ring3 149
13.6.3 为什么要确保 IF=1? 150
13.7 PDE_USER 标志传播：两级页表的”与”逻辑 150
13.8 验证 152
13.8.1 测试流程 152
13.8.2 用户态测试代码 152
13.8.3 预期输出 153
13.9 本章小结与练习 154
13.9.1 本章小结 154
13.9.2 新增文件清单 154
13.9.3 修改文件清单 154
13.9.4 练习 155

14 系统调用 156
14.1 本章目标 156

14.2 概念：为什么需要系统调用 156
14.2.1 系统调用 vs 普通函数调用 157
14.2.2 三种系统调用入口机制 157
14.2.3 系统调用全路径概览 158
14.3 调用约定：寄存器传参 158
14.3.1 参数快照结构体：syscall_regs_t 159
14.3.2 系统调用号定义 160
14.4 可插拔接口：syscall_ops_t 160
14.4.1 后端注册 API 161
14.4.2 handler 函数签名 162
14.4.3 注册单个 handler 162
14.5 Dispatch 层：syscall.c 实现 162
14.5.1 syscall table 163
14.5.2 后端注册 163
14.5.3 handler 注册 164
14.5.4 syscall_dispatch：调用分发 164
14.6 第一批 syscall handler 165
14.6.1 sys_exit：终止进程 165
14.6.2 sys_write：写数据 166
14.6.3 sys_brk：堆管理 167
14.7 初始化：syscall_init() 168
14.7.1 kmain.c 集成 168
14.7.2 kconfig.h：后端选择 169
14.8 验证 170
14.8.1 QEMU 启动日志 170
14.8.2 dispatch 路径内部验证 170
14.9 后端预告：int 0x80 与 sysenter 171
14.9.1 int 0x80（D-3） 171
14.9.2 sysenter（D-4，进阶） 171
14.10 本章小结与练习 172
14.10.1 本章小结 172
14.10.2 新增文件清单 172
14.10.3 修改文件清单 172
14.10.4 练习 173
14.11 int 0x80 后端实现（D-3） 173
14.11.1 IDT 门安装：idt_install_gate 与 type_attr 174
14.11.2 汇编入口 Stub：syscall_int80_entry 175

14.11.3 C 后端：syscall_int80_backend.c . . . 178
14.11.4 kmain.c 集成：后端注册与编译期切换 . . . 179
14.11.5 用户态测试代码：PIC 技巧 . . . 180
14.12 验证：ring3 syscall 测试 . . . 182
14.12.1 内核启动日志 . . . 182
14.12.2 执行 ring3 syscall 命令 . . . 182
14.12.3 执行流程追踪 . . . 183
14.12.4 验证要点 . . . 184

15 ELF 加载器 186
15.1 本章目标 . . . 186
15.2 概念：可执行文件与加载 . . . 186
15.2.1 ELF32 结构详解 . . . 186
15.3 可插拔接口：loader_ops_t . . . 186
15.4 ELF32 加载器后端 . . . 186
15.5 数据结构 . . . 186
15.6 验证 . . . 186
15.7 本章小结 . . . 186

16 进程管理 188
16.1 本章目标 . . . 188
16.2 概念：进程抽象 . . . 189
16.2.1 进程状态机 . . . 189
16.2.2 进程树与 PID . . . 189
16.3 PCB 数据结构：task_struct . . . 189
16.4 进程地址空间 . . . 189
16.5 fork：进程复制 . . . 189
16.6 exec：加载新程序 . . . 189
16.7 exit + waitpid：进程终止与回收 . . . 189
16.8 验证 . . . 189
16.9 本章小结 . . . 189

17 调度器 190
17.1 本章目标 . . . 190
17.2 概念：CPU 调度 . . . 191
17.2.1 调度算法分类 . . . 191
17.3 可插拔接口：sched_ops_t . . . 191
17.4 PIT 定时器配置 . . . 191

17.5 上下文切换 191
17.6 后端一：Round-Robin 调度器 191
17.7 后端二：优先级调度器（进阶） 191
17.8 验证 191
17.9 本章小结 191

V 文件系统 192

18 VFS：虚拟文件系统 193
18.1 本章目标 193
18.2 概念：为什么需要 VFS 193
18.2.1 文件描述符 193
18.3 可插拔接口：`fs_ops_t` 193
18.4 核心数据结构 193
18.5 系统调用集成 193
18.6 验证 193
18.7 本章小结 193

19 ramfs：内存文件系统 195
19.1 本章目标 195
19.2 概念：initrd 与内存文件系统 195
19.2.1 打包格式选择 195
19.3 ramfs 后端实现 195
19.4 initrd 加载 195
19.5 验证 195
19.6 本章小结 195

20 块设备与磁盘文件系统 196
20.1 本章目标 196
20.2 概念：块设备 197
20.3 可插拔接口：`blkdev_ops_t` 197
20.4 后端一：ATA PIO 驱动 197
20.5 ext2 文件系统概念 197
20.6 ext2 只读后端 197
20.7 ext2 写入支持（进阶） 197
20.8 验证 197
20.9 本章小结 197

21 字符设备 **198**
21.1 本章目标 198
21.2 概念：Unix 设备模型 198
21.3 可插拔接口：`chardev_ops_t` 198
21.4 基础字符设备实现 198
21.5 验证 198
21.6 本章小结 198

VI POSIX 兼容层 **199**

22 信号 **200**
22.1 本章目标 200
22.2 概念：信号机制 200
22.2.1 信号在 PCB 中的表示 200
22.3 信号投递与跳板 200
22.4 系统调用 200
22.5 验证 200
22.6 本章小结 200

23 管道与重定向 **201**
23.1 本章目标 201
23.2 概念：进程间通信 201
23.2.1 dup2 与 I/O 重定向 201
23.3 可插拔接口：`ipc_ops_t` 201
23.4 匿名管道后端 201
23.5 验证 201
23.6 本章小结 201

24 用户态 mmap **202**
24.1 本章目标 202
24.2 概念：mmap 内存映射 202
24.2.1 与 VMA 的关系 202
24.3 匿名映射后端 202
24.4 文件映射后端（进阶） 202
24.5 验证 202
24.6 本章小结 202

25 用户态 libc **203**
25.1 本章目标 203
25.2 概念：libc 的角色 203
25.2.1 C 运行时启动流程 203
25.3 syscall wrapper 层 203
25.4 核心函数实现 203
25.5 验证 203
25.6 本章小结 203

26 用户态 Shell **204**
26.1 本章目标 204
26.2 概念：用户态 Shell 204
26.3 命令行解析 204
26.4 环境变量与 PATH 204
26.5 Job Control 204
26.6 验证 204
26.7 本章小结 204

VII 移植 GCC 与 Vim **206**

27 交叉编译工具链 **207**
27.1 本章目标 207
27.2 概念：交叉编译 207
27.3 定义 i686-szy 目标 207
27.4 构建步骤 207
27.5 验证 207
27.6 本章小结 207

28 终端子系统 **208**
28.1 本章目标 208
28.2 概念：终端 208
28.3 可插拔接口：`tty_ops_t` 208
28.4 termios 实现 208
28.5 PTY + VT100 208
28.6 验证 208
28.7 本章小结 208

29 移植 GCC **210**
29.1 本章目标 210
29.2 概念：GCC 运行时依赖 210
29.3 移植步骤 210
29.4 验证 210
29.5 本章小结 210

30 移植 Vim **211**
30.1 本章目标 211
30.2 概念：Vim 依赖分析 211
30.3 移植步骤 211
30.4 验证 211
30.5 本章小结 211

VIII 网络 **212**

31 网卡驱动 **213**
31.1 本章目标 213
31.2 概念：网络分层 214
31.3 可插拔接口：`netdev_ops_t` 214
31.4 PCI 设备枚举 214
31.5 后端一：E1000 驱动 214
31.6 后端二：virtio-net（备选） 214
31.7 验证 214
31.8 本章小结 214

32 TCP/IP 协议栈 **215**
32.1 本章目标 215
32.2 概念：协议栈分层 215
32.3 可插拔接口：`proto_ops_t` 215
32.4 ARP + IPv4 + ICMP 215
32.5 UDP + TCP 215
32.6 验证 215
32.7 本章小结 215

33 Socket API **216**
33.1 本章目标 216
33.2 概念：BSD Socket 216

33.3 可插拔接口：socket_ops_t 216
33.4 INET Socket 后端 216
33.5 验证 216
33.6 本章小结 216

34 网络工具 217
34.1 本章目标 217
34.2 用户态 ping 217
34.3 简易 HTTP client 217
34.4 验证 217
34.5 本章小结 217

IX 附录 218

A 工具链速查 219
A.1 构建命令 219
A.2 QEMU 常用选项 219
A.3 GDB 常用命令 219
A.4 Shell 命令速查 220

B 内核测试框架 221
B.1 测试架构概览 221
B.1.1 为什么不用标准测试框架? 221
B.2 PMM 测试：物理内存分配器 222
B.2.1 测试代码详解 222
B.3 Heap 测试：内核堆分配器 225
B.3.1 测试代码详解 225
B.4 VMA 测试：虚拟内存区域管理 228
B.4.1 测试地址选择 228
B.4.2 测试代码详解 229
B.5 QEMU 自动化测试脚本 231
B.5.1 工作原理 231
B.5.2 Smoke 测试（始终运行） 231
B.5.3 命令注入测试 231
B.5.4 使用方式 232
B.5.5 测试标志一览 232
B.6 测试设计原则 232

C x86 架构速查 **234**
C.1 寄存器 234
C.1.1 通用寄存器（32 位） 234
C.1.2 段寄存器 234
C.1.3 控制寄存器 234
C.2 GDT 条目格式 235
C.3 IDT 条目格式 235
C.4 PDE / PTE 格式 235
C.5 Page Fault 错误码 235
C.6 中断向量分配 236

Part I

准备工作

Chapter 1

前言

1.1 这本书要做什么

本书记录一个完整的 x86 微内核操作系统——SZY-KERNEL——从第一行汇编代码到能运行用户态程序的全过程。每一章对应项目的一个 Stage，包含：

- **目标**：这一步要实现什么功能
- **背景知识**：必要的硬件/CPU 原理
- **设计决策**：为什么选择这种方案而非其他
- **逐行代码讲解**：关键数据结构和实现
- **验证**：如何确认代码正确工作

1.2 目标读者

- 有 C 语言基础，了解指针、结构体、位运算
- 有基本的计算机组成原理概念（寄存器、内存、中断）
- 对”操作系统到底怎么工作的”感到好奇
- 不要求有汇编经验——书中会逐行解释每条汇编指令

1.3 项目愿景

1. 自举移植 GCC 编译器（在自己的 OS 上编译 C 代码）
2. 运行 Vim 文本编辑器

3. 支持 TCP/IP 网络（至少能 ping）

设计原则：

- **自研优先**——内存管理、分页、调度、系统调用全部自己写
- **POSIX 子集**——不追求完整，够移植 GCC/Vim 即可
- **微内核**——内核只做内存、调度、IPC，驱动尽量在用户态

1.4 全书路线图

Stage	章节	名称	里程碑
1	第 2 章	Multiboot2 引导与串口输出	A: 裸机基础
2	第 3 章	GDT：全局描述符表	A
3	第 4 章	IDT：中断描述符表	A
4	第 5 章	IRQ 与键盘驱动	A
5	第 6 章	交互式 Shell	A
6	第 7 章	PMM：物理内存管理	B: 内存管理
7	第 8 章	VMM：虚拟内存与分页	B
8	第 9 章	High-Half Kernel	C: 高级内存
9	第 10 章	内核堆 kmalloc	C
10	第 11 章	VMA：虚拟内存区域	C
11	第 12 章	TSS 与 Ring 3	D: 进程
12	第 13 章	ELF 加载器	D
13	第 14 章	系统调用	D
14	第 15 章	进程管理	D
15	第 16 章	调度器	D
16	第 17 章	VFS 虚拟文件系统	E: 文件系统
17	第 18 章	initrd / ramfs	E

1.5 如何阅读本书

建议按顺序阅读。每章末尾都有”本章小结”和”验证步骤”，确认当前 Stage 的代码能正常工作后再进入下一章。

所有代码可在 `https://github.com/szylover/my_microkernel` 找到，每个 Stage 对应一个 git tag 或 PR。

Chapter 2

开发环境搭建

2.1 本章目标

在动手写任何内核代码之前，先把工具链准备好：交叉编译器、汇编器、链接器、GRUB 打包工具和 QEMU 模拟器。

2.2 宿主机环境

- 操作系统：Ubuntu 22.04+ / WSL2（本书使用 WSL2 + VS Code Remote）
- 编辑器：VS Code + clangd 扩展

2.3 必要工具安装

```
$ Terminal

$ sudo apt update
$ sudo apt install -y nasm gcc binutils grub-pc-bin \
    xorriso qemu-system-x86 gcc-multilib gdb bear
```

各工具的作用：

工具	用途
`nasm`	x86 汇编器（NASM 语法）
`gcc -m32`	C 编译器（32 位模式）
`ld`	链接器
`grub-mkrescue`	生成 GRUB 可引导 ISO
`xorriso`	ISO 9660 工具（grub-mkrescue 依赖）

qemu-system-i386	x86 模拟器
gdb	调试器
bear	生成 compile_commands.json（给 clangd）

2.4 项目目录结构

```
Directory Structure

my_microkernel/
  src/
    boot/        # Multiboot2 引导 + 链接脚本
    include/     # 公共头文件
    kernel/      # 内核实现
  docs/          # 项目文档
  book/          # 本书 LaTeX 源码
  Makefile       # 顶层 wrapper
```

2.5 构建与运行闭环

```
$ Terminal

$ cd src
$ make iso       # 编译内核 + 打包 ISO
$ make run       # QEMU 启动
$ make debug     # QEMU -S 等待 GDB 连接
$ make gdb       # 另一个终端启动 GDB
```

2.6 VS Code 调试集成

2.7 本章小结

工具链就绪后，下一章我们写第一行代码——Multiboot2 引导头和内核入口。

Part II

裸机基础设施

Chapter 3

Multiboot2 引导与串口输出

3.1 本章目标

- 理解 x86 开机流程：BIOS → GRUB → 内核 `_start`
- 掌握 Multiboot2 header 格式（magic / architecture / length / checksum）
- 理解链接脚本 `linker.ld`：物理加载地址 1 MiB、`.boot` 段、高半区布局
- 掌握 `boot.asm`：PSE 页目录构造、CR4/CR3/CR0 设置、跳转到高半区
- 理解引导期双重映射（identity + high-half）的必要性
- 理解内核栈设置与 `kmain` 的 cdecl 调用约定
- 掌握 UART 16550 寄存器与 `serial_init()` 初始化步骤
- 了解 `printk` 的 `va_list` 实现与格式说明符
- 理解 Multiboot2 info 结构的 tag 迭代解析

3.2 背景知识：x86 开机流程

当你按下电源按钮，到内核第一行 C 代码执行，中间经历了什么？

1. **BIOS/UEFI 自检**——CPU 从 `0xFFFFFFF0`（重置向量）开始执行 BIOS 固件，完成硬件自检（POST）、枚举内存及 PCI 设备。
2. **GRUB 加载**——BIOS 读取启动扇区，加载 GRUB bootloader。GRUB 解析 ELF 内核映像，找到 Multiboot2 header 确认格式正确。
3. **内核入口**——GRUB 把内核加载到 ELF `p_paddr` 指定的物理地址，设置好约定的寄存器状态，跳转到 `_start`。

CPU 状态变化

GRUB 移交控制权时的 CPU 状态：

- `EAX` = `0x36d76289`（Multiboot2 magic，用于内核验证）
- `EBX` = Multiboot2 info 结构体的**物理地址**
- `CR0.PG` = 0（分页关闭），处于 32 位保护模式
- `EIP` `0x00100000`（物理地址，内核加载位置）
- 中断已禁用（`IF=0`），无可用栈

思考 3.1

为什么内核要加载到 1 MiB（`0x100000`）而不是 0 地址？
0–`0xA0000`(640 KiB)是传统 DOS 可用内存，但其中散布着 BIOS 数据区(BDA)、中断向量表(IVT, 0–`0x3FF`)等关键结构，GRUB 运行时也在使用。`0xA0000`–`0xFFFFF` 是 VGA 缓冲区、ROM shadow 和 BIOS 扩展区。1 MiB 以上才是干净的、可自由使用的连续 RAM。

3.3 Multiboot2 Header

GRUB 扫描 OS 映像的前 32 KiB，寻找 8 字节对齐的 Multiboot2 header。header 格式如下：

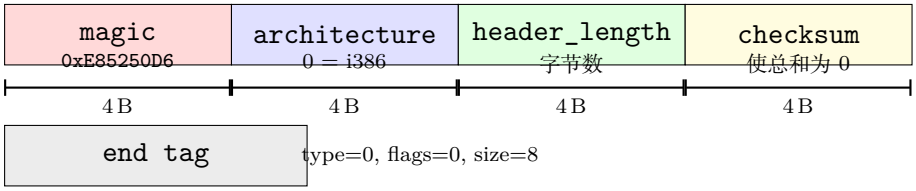

图 3.1: Multiboot2 Header 格式

校验和的计算使四个 32 位字段之和在 2^{32} 模下为 0：

$$\texttt{checksum} = \texttt{0x100000000} - (\texttt{magic} + \texttt{arch} + \texttt{length})$$

对应的汇编实现：

src/boot/boot.asm

```
section .multiboot_header
align 8
header_start:
```

```
    dd 0xe85250d6                   ; Multiboot2 magic
    dd 0                            ; architecture: i386
    dd header_end - header_start    ; header length
    dd 0x100000000 - (0xe85250d6 + 0 + (header_end - header_start))

    ; Required end tag
    dw 0   ; type
    dw 0   ; flags
    dd 8   ; size
align 8
header_end:
```

注意

Multiboot2 header 必须位于映像的前 32 KiB 内，且 8 字节对齐。链接脚本必须确保 `.multiboot_header` 是映像中最早的段，否则 GRUB 会报“`error: no multiboot header found`”并拒绝加载。

3.4 链接脚本 linker.ld 详解

链接脚本控制 ELF 各段的虚拟地址（VMA）和物理地址（LMA）。对于高半区内核（high-half kernel），这两者不同：

src/boot/linker.ld

```
OUTPUT_FORMAT(elf32-i386)
ENTRY(_start)
KERNEL_VIRT_BASE = 0xC0000000;

SECTIONS {
    . = 1M;  /* 物理加载地址从 1 MiB 开始 */
    __kernel_phys_start = .;

    /* Boot 段：物理地址链接 + 物理地址加载 */
    .boot ALIGN(4096) : {
        KEEP(*(.multiboot_header))
        *(.boot .boot.*)
    }
    .boot_bss ALIGN(4096) (NOLOAD) : {
        *(.boot_bss .boot_bss.*)
    }
```

```

    /* 切换到高半区虚拟地址 */
    . += KERNEL_VIRT_BASE;
    __kernel_virt_start = .;

    /* 内核段：虚拟地址是 0xC01xxxxx，物理地址通过 AT() 回到 1M+ */
    .text ALIGN(4096) : AT(ADDR(.text) - KERNEL_VIRT_BASE) {
        *(.text .text.*)
    }
    .rodata ALIGN(4096) : AT(ADDR(.rodata) - KERNEL_VIRT_BASE) {
        *(.rodata .rodata.*)
    }
    .data ALIGN(4096) : AT(ADDR(.data) - KERNEL_VIRT_BASE) {
        *(.data .data.*)
    }
    .bss ALIGN(4096) (NOLOAD) : AT(ADDR(.bss) - KERNEL_VIRT_BASE) {
        *(COMMON)
        *(.bss .bss.*)
    }
    __kernel_virt_end = .;
    __kernel_phys_end = __kernel_virt_end - KERNEL_VIRT_BASE;
}
```

核心要点：

- **`. = 1M;`**——位置计数器从 1 MiB 开始，GRUB 将内核加载到此处。
- **`.boot` 段**——包含 Multiboot2 header 和早期引导代码。这些代码在分页开启前执行，必须链接在物理地址上（否则 EIP 不对）。`KEEP` 确保 `.multiboot_header` 不被垃圾回收优化掉。
- **`. += KERNEL_VIRT_BASE;`**——位置计数器跳到 `0xC0000000` + 当前偏移，后续段链接在高半区虚拟地址。
- **`AT(ADDR(.text) - KERNEL_VIRT_BASE)`**——ELF 的 `p_vaddr` = `0xC01xxxxx`（链接地址），但 `p_paddr` = `0x001xxxxx`（加载地址）。GRUB 按 `p_paddr` 加载到物理 RAM，但代码中所有符号引用用的是虚拟地址——分页开启后才能正确解析。
- **`__kernel_phys_start`/`__kernel_phys_end`**——供 PMM 用来保留内核占用的物理内存，避免被分配出去。

思考 3.2

如果去掉 AT() 宏会发生什么?
ELF 的 p_paddr 和 p_vaddr 将相同（都是 0xC01xxxxx）。GRUB 会尝试把内核加载到物理地址 0xC01xxxxx 3 GiB——如果机器只有 256 MiB 内存，加载直接失败。即使内存足够，1 MiB 以下的 BIOS 区域也已经错过，浪费了低端可用 RAM。

3.5 boot.asm 详解：从物理地址到高半区

boot.asm 是内核的入口点 _start。它的核心任务是：在没有分页的情况下构建临时页目录，开启分页后跳转到高半区。

3.5.1 保存 Multiboot2 信息

src/boot/boot.asm

```
_start:
    mov esi, eax          ; magic (0x36d76289)
    mov edi, ebx          ; mb2 info pointer (physical address)
```

GRUB 传入的 EAX（magic）和 EBX（info 指针）保存在 callee-saved 寄存器 ESI/EDI 中，以便后续传给 kmain。

3.5.2 PSE 页目录构造

src/boot/boot.asm

```
; 清零页目录 (1024 x 4B = 4 KiB)
push edi
mov ecx, 1024
xor eax, eax
mov edi, boot_pd
rep stosd
pop edi

; 填充 PSE 映射: 256 x 4 MiB = 1 GiB
xor ecx, ecx
.fill_pse:
    mov eax, ecx
    shl eax, 22           ; eax = ecx * 4 MiB
    or  eax, 0x83         ; PS(bit7) | RW(bit1) | Present(bit0)
    mov [boot_pd + ecx*4], eax      ; identity: PD[i]
```

```
    mov [boot_pd + 768*4 + ecx*4], eax ; high-half: PD[768+i]
    inc ecx
    cmp ecx, 256
    jb .fill_pse
```

为什么？

为什么用 PSE（4 MiB 大页）而不是标准 4 KiB 页？
4 KiB 页需要分配 page table（每个 PDE 指向一个 4 KiB 页表），但此时 PMM 还没初始化——我们甚至不知道哪些物理内存可用。PSE 模式下 PDE 自身就包含 4 MiB 页的物理基地址，不需要页表。只需一个页目录（4 KiB）就能映射整个地址空间。
`vmm_init()` 之后会用 4 KiB 页表替换这些 PSE 条目，实现更细粒度的权限控制。

PSE PDE 的位格式：

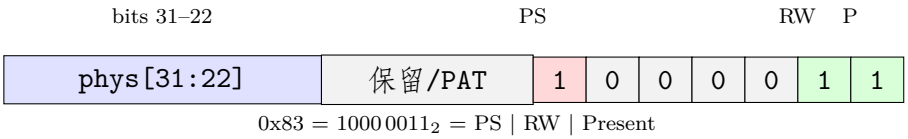

图 3.2: PSE 模式 PDE 位域（`0x83` 标志）

3.5.3 双重映射：Identity + High-Half

循环将同一物理地址同时写入两个 PD 位置：

- `PD[i]`（$i = 0..255$）——Identity 映射：虚拟 $i \times 4\text{MiB} \rightarrow$ 物理 $i \times 4\text{MiB}$
- `PD[768+i]`——High-half 映射：虚拟 `0xC0000000` $+ i \times 4\text{MiB} \rightarrow$ 物理 $i \times 4\text{MiB}$

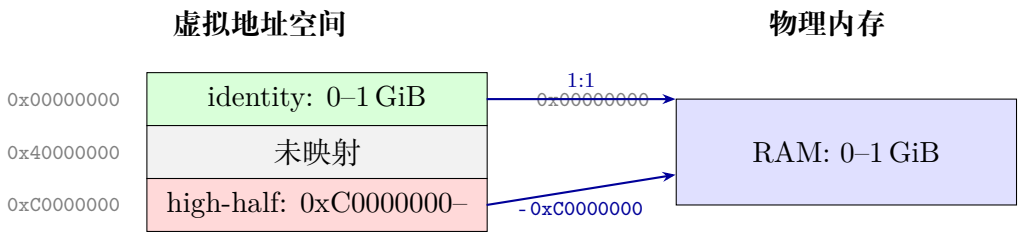

图 3.3: 引导期双重映射：identity 和 high-half 指向同一物理内存

注意

如果只建 high-half 映射而不建 identity 映射会发生什么?
开启分页后，CPU 的下一条指令在物理地址 ~0x001xxxxx。没有 identity 映射，MMU 无法翻译当前 EIP → **Page Fault** → 此时 IDT 还没设置 → **Double Fault** → 没有 DF handler → **Triple Fault** → CPU 重启。
整个"死亡连锁"发生在一条指令之内，QEMU 会直接 reboot，串口什么输出都看不到——这也是引导调试最令人头疼的问题之一。

3.5.4 开启 PSE 和分页

src/boot/boot.asm

```
; CR4.PSE = 1 (允许 4 MiB 页)
mov eax, cr4
or  eax, 0x00000010   ; bit 4 = PSE
mov cr4, eax

; CR3 <- boot_pd (物理地址)
mov eax, boot_pd
mov cr3, eax

; CR0.PG = 1 (开启分页)
mov eax, cr0
or  eax, 0x80000000   ; bit 31 = PG
mov cr0, eax
```

CPU 状态变化

三步 CR 操作后 CPU 状态的逐步变化:

1. CR4.PSE = 1——CPU 现在允许 4 MiB 页，但还没开启分页。
2. CR3 = boot_pd——告诉 CPU 页目录在哪，但分页仍关闭。
3. CR0.PG = 1——分页**立即生效**! 从下一条指令开始，所有内存访问经过 MMU 翻译。Identity 映射保证当前 EIP 仍然有效。

3.5.5 跳转到高半区

src/boot/boot.asm

```
mov eax, _start_high ; 链接地址 = 0xC01xxxxx
jmp eax              ; 跳到高半区虚拟地址
```

_start_high 在 .text 段中，链接在 0xC01xxxxx。mov eax, _start_high 把这个高虚拟地址加载到 EAX，jmp eax 跳转——MMU 通过 PD[768] 将 0xC01xxxxx 翻译回物理 0x001xxxxx。

从此内核运行在高半区虚拟地址空间。

3.6 栈设置与 kmain 调用

进入高半区后，第一件事是设置栈和调用 C 入口：

src/boot/boot.asm

```
section .text
_start_high:
    mov esp, stack_top   ; 栈顶（高半区虚拟地址）
    and esp, 0xFFFFFFF0  ; 16 字节对齐（SSE 要求）

    ; cdecl 调用约定：参数从右向左压栈
    push edi             ; mb2_info（物理地址）
    push esi             ; mb2_magic
    call kmain
    add esp, 8           ; 清理参数（不会执行到这里）

.hlt:
    hlt
    jmp .hlt

section .bss
align 4096
stack_bottom:
    resb 16384           ; 16 KiB 内核栈
stack_top:
```

- 栈在 .bss 段中分配 16 KiB（resb 16384），stack_top 是栈的高地址端（x86 栈向下增长）。
- and esp, 0xFFFFFFF0 确保 16 字节对齐——System V ABI 要求调用函数前 ESP 必须 16 字节对齐。
- push edi; push esi; call kmain——cdecl 约定，参数从右向左压栈，kmain(uint32_t magic, void* mb2_info)。
- kmain 正常不会返回；如果返回则 hlt 停住 CPU。

3.7 UART 16550 串口输出

在 OS 开发中，串口是最可靠的调试输出通道——VGA 文本模式需要正确的显存映射，而串口只需要几个 I/O 端口。QEMU 可以将串口输出重定向到终端（`-serial stdio`），非常方便。

3.7.1 16550 寄存器表

COM1 的基地址为 `0x3F8`，各寄存器偏移如表 3.1：

偏移	DLAB=0	DLAB=1	说明
+0	DATA（读/写）	DLL（除数低字节）	收发数据 / 波特率低字节
+1	IER（中断使能）	DLM（除数高字节）	中断控制 / 波特率高字节
+2	IIR / FCR	—	中断识别 / FIFO 控制
+3	LCR（线路控制）	—	数据位/停止位/校验/DLAB
+4	MCR（Modem 控制）	—	RTS/DTR/OUT 控制
+5	LSR（线路状态）	—	bit 0=DataReady，bit 5=THR Empty

表 3.1: UART 16550 寄存器（COM1 = `0x3F8`）

`DLAB`（Divisor Latch Access Bit）是 LCR 的 bit 7。当 DLAB=1 时，偏移 +0 和 +1 变为波特率除数寄存器。

3.7.2 `serial_init()` 初始化步骤

src/kernel/drivers/serial.c

```c
void serial_init(void) {
    outb(COM1 + 1, 0x00); // 1. 关闭所有中断
    outb(COM1 + 3, 0x80); // 2. 设置 DLAB=1
    outb(COM1 + 0, 0x03); // 3. 除数低字节=3 -> 38400 baud
    outb(COM1 + 1, 0x00); // 4. 除数高字节=0
    outb(COM1 + 3, 0x03); // 5. 8N1, DLAB=0
    outb(COM1 + 2, 0xC7); // 6. 启用 FIFO, 清缓冲, 14B 阈值
    outb(COM1 + 4, 0x0B); // 7. RTS/DTR/OUT2 置位
}
```

逐步解析：

1. 关中断——此时 PIC/IDT 还没设好，串口中断会引发异常。
2. DLAB=1——让偏移 +0/+1 变成除数寄存器。

3. 除数 = 3——波特率 = 115200 ÷ 3 = 38400。
4. 除数高字节 = 0。
5. LCR = 0x03 = 8 数据位、无校验、1 停止位（8N1），同时 DLAB=0。
6. FCR = 0xC7 = 启用 FIFO + 清空收发缓冲区 + 14 字节触发阈值。
7. MCR = 0x0B = RTS + DTR + OUT2（OUT2 在 PC 上与 IRQ 线相连）。

3.7.3 发送一个字符

src/kernel/drivers/serial.c

```c
void serial_putc(char c) {
    if (c == '\n') {
        while (!serial_transmit_empty()) {}
        outb(COM1, '\r');    // CRLF: 先回车
    }
    while (!serial_transmit_empty()) {} // 等 THR 空
    outb(COM1, (uint8_t)c);
}

static int serial_transmit_empty(void) {
    return (inb(COM1 + 5) & 0x20) != 0; // LSR bit5
}
```

发送前轮询 LSR 的 bit 5（Transmitter Holding Register Empty）。遇到 '\n' 时先发 '\r'（CR），确保串口终端换行后光标回到行首（否则输出会呈”阶梯状”）。

3.8 printk 实现概述

printk 是内核的 printf——唯一的格式化输出设施。所有输出最终通过 serial_putc 发送到串口。

3.8.1 核心结构

src/kernel/core/printk.c

```c
void printk(const char* fmt, ...) {
    va_list args;
    va_start(args, fmt);
    vprintk(fmt, args);  // 内部实现
    va_end(args);
```

```
}
```

vprintk 逐字符扫描 fmt，遇到 % 时解析格式说明符。支持的格式如表 3.2：

说明符	参数类型	说明
%d	int	有符号十进制
%u	unsigned	无符号十进制
%x	unsigned	小写十六进制（无 0x 前缀）
%p	void*	指针，格式 0xXXXXXXXX（固定 8 位）
%s	char*	字符串（NULL 安全，输出 (null)）
%c	int	单个字符
%%	—	字面 %

表 3.2: printk 支持的格式说明符

3.8.2 格式化选项

vprintk 还支持：

- **宽度**——%8x 输出至少 8 个字符（右对齐，空格填充）。
- **零填充**——%08x 左侧补零。
- **左对齐**——%-16s 左对齐、右侧补空格。

设计决策

为什么从头实现 printk 而不用 libc 的 printf？
内核没有标准 C 库（freestanding 环境）。printf 依赖 FILE*、stdout、write 系统调用等基础设施——这些都是我们自己要实现的东西。内核的 printk 直接写 serial_putc，零依赖、零缓冲。

3.9 Multiboot2 信息结构解析

GRUB 在 EBX 中传递的 Multiboot2 info 是一个 tag 链表结构：

```c
/* 信息结构头部 */
struct mb2_info {
    uint32_t total_size; /* 整个结构的字节数 */
    uint32_t reserved;
```

```
    /* 后面紧跟若干 tag，每个 tag 8 字节对齐 */
};

/* 每个 tag 的公共头 */
struct mb2_tag {
    uint32_t type;       /* tag 类型 */
    uint32_t size;       /* tag 字节数（含此头） */
};
```

遍历算法：从 `base + 8` 开始，每次跳过当前 tag 的 `size`（向上 8 字节对齐），直到遇到 end tag（type=0, size=8）。

对我们最重要的是 **Memory Map Tag**（type=6），它报告物理内存布局——这是 PMM 初始化的输入数据（详见第 8 章）。

```
struct mb2_mmap_entry {
    uint64_t addr;    /* 区域起始物理地址 */
    uint64_t len;     /* 区域长度 */
    uint32_t type;    /* 1=可用，2=保留，3=ACPI，... */
    uint32_t reserved;
};
```

思考 3.3

Multiboot2 info 指针是**物理地址**，但 `kmain` 在分页开启后的高半区运行。为什么仍然能直接读取 `mb2_info` 的内容？

提示：回顾第 3.5.3 节的 identity 映射——在 `vmm_unmap_identity()` 调用之前，低地址物理页同时可通过 identity 映射和 high-half 映射访问。

3.10 验证

编译并启动后，串口应出现类似如下输出：

```
$ Terminal

[serial] init ok (COM1, 38400 baud)
[mmap] Multiboot2 Memory Map:
  [0x0 - 0x9FC00] type=1 (available) ~639 KiB
  [0x100000 - 0x7FE0000] type=1 (available) ~126 MiB
  ...
[pmm] backend: bitmap
[pmm] init ok: 32495 free pages (126 MiB)
```

- 如果启动后什么都看不到——检查 QEMU 是否加了 `-serial stdio`。
- 如果看到 VGA 上有 "`HH`" 但串口无输出——`serial_init()` 可能有问题，检查端口号和波特率除数。
- 如果 QEMU 反复重启——Triple Fault。检查 Multiboot2 header 和页目录构造。

3.11 思考与练习

练习 3.1

验证 Multiboot2 magic

在 `kmain` 的最开头，检查第一个参数是否等于 `0x36d76289`。如果不等，打印 "`FATAL: invalid multiboot2 magic: 0x%x`" 并 `hlt`。为什么从 GRUB 启动时这个值一定正确，但仍值得检查？(提示：考虑将来用其他 bootloader、或 chainloading 场景)。

练习 3.2

波特率计算

当前 `serial_init()` 设置除数为 3，波特率 $= 115200 \div 3 = 38400$。修改除数为 1，使波特率变为 115200。同时需要修改 QEMU 的 `-serial` 参数吗？(提示：QEMU 的虚拟串口会自动适配，但真实硬件上两端必须匹配。)

练习 3.3

增加 %b 二进制格式支持

给 `vprintk` 添加 `%b` 格式说明符，输出 32 位整数的二进制表示。例如 `printk("%b", 0x83)` 应输出 `10000011`（省略前导零）或 `00000000000000000000000010000011`（填满 32 位）。

建议参照 `fmt_u32_hex` 的实现方式，用循环从高位到低位逐位输出。宽度选项 `%032b` 应输出完整的 32 位（前导零填充）。

Chapter 4

GDT：全局描述符表

4.1 本章目标

- 理解 x86 保护模式下段式内存管理的完整机制
- 掌握 GDT 描述符的 8 字节二进制布局（逐 bit）
- 实现平坦内存模型的 GDT：Null + Kernel Code + Kernel Data
- 理解段寄存器的可见部分（selector）与不可见部分（hidden cache）
- 掌握 `lgdt` + far jump + `mov` 刷新段寄存器的完整流程

4.2 背景知识：保护模式下的段式内存管理

4.2.1 从实模式到保护模式

在实模式下（8086），CPU 使用 `segment:offset` 计算物理地址：

$$\text{物理地址} = \text{segment} \times 16 + \text{offset}$$

这种方式没有任何保护——任何代码都能访问任何内存。

保护模式改变了规则：段寄存器不再直接存储段基址，而是存储一个 16 位的 **段选择子** (selector)。CPU 用 selector 去一张全局表 (GDT) 中查找对应的**段描述符** (segment descriptor)，描述符包含段的基址、大小、权限等信息。

地址翻译变成两步：

1. **分段**：逻辑地址 (selector : offset) → 线性地址 = base + offset
2. **分页**（如果开启）：线性地址 → 物理地址

为什么？

现代 OS 都用**平坦模型**（flat model）：所有段的 base=0, limit=4GiB。这让分段**不参与地址转换**（线性地址 == offset），把控制完全交给分页。但 GDT 不能省略——x86 保护模式硬性要求每个段寄存器都指向一个有效描述符。

4.2.2 段寄存器的"双面"结构

每个段寄存器（CS, DS, SS, ES, FS, GS）实际上包含两部分：

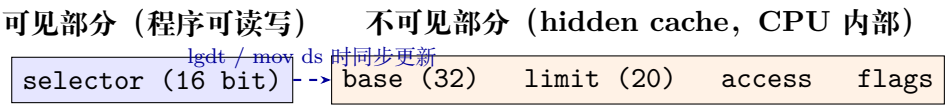

图 4.1: 段寄存器由可见的 selector 和不可见的 hidden cache 组成

当你执行 `mov ds, ax` 时，CPU 做了两件事：

1. 把 `ax`（selector）写入 `DS` 的可见部分
2. 用 selector 去 GDT 查表，把找到的描述符**缓存**到 `DS` 的 hidden part

之后的每次内存访问，CPU 直接用 hidden cache 中的 base/limit/权限，**不再查 GDT**。这就是为什么改了 GDT 后必须重新加载段寄存器——否则 hidden cache 里还是旧的描述符。

思考 4.1

如果 CPU 每次内存访问都重新查 GDT，性能会怎样？一次内存读取原本只需 1 次总线事务，现在变成 3 次（读 GDT → 读描述符 → 读目标内存）。hidden cache 就是为了避免这个开销。

4.3 段选择子格式

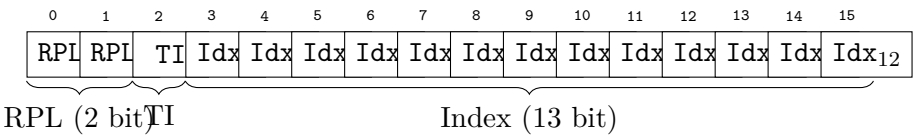

图 4.2: 段选择子的 16 位布局

bit 0--1 RPL (Requested Privilege Level)：请求的特权级。0= 内核，3= 用户。当 selector 加载到段寄存器时，CPU 检查 $\max(\mathrm{CPL}, \mathrm{RPL}) \leq \mathrm{DPL}$。

bit 2 TI (Table Indicator)：0= 在 GDT 中查找，1= 在 LDT 中查找。我们只用 GDT。

bit 3--15 Index：GDT 中的描述符索引。GDT 条目编号从 0 开始，每个 8 字节。selector 的 Index 字段 × 8 就是 GDT 中的字节偏移。

我们的选择子取值：

Selector	二进制	Index	RPL	用途
0x00	0000000000000000	0	0	Null（无效，CPU 用于检查）
0x08	0000000000001000	1	0	内核代码段
0x10	0000000000010000	2	0	内核数据段

src/include/arch/gdt.h

```
// gdt.h
enum {
    GDT_KERNEL_CODE_SEL = 0x08, // Index=1, TI=0, RPL=0
    GDT_KERNEL_DATA_SEL = 0x10, // Index=2, TI=0, RPL=0
};
```

4.4 GDT 描述符的 8 字节布局

这是 x86 最”反直觉”的数据结构之一——由于历史兼容性（286→386），字段被拆成不连续的碎片散布在 8 个字节中。

4.4.1 内存中的字节布局

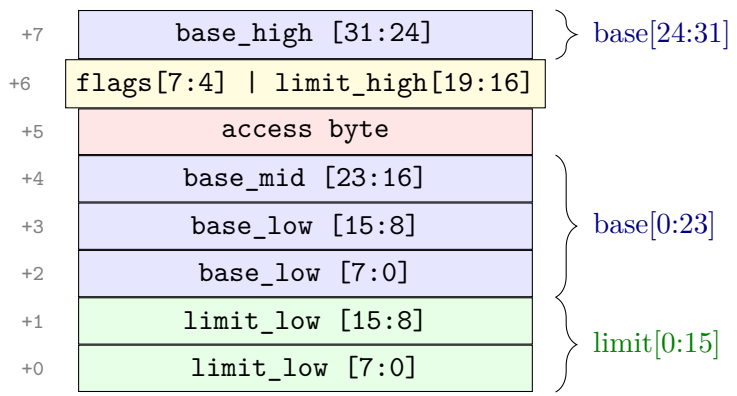

图 4.3: GDT 描述符的 8 字节内存布局（地址从下到上递增）

4.4.2 对应的 C 结构体

src/include/arch/gdt.h

```c
typedef struct __attribute__((packed)) {
    uint16_t limit_low; // 字节 0-1: limit 的低 16 位 [0:15]
    uint16_t base_low; // 字节 2-3: base 的低 16 位 [0:15]
    uint8_t base_mid;  // 字节 4: base 的中间 8 位 [16:23]
    uint8_t access;    // 字节 5: 访问字节 (P/DPL/S/Type)
    uint8_t gran;      // 字节 6: 高4位=flags, 低4位=limit[16:19]
    uint8_t base_high; // 字节 7: base 的最高 8 位 [24:31]
} gdt_entry_t;
```

注意

`__attribute__((packed))` 是**必须的**。没有它，编译器可能在 `base_mid` 后面插入 padding 字节来对齐 `access`，导致整个结构体从 8 字节膨胀到 12 字节——CPU 会把 padding 当作描述符的一部分，结果完全错乱。

思考 4.2

为什么 base 被拆成三段（low/mid/high）而非一个连续的 32 位字段？
因为 286 时代 base 只有 24 位（3 字节），386 扩展到 32 位时在末尾加了 1 字节。Intel 必须向后兼容 286 的描述符格式，所以新增的 8 位只能塞到字节 7。这就是为什么 base 是”碎片化”的——历史包袱。

4.4.3 重组逻辑：gdt_set_entry

因为字段是碎片化的，填充描述符需要位操作来拆分和重组：

src/kernel/arch/gdt.c

```c
static void gdt_set_entry(int idx, uint32_t base, uint32_t limit,
                          uint8_t access, uint8_t flags) {
    // --- limit 拆分: 低 16 位放 limit_low, 高 4 位放 gran 的低半 ---
    gdt[idx].limit_low = (uint16_t)(limit & 0xFFFF);
    //  limit = 0x000FFFFF
    //  limit & 0xFFFF = 0xFFFF → limit_low

    // --- base 拆分: 3 段 ---
    gdt[idx].base_low = (uint16_t)(base & 0xFFFF);
    //  base = 0x00000000
    //  base & 0xFFFF = 0x0000 → base_low

    gdt[idx].base_mid = (uint8_t)((base >> 16) & 0xFF);
    //  (base >> 16) & 0xFF = 0x00 → base_mid

```

```
    gdt[idx].base_high = (uint8_t)((base >> 24) & 0xFF);
    //  (base >> 24) & 0xFF = 0x00 → base_high

    // --- access 直接赋值（完整的 8 位） ---
    gdt[idx].access = access;

    // --- gran 字节：高 4 位是 flags，低 4 位是 limit 的 [16:19] ---
    gdt[idx].gran = (uint8_t)((flags & 0xF0) | ((limit >> 16) & 0x0F));
    //  flags = 0xC0 → 高 4 位 = 0xC (= 1100b → G=1, D/B=1)
    //  (limit >> 16) & 0x0F = 0x0F → 低 4 位
    //  结果：0xCF
}
```

对于我们的内核代码段（base=0, limit=`0xFFFFF`, access=`0x9A`, flags=`0xC0`），实际写入内存的 8 字节是：

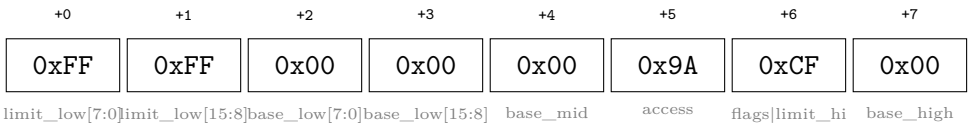

图 4.4: 内核代码段描述符在内存中的实际 8 字节

4.5 Access 字节：逐 bit 详解

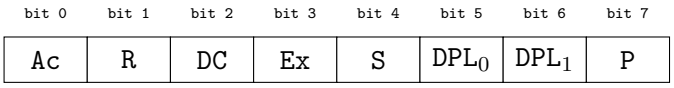

图 4.5: access 字节的 8 个 bit

bit 7 P (Present) = 1：此描述符有效。P=0 时访问该段会触发 #NP (Segment Not Present)。

bit 5--6 DPL (Descriptor Privilege Level)：段的最低访问权限。00_b = Ring 0（只有内核能访问），11_b = Ring 3（用户态可访问）。

bit 4 S (Descriptor Type) = 1：代码/数据段。S=0 表示系统段（TSS、LDT、Call Gate 等），我们将来做 TSS 时会用到。

bit 3 Ex (Executable) = 1：代码段（此段中的内容可以执行）。Ex=0：数据段（此段中的内容只能读/写，不能执行）。

bit 2 DC (Direction/Conforming)：

- 数据段：方向位。0= 向上增长（正常），1= 向下增长（用于栈段扩展）
- 代码段：一致性位。0= 非一致，1= 一致（允许低特权级代码跳入）

我们设为 0。

bit 1 RW (Readable/Writable)：

- 代码段：1= 可读（可以读取代码段中的数据），0= 仅可执行
- 数据段：1= 可写，0= 只读

我们代码段和数据段都设为 1。

bit 0 Ac (Accessed)：CPU 访问此段后自动置 1。OS 可用它做”最近使用”跟踪。初始化时设为 0 即可。

内核代码段 access = `0x9A`

$$\texttt{0x9A} = 10011010_b$$

P	DPL	DPL	S	Ex	DC	RW	Ac
1	0	0	1	1	0	1	0

含义：有效（P=1）、Ring 0（DPL=00）、代码/数据段（S=1）、可执行（Ex=1）、非一致（DC=0）、可读（RW=1）、未访问（Ac=0）。

内核数据段 access = `0x92`

$$\texttt{0x92} = 10010010_b$$

与代码段的唯一区别：Ex=0（不可执行）。RW=1 在数据段表示可写。

4.6 Flags + Limit High 字节（gran）

字节 6 的 8 bit 被分成两半使用：

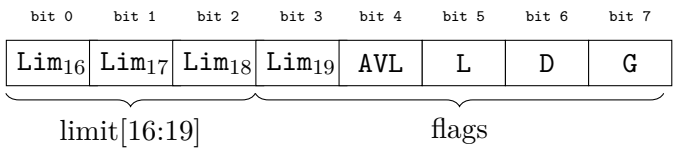

图 4.6: gran 字节的 bit 布局

bit 7 G (Granularity)：limit 的单位。G=0：limit 单位是字节（最大 $2^{20} - 1 = 1\text{MiB}$）。G=1：limit 单位是 4KiB 页（最大 $2^{20} \times 4096 = 4\text{GiB}$）。平坦模型 limit=`0xFFFFF` + G=1 覆盖完整 4GiB 地址空间。

bit 6 D/B (Default Operation Size)：D=1：32 位段（默认操作数和地址大小是 32 位）。D=0：16 位段。我们在 32 位保护模式下必须设 D=1。

bit 5 L (Long mode)：64 位代码段标志。i386 下**必须为 0**。

bit 4 AVL (Available)：CPU 不使用，软件可自由使用。我们设为 0。

bit 0--3 limit 的高 4 位 [16:19]。

我们的 flags = `0xC0`：

$$\texttt{0xC0} = 1100\ \underbrace{0000}_{\text{limit_hi}}$$

即 G=1, D/B=1, L=0, AVL=0。与 limit_high = `0x0F` 合并后 gran = `0xCF`。

4.7 GDTR 结构体

`lgdt` 指令的操作数是一个 6 字节（48 位）的结构体：

src/include/arch/gdt.h

```
typedef struct __attribute__((packed)) {
    uint16_t limit; // GDT 总字节数 - 1
    uint32_t base; // GDT 数组的线性地址
} gdtr_t;
```

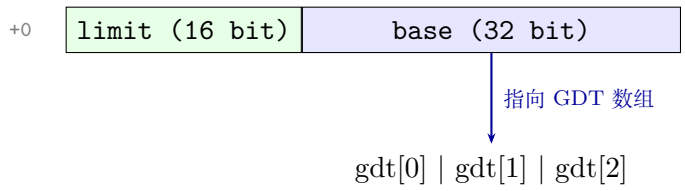

图 4.7: GDTR 的 6 字节布局

src/kernel/arch/gdt.c

```
gdtr.limit = (uint16_t)(sizeof(gdt) - 1); // 3 * 8 - 1 = 23
gdtr.base = (uint32_t)(uintptr_t)&gdt[0]; // GDT 数组的线性地址
```

思考 4.3

为什么 limit 是 “sizeof(gdt) - 1“ 而非 “sizeof(gdt)“？这是 x86 的惯例：limit 表示最后一个有效字节的**偏移**，所以 3 个描述符 × 8 字节 = 24 字节，最后一个字节偏移是 23。如果写 24 会怎样？CPU 会认为 GDT 多了一个字节，可能读到 GDT 数组之外的垃圾数据。

4.8 gdt_init()：填充三个描述符

src/kernel/arch/gdt.c

```c
void gdt_init(void) {
    // 描述符 0: Null 描述符 (x86 硬性要求)
    //  所有字段都是 0。
    //  如果任何段寄存器的 selector = 0x00, CPU 知道它是"空的"。
    //  在某些场景 (如加载 LDT 寄存器) CPU 会检查是否为 null selector。
    gdt_set_entry(0, 0, 0, 0, 0);

    // 描述符 1: 内核代码段 (selector = 0x08)
    gdt_set_entry(1,
        0x00000000, // base = 0 (平坦模型)
        0x000FFFFF, // limit = 0xFFFFF (配合 G=1 → 4GiB)
        0x9A,       // access: P=1, DPL=0, S=1, Ex=1, DC=0, RW=1, Ac=0
        0xC0        // flags: G=1, D/B=1, L=0, AVL=0
    );

    // 描述符 2: 内核数据段 (selector = 0x10)
    gdt_set_entry(2,
        0x00000000, // base = 0 (平坦模型)
        0x000FFFFF, // limit = 0xFFFFF
        0x92,       // access: P=1, DPL=0, S=1, Ex=0, DC=0, RW=1, Ac=0
        0xC0        // flags: G=1, D/B=1, L=0, AVL=0
    );

    gdtr.limit = (uint16_t)(sizeof(gdt) - 1); // 23
    gdtr.base = (uint32_t)(uintptr_t)&gdt[0];

    gdt_flush(&gdtr);
}
```

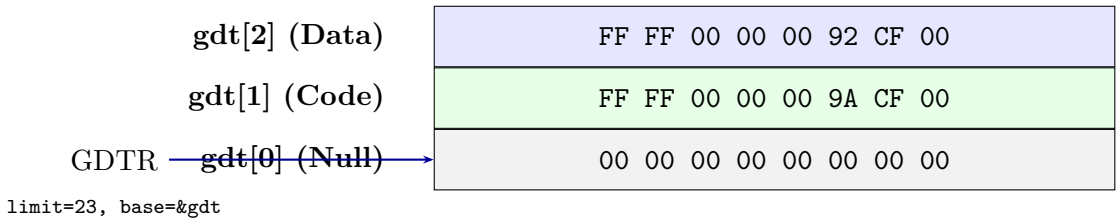

图 4.8: GDT 初始化后的内存布局（3 个描述符 = 24 字节）

设计决策

为什么 GDT 第 0 项必须是空描述符？
Intel 规范规定 selector=0 是 null selector。作用有二：

1. **防御性检查**：如果代码不小心用了未初始化的段寄存器（值为 0），CPU 在访问内存时会检测到 null selector 并触发 #GP，而非悄悄使用错误的段。
2. **LDT 相关**：加载 LDT 寄存器时，null selector 表示" 不使用 LDT"。

思考 4.4

将来做用户态（Ring 3）时，我们需要添加 2 个新描述符：

- 用户代码段（DPL=3，access=`0xFA`）
- 用户数据段（DPL=3，access=`0xF2`）

它们的 selector 分别是多少？（提示：index 3 和 4，各乘以 8。）

4.9 汇编详解：gdt_flush.asm

这是整个 GDT 初始化中最关键也最容易出错的部分。逐条指令解释：

src/kernel/arch/gdt_flush.asm

```
bits 32
global gdt_flush

gdt_flush:
    mov eax, [esp + 4]   ; (1) 取函数参数：gdtr_ptr
    lgdt [eax]           ; (2) 加载 GDTR

    jmp 0x08:.flush_cs   ; (3) far jump 刷新 CS

.flush_cs:
    mov ax, 0x10         ; (4)
    mov ds, ax           ; (5) 刷新 DS
    mov es, ax           ; (6) 刷新 ES
    mov fs, ax           ; (7) 刷新 FS
    mov gs, ax           ; (8) 刷新 GS
    mov ss, ax           ; (9) 刷新 SS
    mov esp, esp         ; (10) SS 后的安全指令

```

```
19    ret                    ; (11) 返回
```

第 5 行：`mov eax, [esp + 4]` `gdt_flush` 使用 cdecl 调用约定。进入函数时栈布局：

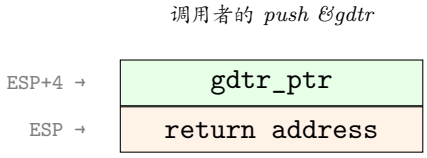

图 4.9: 进入 gdt_flush 时的栈布局

`[esp + 4]` 跳过返回地址，取到 `gdtr_ptr`。

第 6 行：`lgdt [eax]` CPU 从 `eax` 指向的 6 字节中读取 limit（2 字节）和 base（4 字节），写入 GDTR 内部寄存器。

CPU 状态变化

`lgdt` 执行后：

- GDTR.limit = 23, GDTR.base = &gdt[0]
- CPU **知道**新 GDT 在哪了
- 但 `CS`/`DS`/`SS` 的 hidden cache **仍然是旧的**
- 此时用旧 GDT 还是新 GDT 取决于 hidden cache（旧的）

第 8 行：`jmp 0x08:.flush_cs` —Far Jump 这是**最关键的一条指令**。它不是普通的 `jmp`（只改 `EIP`），而是 **far jump**：同时修改 `CS` 和 `EIP`。

- `0x08` → 写入 `CS`（新的 selector）
- `.flush_cs` → 写入 `EIP`（跳转目标）

由于 `CS` 被重新加载，CPU 用新 selector (`0x08`) 去**新 GDT** 查表，找到描述符 1（内核代码段），把 base/limit/权限缓存到 `CS` 的 hidden part。

CPU 状态变化

far jump 执行后：

- `CS` 的可见部分 = `0x08`（index=1, RPL=0）
- `CS` 的 hidden cache = GDT[1] 的完整描述符

- 后续取指令使用新的代码段描述符
- DS/SS 等仍然使用旧缓存——还需要继续刷新

为什么？

为什么刷新 CS 必须用 far jump，不能用 mov cs，ax?
因为 x86 **没有** mov cs，reg 这条指令——CS 不能被直接赋值。唯一能修改 CS 的途径是：far jump、far call、far ret、iret。这些指令会同时修改 CS 和 EIP，确保代码执行流不会”断裂”。

第 11–16 行：刷新数据段寄存器 src/kernel/arch/gdt_flush.asm

```
1   mov ax, 0x10  ; selector = 0x10 = GDT[2] (内核数据段)
2   mov ds, ax    ; DS hidden cache ← GDT[2]
3   mov es, ax    ; ES hidden cache ← GDT[2]
4   mov fs, ax    ; FS hidden cache ← GDT[2]
5   mov gs, ax    ; GS hidden cache ← GDT[2]
```

每条 mov ds，ax 都会触发 CPU：

1. 检查 selector 是否有效（index 在 GDT 范围内、P=1、权限检查通过）
2. 将 GDT[2] 的描述符缓存到对应段寄存器的 hidden part

第 17–18 行：mov ss，ax + mov esp，esp SS 比较特殊：修改 SS 后，CPU 会在**下一条指令执行完**之前 **禁止中断和异常**（硬件行为）。这是为了保证 SS:ESP 的原子性——防止中断在 SS 改了但 ESP 还没改的”半截”状态到来。

mov esp，esp 是一条无害指令（空操作），目的是消耗这个”抑制窗口”。之后 ret 正常返回到 C 代码。

4.10 验证

```
$ Terminal

# 串口输出:
[init] gdt ok
```

如果 GDT 有误（如 access byte 写错、base/limit 计算错误），CPU 会在 far jump 时 Triple Fault 并重启。

4.10.1 GDB 逐指令验证

```
$ Terminal

# 终端 A
$ make DEBUG=1 debug

# 终端 B
$ make gdb
(gdb) b gdt_flush
(gdb) c
Breakpoint 1, gdt_flush () at gdt_flush.asm:21
(gdb) info reg cs ds ss
cs  0x8  8          # GRUB 设置的 CS (通常也是 0x08)
ds  0x10 16         # GRUB 设置的 DS
ss  0x10 16

(gdb) si             # lgdt [eax]
(gdb) si             # jmp 0x08:.flush_cs
(gdb) info reg cs
cs  0x8  8          # CS 重新加载, hidden cache 已更新

(gdb) si             # mov ax, 0x10
(gdb) si             # mov ds, ax
(gdb) info reg ds
ds  0x10 16         # DS 重新加载

(gdb) c              # 继续, 应该看到串口打印 [init] gdt ok
```

4.11 思考与练习

练习 4.1

在 GDB 中的 `gdt_flush` 处，执行 `lgdt` 前后分别用 `info reg cs ds` 查看段寄存器值。`lgdt` 前后 CS 的值有变化吗？`jmp 0x08:.flush_cs` 后呢？画出这三个时间点段寄存器的状态变化。

练习 4.2

把内核代码段的 access 从 `0x9A` 改为 `0x92`（变成数据段描述符）。重新编译运行。会在什么时候崩溃？（提示：far jump 时 CPU 发现 CS 指向的不是代码段……）错误是 #GP 还是 Triple Fault？

练习 4.3

在 GDT 中添加第 4 个条目：DPL=3 的用户代码段（access=`0xFA`，base=0，limit=`0xFFFFF`，flags=`0xC0`）。计算它的 selector。不需要使用它，只需确认添加后内核正常启动。这是 Stage 10 (Ring 3) 的准备。

练习 4.4

（挑战）注释掉 `gdt_flush` 中的 `mov ss, ax` 一行。运行后内核似乎仍然工作？为什么没有立刻崩溃？提示：GRUB 设置的 SS 可能和我们的 `0x10` 一样——用 GDB 验证你的猜想。如果 GRUB 的 SS 配置不同（比如用了不同的 GDT 布局），会怎样？

4.12 本章小结

本章我们完整拆解了 GDT 的每一个字节：

1. **段选择子**（16 位）= index + TI + RPL
2. **描述符**（8 字节）= 碎片化的 base/limit + access byte + flags
3. **段寄存器**的双面结构：可见的 selector + 不可见的 hidden cache
4. **gdt_flush.asm**：lgdt 加载表 → far jump 刷新 CS → mov 刷新 DS/SS

GDT 是 x86 保护模式的基础设施，也是后续 TSS（Ring 3 栈切换）和 IDT（中断门需要代码段 selector）的前置条件。

下一章我们设置 IDT，让内核能捕获 CPU 异常并打印诊断信息。

Chapter 5

IDT：中断描述符表

5.1 本章目标

- 理解 x86 中断与异常的完整机制：向量号、异常分类、错误码
- 掌握 IDT 门描述符的 8 字节二进制布局（逐 bit）
- 理解 Interrupt Gate 与 Trap Gate 的区别
- 设计 ISR 汇编 stub → C handler 的栈布局约定
- 实现 `regs_t` 结构体，与汇编 push 顺序严格对应
- 用 `int3` 自检验证整条链路

5.2 背景知识：中断与异常

CPU 在执行指令的过程中，可能被两种事件打断：

- **异常（Exception）**：**同步**事件，由 CPU 执行指令时产生（如除零、非法指令、Page Fault）。异常和造成它的指令有确定的因果关系。
- **中断（Interrupt）**：**异步**事件，由外部硬件触发（如键盘按键、定时器到期、磁盘完成 I/O）。与当前执行的指令无关。

无论是异常还是中断，CPU 的处理方式相同：

1. 用向量号 N（0–255）在 IDT 中查找第 N 个门描述符
2. 从描述符中取出 handler 的地址（`CS`:offset）
3. 在栈上保存当前的 `EFLAGS`、`CS`、`EIP`（发生特权级切换时还保存 `SS`、`ESP`）
4. 跳转到 handler 执行

5.2.1 异常的三种分类

类型	特征	例子
Fault	EIP 指向**故障指令**。handler 修复问题后 `iret` 会重新执行该指令。	#PF, #GP
Trap	EIP 指向故障指令**的下一条**。`iret` 继续执行后续代码。	`int3`, `int N`
Abort	不可恢复的严重错误，EIP 可能无意义。	#DF

思考 5.1

Page Fault 为什么是 Fault 而非 Trap?

因为 handler 需要**修复**故障（如分配物理页并建立映射），然后让 CPU **重新执行**那条触发 #PF 的指令。如果 EIP 跳过了故障指令（像 Trap 那样），CPU 就永远不会读到那个页面的数据了。这就是**按需分页**（demand paging）的基础。

5.2.2 向量号分配

向量	助记符	名称	有错误码？
0	#DE	除零	否
1	#DB	调试	否
2	NMI	不可屏蔽中断	否
3	#BP	断点 (`int3`)	否
4	#OF	溢出	否
5	#BR	BOUND 范围超出	否
6	#UD	无效操作码	否
7	#NM	设备不可用	否
8	#DF	Double Fault	**是**（总是 0）
9		协处理器段越界	否
10	#TS	无效 TSS	**是**
11	#NP	段不存在	**是**
12	#SS	栈段错误	**是**
13	#GP	通用保护	**是**
14	#PF	Page Fault	**是**
16	#MF	x87 浮点异常	否
17	#AC	对齐检查	**是**
18	#MC	机器检查	否

19	#XM	SIMD 浮点异常	否
32–47	IRQ0–15	硬件中断（PIC remap 后）	否
128	—	系统调用（`int 0x80`）	否

注意

有错误码的异常和没有错误码的异常，在 ISR 汇编 stub 中必须区别对待。如果搞混了，整个栈布局都会偏移——C handler 读到的寄存器值全是错的。

5.3 IDT 门描述符的 8 字节布局

每个 IDT 条目（gate descriptor）是 8 字节（64 位），格式和 GDT 描述符一样”碎片化”：

5.3.1 内存布局

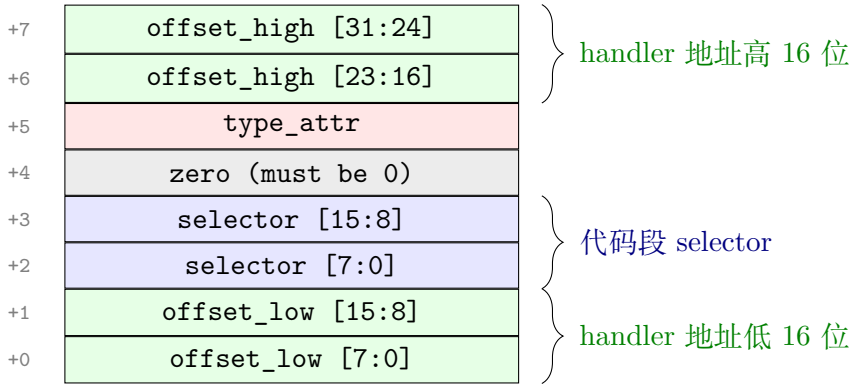

图 5.1: IDT 门描述符的 8 字节内存布局

5.3.2 C 结构体

src/include/arch/idt.h

```
typedef struct __attribute__((packed)) {
    uint16_t offset_low; // handler 地址低 16 位 [0:15]
    uint16_t selector;   // 代码段选择子 (0x08 = 内核代码段)
    uint8_t zero;        // 保留字段，必须为 0
    uint8_t type_attr;   // P(1) | DPL(2) | 0(1) | Type(4)
    uint16_t offset_high; // handler 地址高 16 位 [16:31]
} idt_entry_t;
```

思考 5.2

handler 地址为什么也被拆成 low 和 high 两段？和 GDT 描述符一样，这是 286→386 向后兼容的历史包袱。286 的 IDT 门只有 16 位 offset。

5.3.3 type_attr 字节逐 bit 详解

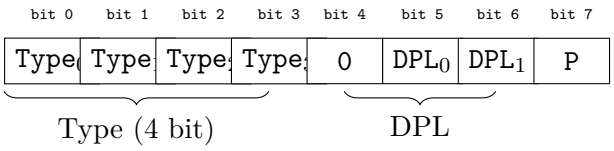

图 5.2: type_attr 字节的 8 个 bit

bit 7 P (Present) = 1：此门有效。P=0 时触发该向量会引发 #NP。

bit 5--6 DPL (Descriptor Privilege Level)：允许通过 `int N` 软件触发此门的最低特权级。DPL=0：只有 Ring 0 能用 `int N` 触发。DPL=3：Ring 3（用户态）也能触发（如 `int 0x80` 系统调用）。**注意**：硬件异常不受 DPL 限制。CPU 除零时无论 DPL 都会进入 handler。

bit 4 固定为 0（区分系统段描述符和门描述符）。

bit 0--3 Type：

- `1110b` = `0xE` = 32-bit Interrupt Gate：进入时**自动清 IF**（关中断）
- `1111b` = `0xF` = 32-bit Trap Gate：进入时**不清 IF**

我们使用 `0x8E`：

$$\texttt{0x8E} = 1\ \underbrace{00}_{DPL=0}\ \underbrace{0}\ \underbrace{1110}_{InterruptGate}$$

设计决策

Interrupt Gate vs Trap Gate——唯一区别是进入 handler 时是否自动清 `EFLAGS.IF`。

Interrupt Gate（`0x8E`）：自动关中断。适合异常处理——处理 #PF 时我们不希望被键盘中断打断，否则嵌套的中断可能在异常尚未修复时访问出错的页面。

Trap Gate（`0x8F`）：不关中断。将来 syscall gate（`int 0x80`）可以考虑用 Trap Gate，让系统调用期间仍能响应硬件中断。

5.3.4 idt_set_gate：填充一个门描述符

src/kernel/arch/idt.c

```
static void idt_set_gate(uint8_t vector, void (*handler)(void),
                         uint16_t selector, uint8_t type_attr) {
    uint32_t addr = (uint32_t)(uintptr_t)handler;

    idt[vector].offset_low = (uint16_t)(addr & 0xFFFF);
    //  addr = 0xC0101234
    //  addr & 0xFFFF = 0x1234 → offset_low

    idt[vector].selector = selector;
    //  0x08（内核代码段）

    idt[vector].zero     = 0;
    //  保留字段，必须为 0

    idt[vector].type_attr = type_attr;
    //  0x8E = Interrupt Gate, DPL=0, Present

    idt[vector].offset_high = (uint16_t)((addr >> 16) & 0xFFFF);
    //  (addr >> 16) & 0xFFFF = 0xC010 → offset_high
}
```

CPU 触发向量 N 时，从 IDT[N] 拼出 handler 地址：

$$\text{handler} = (\text{offset_high} \ll 16) \mid \text{offset_low}$$

然后用 selector（`0x08`）去 GDT 查代码段描述符，切换到内核代码段执行 handler。

5.3.5 IDTR 结构体

和 GDTR 格式完全相同：6 字节，limit + base。

src/include/arch/idt.h

```
typedef struct __attribute__((packed)) {
    uint16_t limit; // IDT 总字节数 - 1
    uint32_t base; // IDT 数组的线性地址
} idtr_t;
```

256 个门 × 8 字节 = 2048 字节，所以 `limit = 2047`。

5.4 ISR 汇编 Stub：isr_stubs.asm

这是 IDT 实现中最精密的部分——必须保证汇编 push 的顺序与 C 结构体**完全一致**。

5.4.1 问题：栈布局不统一

当异常发生时，CPU 自动压栈：

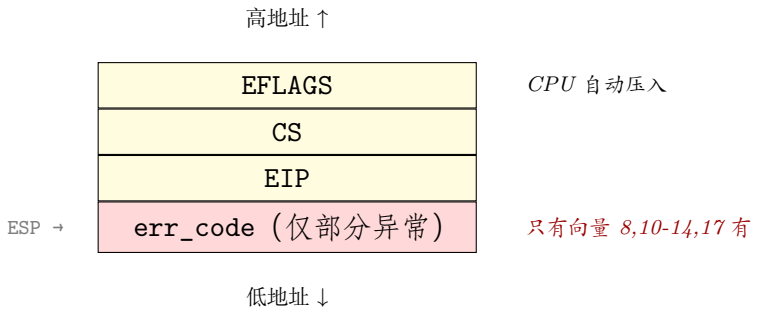

图 5.3: 异常入口时 CPU 自动压栈的内容

问题：有些异常（如 #PF）CPU 会额外压入一个 error code，有些（如 #DE）不会。如果不处理这个差异，C handler 无法用统一的结构体解析栈。

5.4.2 解决方案：ISR_NOERR 和 ISR_ERR 宏

src/kernel/arch/isr_stubs.asm

```
; 无错误码的异常：手动 push 0 对齐
%macro ISR_NOERR 1
isr%1:
    push dword 0        ; 伪 err_code = 0
    push dword %1       ; int_no
    jmp isr_common_stub
%endmacro

; 有错误码的异常：CPU 已经 push 了 err_code
%macro ISR_ERR 1
isr%1:
    push dword %1       ; int_no (err_code 已在栈上)
    jmp isr_common_stub
%endmacro
```

效果：无论哪种异常，进入 isr_common_stub 时栈顶布局总是统一的：

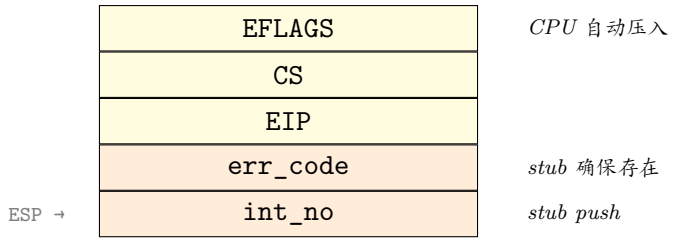

图 5.4: 进入 isr_common_stub 时的统一栈布局

5.4.3 isr_common_stub：逐指令详解

src/kernel/arch/isr_stubs.asm

```
isr_common_stub:
    pushad              ; (1) 保存 8 个通用寄存器

    push ds             ; (2) 保存段寄存器
    push es             ; (3)
    push fs             ; (4)
    push gs             ; (5)

    mov ax, 0x10        ; (6) 切换到内核数据段
    mov ds, ax          ; (7)
    mov es, ax          ; (8)
    mov fs, ax          ; (9)
    mov gs, ax          ; (10)

    push esp            ; (11) 参数：指向 regs_t 的指针
    call isr_handler_c  ; (12) 调用 C handler
    add esp, 4          ; (13) 清理参数

    pop gs              ; (14) 恢复段寄存器
    pop fs              ; (15)
    pop es              ; (16)
    pop ds              ; (17)

    popad               ; (18) 恢复通用寄存器

    add esp, 8          ; (19) 跳过 int_no 和 err_code

    iret                ; (20) 从中断返回
```

第 2 行：`pushad` `pushad` 一次性压入 8 个通用寄存器，顺序是：EAX → ECX → EDX → EBX → ESP → EBP → ESI → EDI。

注意

`pushad` 压入的 ESP 是**执行 `pushad` 之前**的值（即"当时的快照"），不是当前栈指针。这意味着 `regs_t` 中的 `esp` 字段只是参考值，不能用来恢复栈。`popad` 恢复时会跳过 ESP 字段。

第 3–6 行：保存段寄存器 `push ds/es/fs/gs` 的顺序决定了 `regs_t` 中对应字段的位置。**顺序必须严格匹配**——下面会看到 C 结构体的字段排列。

第 7–11 行：切换到内核数据段 异常可能发生在段寄存器指向非内核段的时候（将来用户态会遇到）。在调用 C handler 前，先确保 DS/ES 指向内核数据段 `0x10`。

第 12–14 行：调用 C handler `push esp` 把当前栈指针作为参数传给 `isr_handler_c`。此时 ESP 恰好指向刚才 push 的所有数据的起始位置——也就是 `regs_t*`。

第 20 行：`add esp, 8` 跳过栈上的 `int_no` 和 `err_code`（各 4 字节），让 ESP 指向 CPU 自动压入的 EIP/CS/EFLAGS。

第 21 行：`iret` `iret`（Interrupt Return）从栈上弹出 EIP、CS、EFLAGS，恢复到中断前的执行状态。

CPU 状态变化

`iret` 执行时 CPU 弹出三个值：

1. 弹出 EIP → 恢复程序计数器
2. 弹出 CS → 恢复代码段（如果 CS.RPL 变了，触发特权级切换）
3. 弹出 EFLAGS → 恢复标志位（包括 IF，如果原来中断是开的就恢复开启）

如果发生了特权级切换（如从 Ring 0 回到 Ring 3），还会额外弹出 ESP 和 SS。

5.5 完整栈布局图（ISR 入口到 C handler）

这张图展示了从异常发生到进入 C handler 时，栈上所有数据的排列：

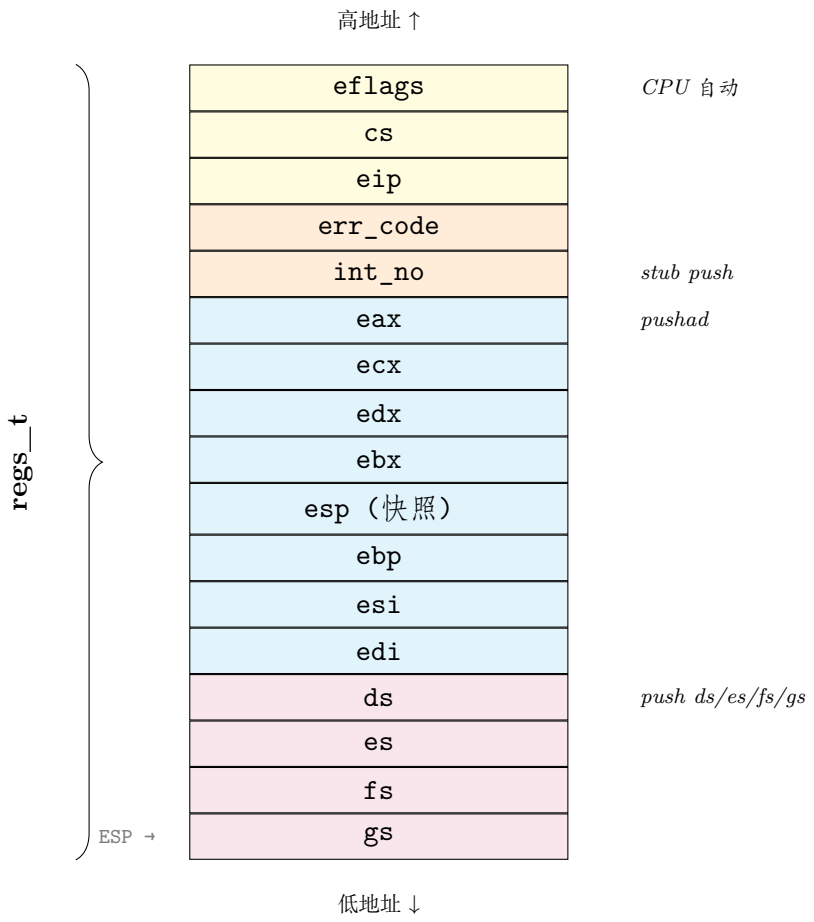

图 5.5: ISR 入口到 push esp（传给 C handler）时的完整栈布局

5.6 regs_t：与汇编栈布局一一对应的 C 结构体

src/include/arch/idt.h

```
typedef struct regs {
    // push gs/fs/es/ds (最后 push 的在最低地址 = 结构体最前面)
    uint32_t gs, fs, es, ds;

    // pushad (EAX 最先 push = 最高地址 → 结构体中排在后面)
    // pushad 的 push 顺序: EAX ECX EDX EBX ESP EBP ESI EDI
    // 栈上从高到低:      EAX ECX EDX EBX ESP EBP ESI EDI
    // 结构体从前到后:    edi esi ebp esp ebx edx ecx eax
    uint32_t edi, esi, ebp, esp, ebx, edx, ecx, eax;

    // ISR stub push 的 int_no 和 err_code
    uint32_t int_no, err_code;

    // CPU 自动压入 (最先压的在最高地址)
```

```
    uint32_t eip, cs, eflags;
} regs_t;
```

注意

regs_t 的字段顺序是由汇编 push 顺序**反向**决定的：

- 最后 push 的数据在最低地址 → 对应结构体的**第一个**字段
- 最先 push 的数据在最高地址 → 对应结构体的**最后一个**字段

如果顺序搞反，C handler 读到的 r->eip 可能是 ds 的值——这种 bug 极难排查。图 5.5 是你的"参照表"。

5.7 C 异常处理：isr_handler_c

src/kernel/arch/idt.c

```c
void isr_handler_c(const regs_t* r) {
    // Page Fault 特殊路径
    if (r->int_no == 14) {
        page_fault_handler(r);
        printk("Kernel panic: #PF Page Fault\n");
        for (;;) __asm__ volatile("hlt");
    }

    // 打印异常信息
    printk("\n[isr] %s vector=%u err=0x%08x eip=0x%08x\n",
           exception_name(r->int_no),
           r->int_no, r->err_code, r->eip);

    // Breakpoint (int3) 允许返回 → 用于自检
    if (r->int_no == 3) return;

    // 其他异常不可恢复
    printk("Kernel panic: %s\n", exception_name(r->int_no));
    for (;;) __asm__ volatile("hlt");
}
```

5.7.1 Page Fault Handler：CR2 与错误码

src/include/arch/idt.h

```c
static inline uint32_t read_cr2(void) {
    uint32_t val;
    __asm__ volatile("mov %%cr2, %0" : "=r"(val));
    return val;
}
```

CR2 在 #PF 发生时由 CPU 自动写入故障虚拟地址。

错误码的逐 bit 含义：

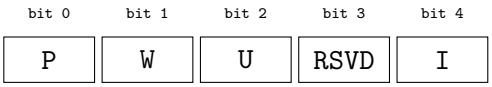

图 5.6: #PF 错误码的低 5 位

bit 0 P (Present)：0= 页不存在（not-present），1= 权限违规（页存在但不允许访问）

bit 1 W/R：0= 读操作引起，1= 写操作引起

bit 2 U/S：0= 在 Ring 0（内核态）发生，1= 在 Ring 3（用户态）发生

bit 3 RSVD：PTE 中的保留位被错误置位（硬件级错误，通常是写 PTE 的代码有 bug）

bit 4 I/D：1= 取指令（instruction fetch）引起，0= 数据访问引起

常见错误码示例：

err_code	含义
0x00	内核态读一个不存在的页
0x02	内核态写一个不存在的页
0x05	用户态读一个存在但权限不足的页
0x07	用户态写一个存在但权限不足的页

5.8 idt_init()：安装所有 gate

src/kernel/arch/idt.c

```c
void idt_init(void) {
    // 清空 IDT (256 项全部归零)
    for (size_t i = 0; i < 256; i++) {
        idt[i] = (idt_entry_t){0};
    }

    // CPU 异常 0..31 (全部用 Interrupt Gate 0x8E)
```

```
    const uint8_t INT_GATE = 0x8E;
    idt_set_gate(0, isr0, GDT_KERNEL_CODE_SEL, INT_GATE);
    idt_set_gate(1, isr1, GDT_KERNEL_CODE_SEL, INT_GATE);
    // ... 每个向量对应自己的 stub ...
    idt_set_gate(14, isr14, GDT_KERNEL_CODE_SEL, INT_GATE); // #PF
    // ... 一直到 31 ...

    // 硬件 IRQ 0x20..0x2F (先装 gate, PIC remap 在下一章)
    idt_set_gate(0x20, irq0, GDT_KERNEL_CODE_SEL, INT_GATE);
    idt_set_gate(0x21, irq1, GDT_KERNEL_CODE_SEL, INT_GATE);
    // ... 到 0x2F ...

    // 加载 IDTR
    idtr.limit = (uint16_t)(sizeof(idt) - 1); // 256*8-1 = 2047
    idtr.base = (uint32_t)(uintptr_t)&idt[0];
    lidt(&idtr);
}
```

CPU 状态变化

lidt 执行后：

- IDTR.limit = 2047, IDTR.base = &idt[0]
- 从此刻起，任何异常都会通过新 IDT 分发
- 中断仍然关闭（IF=0），直到我们显式 sti
- 未安装的向量（32–255 中大部分）条目全为 0，触发时会引发 #GP

5.9 验证：int3 自检

src/kernel/core/kmain.c

```
// kmain.c
idt_init();
printk("[init] idt ok\n");
__asm__ volatile("int3"); // 触发 #BP
printk("int3 returned, IDT works!\n");
```

预期输出：

```
$ Terminal

[init] idt ok
[isr] #BP Breakpoint vector=3 err=0x00000000 eip=0xC01xxxxx
int3 returned, IDT works!
```

如果看不到 “int3 returned”，说明 `iret` 回不来——检查栈布局。

5.9.1 GDB 逐指令验证

```
$ Terminal

(gdb) b isr_handler_c
(gdb) c
Breakpoint, isr_handler_c (r=0xc01xxxxx)
(gdb) p r->int_no
$1 = 3
(gdb) p/x r->eip
$2 = 0xc010abcd  # int3 指令的下一条地址 (Trap 语义)
(gdb) p/x r->err_code
$3 = 0x0          # int3 没有错误码
```

5.10 思考与练习

练习 5.1

在 `kmain` 中触发除零异常：

```
__asm__ volatile("int $0");
```

观察串口输出的 EIP。它指向哪条指令？和 `int3` 的行为有什么不同？（提示：`int N` 对所有 N 都是 Trap 语义——EIP 指向下一条。但真正的除零 `1/0` 是 Fault——EIP 指向 `div` 指令本身。）

练习 5.2

故意将 `isr_common_stub` 中 `pushad` 和 `push ds/es/fs/gs` 的顺序对调。然后触发 `int3`，看 C handler 打印的 `r->eip`。它还正确吗？参考图 5.5 分析为什么。

练习 5.3

将所有异常的 `type_attr` 从 `0x8E`（Interrupt Gate）改为 `0x8F`（Trap Gate）。运行后键盘是否还能正常输入？（提示：Trap Gate 不关中断，异常处理期间可能被键盘 IRQ 打断。在当前简单内核中可能没问题，但在更复杂的场景下会导致嵌套中断问题。）

练习 5.4

（挑战）当前 `idt_init` 中 `int3` 的 DPL=0。这意味着将来的用户态程序不能用 `int3` 做调试断点。把它改成 DPL=3（`type_attr = 0xEE`），并解释 `0xEE` 的逐 bit 含义。

5.11 本章小结

IDT 是内核的”异常/中断事件分发表”。本章涵盖了：

1. **IDT 门描述符**（8 字节）：offset 拆分 + selector + type_attr 逐 bit
2. **ISR 汇编 stub**：NOERR/ERR 宏统一栈布局 → pushad → push 段寄存器 → call C
3. **regs_t 结构体**：字段顺序严格对应汇编 push 顺序（图 5.5）
4. **Page Fault 特殊处理**：读 `CR2` + 5 bit 错误码解析
5. **int3 自检**：验证整条链路 ISR stub → C handler → iret

有了 IDT，内核不再”闷死”——任何 CPU 错误都会被捕获并打印诊断信息。下一章我们接入硬件中断：初始化 8259 PIC，让键盘能触发 IRQ 并输入字符。

Chapter 6

IRQ、PIC 与键盘驱动

6.1 本章目标

- 理解 8259 PIC 的硬件架构：主从级联、ICW 初始化序列、IRQ mask、EOI
- 理解为什么必须 remap PIC（避免与 CPU 异常冲突）
- 实现 IRQ 分发框架：函数指针数组 + 统一 EOI
- 理解 IRQ 汇编 stub 与 ISR stub 的关系
- 实现 PS/2 键盘驱动：scancode 解码、Shift 状态机、环形缓冲区
- 掌握中断上下文与主循环之间的生产者-消费者模式

6.2 背景知识：8259 PIC 硬件架构

PC 有两片级联的 8259A PIC（Programmable Interrupt Controller），
每片管理 8 条 IRQ 线，合计 16 条：

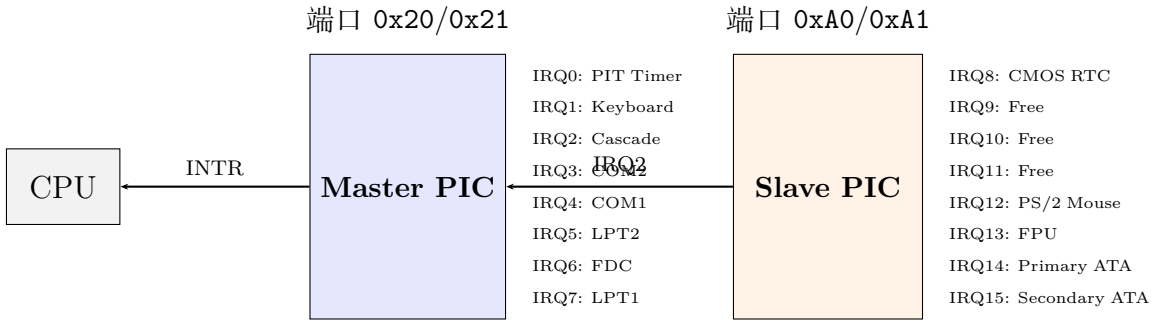

图 6.1: 8259 PIC 主从级联架构与 IRQ 分配

6.2.1 为什么必须 Remap？

PIC 上电后的默认映射：

IRQ	默认向量	冲突
IRQ0	8	#DF (Double Fault)
IRQ1	9	Coprocessor Segment Overrun
IRQ7	15	Reserved

IRQ0-7 的默认向量 8-15 和 CPU 异常**完全重叠**！如果不 remap，按键盘（IRQ1）会被 CPU 当成向量 9（Coprocessor Segment Overrun）处理。

思考 6.1

如果你忘了做 remap 就启用了 IRQ1，按键盘后会发生什么？CPU 认为向量 9 是一个异常，会调用 `isr9` 的 handler。ISR handler 打印 "Coprocessor Segment Overrun" 然后 halt。键盘表现为：按一下就死机。

6.3 PIC 初始化：ICW 序列详解

PIC 通过 4 个 ICW（Initialization Command Word）完成初始化。每个 ICW 有精确的格式和发送顺序：

src/kernel/arch/pic.c

```c
void pic_init(void) {
    // 保存当前 mask（可选，我们会覆盖）
    uint8_t a1 = inb(PIC1_DATA);
    uint8_t a2 = inb(PIC2_DATA);
```

6.3.1 ICW1：开始初始化

src/kernel/arch/pic.c

```c
    outb(PIC1_CMD, 0x11); // ICW1: INIT + ICW4_NEEDED
    io_wait();
    outb(PIC2_CMD, 0x11);
    io_wait();
```

`0x11` = ICW1_INIT (bit 4=1) | ICW1_ICW4 (bit 0=1)。

向命令端口写入 ICW1 告诉 PIC：" 开始初始化序列，后面会有 ICW4"。

为什么？

io_wait() 是什么？ISA 总线的某些旧设备需要在连续 I/O 操作间插入一个短延迟。常见实现是向端口 0x80（POST 诊断端口）写一个字节：

src/include/arch/io.h

```
static inline void io_wait(void) {
    outb(0x80, 0); // 约 1 微秒延迟
}
```

6.3.2 ICW2：向量偏移

src/kernel/arch/pic.c

```
    outb(PIC1_DATA, 0x20); // master: IRQ0 → 向量 0x20
    io_wait();
    outb(PIC2_DATA, 0x28); // slave: IRQ8 → 向量 0x28
    io_wait();
```

这就是 **remap 的核心**：告诉每片 PIC 它管理的 IRQ 对应的起始向量号。

Remap 后的映射：

IRQ	向量	设备
0	0x20 (32)	PIT Timer
1	0x21 (33)	PS/2 Keyboard
2	0x22 (34)	Cascade（slave PIC）
8	0x28 (40)	CMOS RTC
14	0x2E (46)	Primary ATA

6.3.3 ICW3：级联关系

src/kernel/arch/pic.c

```
    outb(PIC1_DATA, 0x04); // master: slave 挂在 IRQ2 (bit 2 = 1)
    io_wait();
    outb(PIC2_DATA, 0x02); // slave: cascade identity = 2
    io_wait();
```

Master 的 ICW3 是一个 bitmask：bit $N = 1$ 表示 IRQN 上挂了一个 slave PIC。0x04 = bit 2 = IRQ2 上有 slave。

Slave 的 ICW3 是自身的 cascade identity：2 表示”我挂在 master 的 IRQ2 上”。

图 6.2: Master PIC 的 ICW3 = `0x04`：IRQ2 位置为 1

6.3.4 ICW4：模式设置

src/kernel/arch/pic.c

```
    outb(PIC1_DATA, 0x01); // 8086/88 模式
    io_wait();
    outb(PIC2_DATA, 0x01);
    io_wait();
```

`0x01` = ICW4_8086：告诉 PIC 工作在 8086 模式（相对于 8085 模式）。现代 x86 都用这个。

6.3.5 初始 Mask：全部关闭

src/kernel/arch/pic.c

```
    outb(PIC1_DATA, 0xFF); // mask 所有 master IRQ
    outb(PIC2_DATA, 0xFF); // mask 所有 slave IRQ
}
```

设计决策

初始化后先把所有 IRQ mask 掉。原因：

1. 此时大部分 IRQ 还没安装 handler。如果中断进来但 IDT 中没有有效的 gate，CPU 会触发 #GP。
2. 每个驱动在 init 时自己调用 `pic_clear_mask(irq)` 打开需要的 IRQ —" 谁用谁开" 原则。

6.4 EOI（End of Interrupt）

IRQ handler 执行完后**必须**向 PIC 发送 EOI，否则 PIC 认为当前中断还在处理中，不会发送同级或更低优先级的后续中断。

src/kernel/arch/pic.c

```
void pic_send_eoi(uint8_t irq) {
```

```
    if (irq >= 8) {
        outb(PIC2_CMD, 0x20); // 先通知 slave
    }
    outb(PIC1_CMD, 0x20);  // 再通知 master (所有 IRQ 都要)
}
```

注意

忘记发 EOI 是最常见的硬件中断 bug。表现为：第一次按键有反应，之后键盘完全死掉。因为 PIC 还在等待上一次 IRQ1 的 EOI，拒绝发送新的中断。

思考 6.2

为什么 slave IRQ（8–15）需要向**两片** PIC 都发 EOI?
因为 slave 是挂在 master 的 IRQ2 上的。一次 slave IRQ 同时占用了：

1. slave PIC 的一个 IRQ 槽位
2. master PIC 的 IRQ2 槽位

两边都要通知释放。

6.5 IRQ Mask 操作

src/kernel/arch/pic.c

```
void pic_clear_mask(uint8_t irq) {
    uint16_t port = (irq < 8) ? PIC1_DATA : PIC2_DATA;
    uint8_t line = (uint8_t)(irq & 7u);

    uint8_t mask = inb(port);     // 读当前 mask
    mask &= (uint8_t)~(1u << line); // 清除对应 bit (0=允许)
    outb(port, mask);             // 写回
}

void pic_set_mask(uint8_t irq) {
    // ...同理，把对应 bit 置 1 (1=屏蔽)
}
```

PIC 的 mask 寄存器（IMR）是一个 8-bit 值，每 bit 对应一个 IRQ：

- bit = 0：允许该 IRQ 通过
- bit = 1：屏蔽该 IRQ

6.6 IRQ 分发框架：irq.c

6.6.1 函数指针数组

src/kernel/arch/irq.c

```
static irq_handler_t g_irq_handlers[16]; // 初始全为 NULL

void irq_install_handler(uint8_t irq, irq_handler_t handler) {
    if (irq < 16) {
        g_irq_handlers[irq] = handler;
    }
}
```

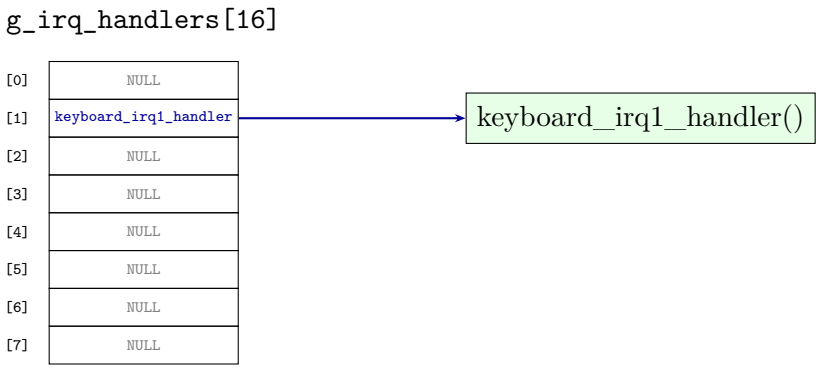

图 6.3: IRQ 分发表：g_irq_handlers 函数指针数组

6.6.2 统一 C 入口

src/kernel/arch/irq.c

```
void irq_handler_c(const irq_regs_t* r) {
    uint8_t irq = (uint8_t)(r->int_no - 0x20u);

    // 调用已注册的 handler (如果有)
    if (irq < 16 && g_irq_handlers[irq]) {
        g_irq_handlers[irq](r);
    }

    // 统一发送 EOI
    pic_send_eoi(irq);
}
```

设计决策

EOI 在 dispatcher 中统一发送，而非让每个 handler 自己发。好处：

1. 驱动开发者不会忘记发 EOI
2. handler 只需专注于设备逻辑
3. 将来做更复杂的 IRQ 优先级管理时只改 dispatcher 一处

6.6.3 IRQ 汇编 Stub

IRQ stub 和 ISR stub 结构相同（push err_code=0 → push int_no → pushad → call C）：

src/kernel/arch/irq_stubs.asm

```
%macro IRQ 2
irq%1:
    push dword 0        ; err_code = 0 (硬件 IRQ 无 error code)
    push dword %2       ; int_no = vector (0x20 + irq)
    jmp irq_common_stub
%endmacro

IRQ 0, 0x20  ; IRQ0 → 向量 0x20
IRQ 1, 0x21  ; IRQ1 → 向量 0x21 (键盘)
; ... 共 16 个 ...
```

`irq_common_stub` 和 `isr_common_stub` 完全一样（pushad → push 段寄存器 → call C → 恢复 → iret），只是调用的 C 函数不同（`irq_handler_c` vs `isr_handler_c`）。

6.7 PS/2 键盘驱动：keyboard.c

6.7.1 Scancode Set 1

PS/2 键盘按下键时发送一个 **make code**（0x00–0x7F），释放时发送 **break code**（make code | 0x80）。

src/kernel/drivers/keyboard.c

```
// Scancode Set 1 基础映射 (部分)
static const char scancode_map[0x40] = {
    /* 0x00 */ 0, 0, '1','2','3','4','5','6','7','8','9','0','-','=',
    /* 0x0E */ '\b', '\t',
    /* 0x10 */ 'q','w','e','r','t','y','u','i','o','p','[',']','\n', 0,
```

```
    /* 0x1E */ 'a','s','d','f','g','h','j','k','l',';','\'','`', 0, '\\',
    /* 0x2C */ 'z','x','c','v','b','n','m',',','.','/', 0, 0, 0, ' ',
};
```

思考 6.3

为什么键盘发送的是 scancode 而非 ASCII?
因为键盘是一个" 物理开关阵列"——它只知道哪个位置的键被按了或松了。把 scancode 翻译成哪个字符取决于**键盘布局**（US、UK、DE、中文等）。同一个 scancode 0x10 在 QWERTY 布局是'q'，在 AZERTY 布局是'a'。翻译工作由操作系统（或键盘驱动）完成。

6.7.2 Shift 状态机

src/kernel/drivers/keyboard.c

```c
static volatile uint8_t g_shift_down; // Shift 是否被按住

static void keyboard_handle_scancode(uint8_t sc) {
    // 0xE0 前缀：扩展键（方向键等），暂时忽略
    if (sc == 0xE0u) { g_e0_prefix = 1; return; }
    if (g_e0_prefix) { g_e0_prefix = 0; return; }

    uint8_t released = (sc & 0x80u) != 0; // 最高位=1 表示松开
    uint8_t code = sc & 0x7Fu;          // 低 7 位 = make code

    // Left Shift (0x2A) 或 Right Shift (0x36)
    if (code == 0x2Au || code == 0x36u) {
        g_shift_down = released ? 0 : 1;
        return;
    }

    if (released) return; // 只处理按下事件

    // 根据 Shift 状态选择映射表
    char ch = g_shift_down ? scancode_map_shift[code]
                           : scancode_map[code];
    if (ch) kbd_buf_put(ch);
}
```

6.7.3 环形缓冲区

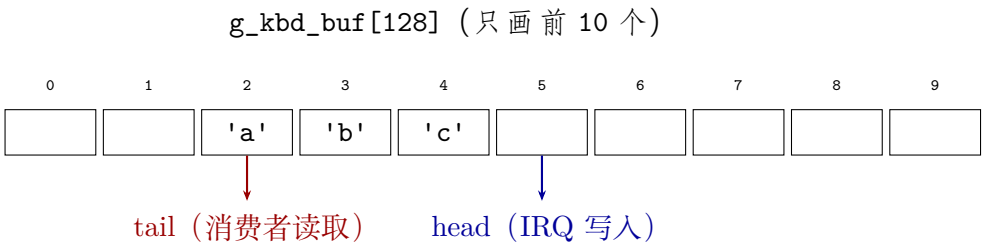

图 6.4: 键盘环形缓冲区：IRQ handler 写 head，主循环读 tail

src/kernel/drivers/keyboard.c

```
#define KBD_BUF_SIZE 128

static volatile char g_kbd_buf[KBD_BUF_SIZE];
static volatile uint8_t g_kbd_head; // 下一个写位置
static volatile uint8_t g_kbd_tail; // 下一个读位置

static void kbd_buf_put(char c) {
    uint8_t next = (g_kbd_head + 1) % KBD_BUF_SIZE;
    if (next == g_kbd_tail) return; // 满了 → 丢弃
    g_kbd_buf[g_kbd_head] = c;
    g_kbd_head = next;
}

static int kbd_buf_get(char* out) {
    if (g_kbd_tail == g_kbd_head) return 0; // 空
    *out = g_kbd_buf[g_kbd_tail];
    g_kbd_tail = (g_kbd_tail + 1) % KBD_BUF_SIZE;
    return 1;
}
```

设计决策

为什么用环形缓冲区而非普通数组？

1. **解耦生产者和消费者**：IRQ handler（生产者）在中断上下文执行，必须尽快返回。Shell 主循环（消费者）在非中断上下文运行，可以慢慢处理。
2. **避免数据拷贝**：环形缓冲区通过 head/tail 指针管理读写位置，不需要移动数组元素。

3. **线程安全**：单生产者 + 单消费者的环形缓冲区在不需要锁的情况下就是线程安全的（原子的 head/tail 更新）。

思考 6.4

g_kbd_buf 和 g_kbd_head/tail 为什么要声明为 volatile?
因为它们在两个”执行流”中被访问：

- IRQ handler（中断上下文）写 g_kbd_head
- keyboard_getc（主循环）读 g_kbd_head

没有 volatile，编译器可能把 g_kbd_head 缓存在寄存器中，导致主循环永远看到旧值——缓冲区”永远为空”。

6.7.4 公开 API

src/kernel/drivers/keyboard.c

```c
// 阻塞等待一个字符（hlt 直到 IRQ 把字符放入缓冲区）
char keyboard_getc(void) {
    char c;
    while (!keyboard_try_getc(&c)) {
        __asm__ volatile("hlt"); // 等下一个中断
    }
    return c;
}

// 非阻塞尝试读取（0=无字符，1=读到一个）
int keyboard_try_getc(char* out) {
    return kbd_buf_get(out);
}
```

为什么？

为什么用 hlt 而非空循环?
hlt 让 CPU 进入低功耗状态直到下一个中断。空循环（while(1){}）让 CPU 100% 占用，白白浪费电力和 QEMU 宿主机 CPU 资源。

6.7.5 keyboard_init：注册 + 开 IRQ

src/kernel/drivers/keyboard.c

```c
void keyboard_init(void) {
    irq_install_handler(1, keyboard_irq1_handler);
    pic_clear_mask(1); // 允许 IRQ1 通过 PIC
}
```

注意此时 EFLAGS.IF 仍然是 0（中断关闭）。IRQ handler 不会触发，直到 `kmain` 末尾执行 `__asm__ volatile("sti")`。

6.8 完整中断链路图

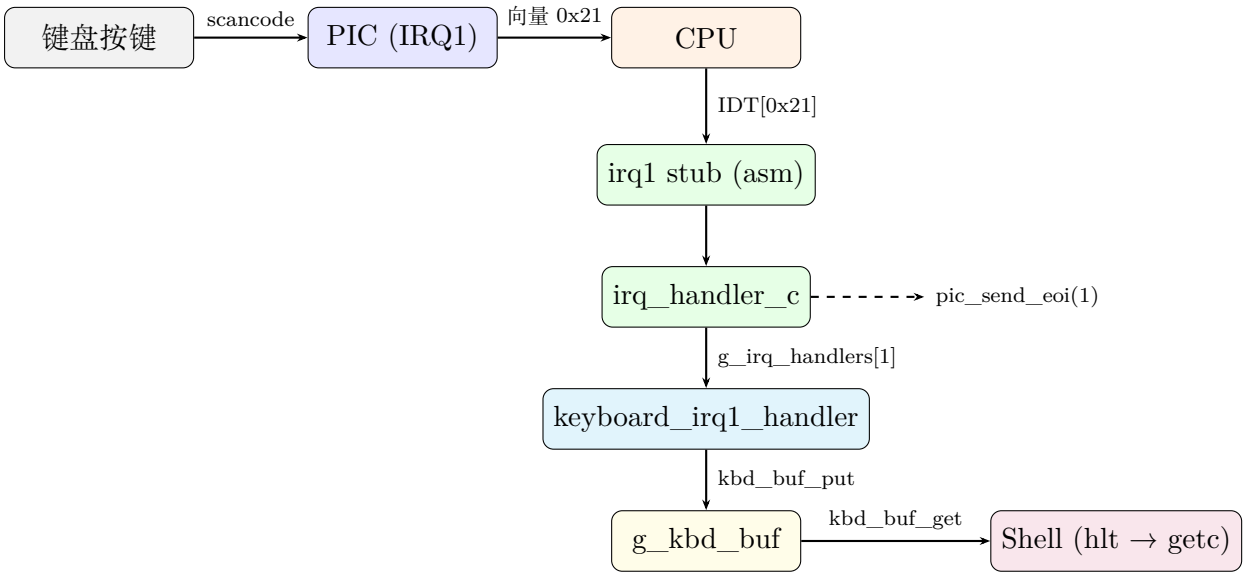

图 6.5: 从键盘按键到 Shell 读取的完整中断链路

6.9 验证

```
$ Terminal

$ make iso && make run
# 在 QEMU 窗口中按键，串口应看到字符回显
# 按 Shift+a 应显示 'A'
# 快速连续打字不应丢字符（除非超过 128 个未消费的字符）
```

6.10 思考与练习

练习 6.1

注释掉 `irq_handler_c` 中 `pic_send_eoi(irq)` 的调用。重新运行，第一次按键后再按键还有反应吗？恢复后试试只给 master 发 EOI （不给 slave），IRQ8–15 的设备是否受影响？

练习 6.2

修改 `KBD_BUF_SIZE` 为 4（极小缓冲区）。快速连续打字 10 个字符，`keyboard_getc` 最多能读到几个？改成 2 呢？思考：环形缓冲区的有效容量是 `size - 1` 还是 `size`？（提示：head == tail 表示空，那满的时候 head 和 tail 是什么关系？）

练习 6.3

在键盘驱动中添加对 Caps Lock 的支持。Caps Lock 的 make code 是 `0x3A`。它是一个" 切换键"——按一次开启，再按一次关闭。提示：维护一个 `g_caps_lock` 状态，按下时 toggle。Caps Lock 只影响字母键的大小写，不影响数字和符号。

练习 6.4

（挑战）当前 `0xE0` 前缀（方向键等）被直接忽略。实现方向键的处理：上箭头（`0xE0 0x48`）、下箭头（`0xE0 0x50`）、左箭头（`0xE0 0x4B`）、右箭头（`0xE0 0x4D`）。把它们翻译成 ANSI 转义序列（如 `\x1b[A` 表示上箭头），放入键盘缓冲区。Shell 可以用这些序列实现光标移动。

6.11 本章小结

本章完成了硬件中断的完整链路：

1. **PIC 初始化**：ICW1-4 序列完成 remap（IRQ → 向量 0x20+），默认 mask 全关
2. **IRQ 分发**：函数指针数组 + 统一 EOI
3. **键盘驱动**：scancode → Shift 状态机 → ASCII → 环形缓冲区
4. **生产者-消费者**：IRQ handler 写 head，主循环读 tail，`volatile` 保证可见性

内核现在能接收用户输入了。下一章我们用这个能力构建交互式 Shell。

Chapter 7

交互式 Shell

7.1 本章目标

- 设计统一的 Console 输入抽象层（键盘 IRQ + 串口轮询）
- 实现行编辑器：回显、退格（`\b`）、回车
- 实现命令解析器：空格分词 → `argc/argv`
- 设计可扩展的命令注册表（`cmd_t` 结构体 + 静态数组）
- 实现第一批命令：`cls`、`shutdown`、`cmds`

7.2 架构设计

Shell 采用五层架构，各层通过清晰的函数接口解耦：

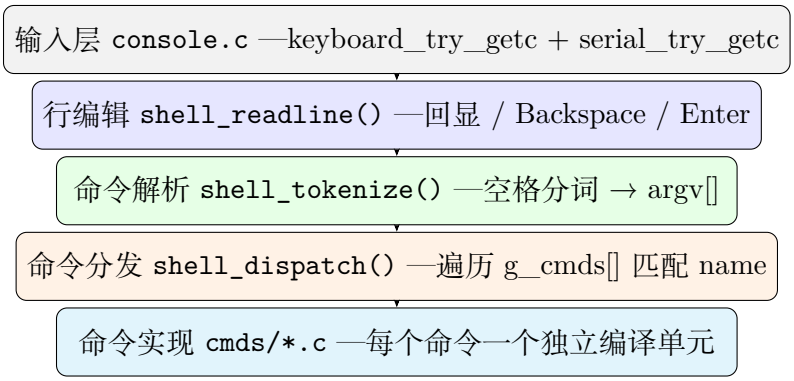

图 7.1: Shell 五层架构

思考 7.1

为什么要把输入抽象成 Console 层？如果 Shell 直接调 `keyboard_getc()`，将来要支持串口远程调试（QEMU `-serial stdio`）时需要改 shell.c。有了 Console 层，输入源的增减只改 console.c 一处。

7.3 Console 输入层：console.c

src/kernel/core/console.c

```c
int console_try_getc(char* out) {
    // 优先查键盘 IRQ 缓冲区（非阻塞）
    if (keyboard_try_getc(out)) return 1;

    // 其次查串口（轮询，非阻塞）
    if (serial_try_getc(out)) {
        if (*out == '\r') *out = '\n'; // 串口终端发 CR，归一化为 LF
        return 1;
    }
    return 0; // 无输入
}

char console_getc(void) {
    for (;;) {
        char c;
        if (console_try_getc(&c)) return c;
        __asm__ volatile("pause"); // 让出 CPU 一个周期
    }
}
```

为什么？

为什么 `console_getc` 用 `pause` 而非 `hlt`？

`hlt` 会让 CPU 完全停止直到下一个中断。但 `serial_try_getc` 是轮询模式（不依赖中断），`hlt` 后如果没有键盘中断就永远不会被唤醒。`pause` 只是一个短暂提示（用于 spin-wait），CPU 仍然继续执行循环。

更好的方案是在每次 `hlt` 前 check 一次串口，但当前简单实现已够用。

7.4 命令接口：cmd.h

src/include/kernel/cmd.h

```
typedef int (*cmd_fn_t)(int argc, char** argv);

typedef struct {
    const char* name; // 命令名（如 "cls"）
    const char* help; // 帮助文本
    cmd_fn_t fn;      // 处理函数
} cmd_t;
```

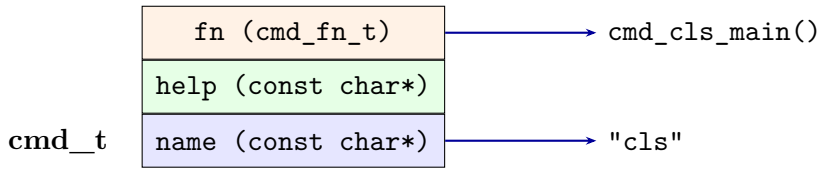

图 7.2: cmd_t 结构体的内存布局与指针指向

每个命令做成独立编译单元（一个 .c 文件），在文件末尾导出一个 const cmd_t：

src/kernel/cmds/cmd_cls.c

```
// cmd_cls.c
static int cmd_cls_main(int argc, char** argv) {
    (void)argc; (void)argv;
    printk("\x1b[2J\x1b[H"); // ANSI 清屏 + 光标归位
    return 0;
}

const cmd_t cmd_cls = {
    .name = "cls",
    .help = "Clear screen (serial ANSI)",
    .fn   = cmd_cls_main,
};
```

设计决策

为什么用 const cmd_t（全局常量）而非注册函数？

1. 编译期确定：不需要运行时动态分配内存（此时堆还没初始化）
2. 链接器自动包含：只要 .o 文件被链接进来，cmd_t 就存在
3. Shell 只需 extern 声明 + 加入数组即可

7.5 命令注册表与分发

7.5.1 注册表：静态指针数组

src/kernel/core/shell.c

```
// shell.c 中
extern const cmd_t cmd_cls;
extern const cmd_t cmd_shutdown;
extern const cmd_t cmd_cmds;
// ... 每加一个命令就加一行 extern ...

static const cmd_t* g_cmds[] = {
    &cmd_cls,
    &cmd_shutdown,
    &cmd_cmds,
    &cmd_mmap,
    &cmd_free,
    &cmd_pmm,
    &cmd_vmm,
    &cmd_heap,
    &cmd_vma,
};
```

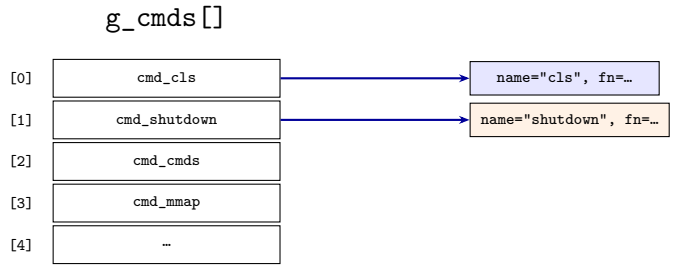

图 7.3: g_cmds[] 是指向各 cmd_t 常量的指针数组

7.5.2 分发逻辑

src/kernel/core/shell.c

```
static void shell_dispatch(char* line) {
    if (!line || !*line) return;

    char* argv[16];
    int argc = shell_tokenize(line, argv, 16);
    if (argc <= 0) return;
```

```c

    // 遍历注册表，匹配 name
    for (size_t i = 0; i < sizeof(g_cmds)/sizeof(g_cmds[0]); i++) {
        if (streq(argv[0], g_cmds[i]->name)) {
            g_cmds[i]->fn(argc, argv);
            return;
        }
    }

    printk("Unknown command: %s\n", argv[0]);
}
```

思考 7.2

当前遍历是 $O(n)$——对几十个命令完全够用。如果将来命令数量上千（不太可能在内核态），可以改为排序数组 + 二分查找或哈希表。但这是过度工程化——**YAGNI**（You Aren't Gonna Need It）。

7.6 行编辑器：shell_readline

src/kernel/core/shell.c

```c
static size_t shell_readline(char* buf, size_t cap) {
    size_t len = 0;
    for (;;) {
        char c = console_getc(); // 阻塞等待一个字符

        if (c == '\n') {
            printk("\n");
            buf[len] = '\0';
            return len;
        }

        // Backspace (0x08) 或 DEL (0x7F)
        if (c == '\b' || (unsigned char)c == 0x7F) {
            if (len > 0) {
                len--;
                printk("\b \b"); // 退格 + 空格覆盖 + 再退格
            }
            continue;
        }
```

```

        // 忽略其他控制字符 (< 0x20)
        if ((unsigned char)c < 0x20) continue;

        // 可见字符: 存入缓冲区 + 回显
        if (len + 1 < cap) {
            buf[len++] = c;
            printk("%c", c);
        }
    }
}
```

退格的三步序列 \b \ \b 详解:

szy-kernel > helo　　按 *Backspace* 前

szy-kernel > hel␣　　*\b* 退格 → 空格覆盖 *'o'*

szy-kernel > hel　　再 *\b* 退格到正确位置

图 7.4: 退格三步序列: \b (退格) → ' ' (覆盖) → \b (归位)

7.6.1 命令分词: shell_tokenize

src/kernel/core/shell.c

```
static int shell_tokenize(char* line, char** argv, int argv_cap) {
    int argc = 0;
    char* p = line;
    while (*p) {
        while (*p && is_space(*p)) p++; // 跳过空白
        if (!*p) break;
        if (argc >= argv_cap) break;
        argv[argc++] = p;           // 记录 token 起始
        while (*p && !is_space(*p)) p++; // 跳过非空白
        if (*p) { *p = '\0'; p++; } // 用 NUL 截断 token
    }
    return argc;
}
```

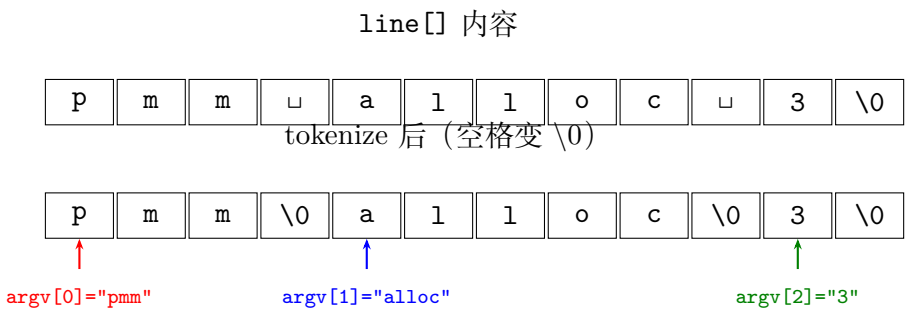

图 7.5: tokenize 将空格替换为 \0，argv[] 指向各 token 起始

注意

shell_tokenize 会**修改**输入字符串（用 \0 替换空格）。这是 C 中常见的”零拷贝分词”技巧——不分配新内存，但调用者不能再使用原始字符串。

7.7 主循环：shell_run

src/kernel/core/shell.c

```
void shell_run(void) {
    printk("\nInteractive shell ready.\n");
    char line[SHELL_LINE_MAX]; // 128 字节栈上缓冲区

    for (;;) {
        shell_print_prompt();              // "szy-kernel > "
        shell_readline(line, sizeof(line)); // 阻塞读一行
        shell_dispatch(line);               // 分词 + 匹配 + 执行
    }
}
```

7.8 命令实现示例

7.8.1 cmd_cls：清屏

src/kernel/cmds/cmd_cls.c

```
printk("\x1b[2J\x1b[H");
```

- \x1b[2J：ANSI 转义序列——清除整个屏幕
- \x1b[H：光标移到左上角 (1,1)

这只对支持 ANSI 的串口终端有效。QEMU -serial stdio 的宿主终端通常支持。

7.8.2 cmd_shutdown：关机

src/kernel/cmds/cmd_shutdown.c

```
outw(0x604, 0x2000); // QEMU ACPI 关机
outw(0xB004, 0x2000); // Bochs 关机
cpu_halt_forever();  // cli + hlt 循环
```

为什么？

为什么要尝试两个不同的端口？因为 QEMU 和 Bochs 的 ACPI 关机端口不同。如果两个都无效（真实硬件），就退化为 `cli; hlt`——CPU 停止，电源不会关闭但系统不再响应。

7.9 添加新命令的完整流程

1. 创建 `src/kernel/cmds/cmd_xxx.c`
2. 实现 handler 函数并导出：

```
const cmd_t cmd_xxx = {
    .name = "xxx", .help = "...", .fn = cmd_xxx_fn
};
```

3. 在 `shell.c` 中添加 `extern const cmd_t cmd_xxx;` 并加入 `g_cmds[]`
4. 无需修改 Makefile——`kernel/cmds/*.c` 被自动发现编译

7.10 验证

```
$ Terminal

szy-kernel > cmds
Commands (9):
cls      shutdown cmds    mmap     free
pmm      vmm      heap    vma
szy-kernel > cls
# 屏幕清空
szy-kernel > shutdown
Shutting down...
# QEMU 窗口关闭
```

7.11 思考与练习

练习 7.1

添加一个 `echo` 命令，将 `argv[1..argc-1]` 用空格连接后打印。示例：`echo hello world` 输出 `hello world`。

练习 7.2

当前 `shell_readline` 的缓冲区是 128 字节。如果用户连续输入 200 个字符（不按回车），超出部分会怎样？修改为在超出时发出 `\a`（BEL，蜂鸣器）提醒。

练习 7.3

实现命令历史：用上箭头键（ANSI `\x1b[A`）回显上一条命令。提示：维护 `history[8][128]` 环形数组。键盘驱动需要先支持方向键（ch05 的挑战练习）。

练习 7.4

（挑战）让 `streq` 支持前缀匹配：输入 `shut` 自动匹配到 `shutdown`（如果只有一个候选）。如果有多个候选，打印所有匹配项。这就是简单的 Tab 补全。

7.12 本章小结

Shell 的核心数据结构：

1. **`cmd_t`**：name + help + fn 函数指针，每个命令一个独立编译单元
2. **`g_cmds[]`**：静态指针数组，编译期确定，遍历分发
3. **行缓冲**：栈上 128 字节，tokenize 原地修改（零拷贝）
4. **Console 层**：统一键盘 + 串口输入，屏蔽输入源差异

Shell 是内核开发阶段最重要的调试工具——后续每实现一个子系统都会立即添加对应的调试命令。下一章进入内存管理：PMM（物理内存分配器）。

Part III

内存管理

Chapter 8

PMM：物理内存管理

8.1 本章目标

- 解析 Multiboot2 Memory Map Tag，获取物理内存布局
- 设计可插拔 PMM 后端接口（`pmm_ops_t` 函数指针表）
- 实现 `pmm.c` dispatch 层
- 实现 bitmap 分配器后端：多 region、位图放置算法、round-robin 分配
- 实现 buddy 分配器后端：order 0–10 分裂/合并
- Shell 命令：`free`、`mmap`、`pmm`

8.2 背景知识：物理内存布局

BIOS 通过 Multiboot2 Memory Map Tag（type=6）报告物理内存区域。一台典型的 256MiB QEMU 虚拟机的内存映射如下：

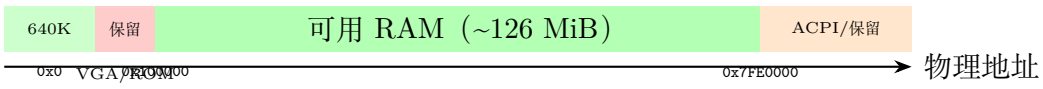

图 8.1: 典型物理内存布局（256MiB QEMU VM）

8.2.1 Multiboot2 Memory Map Tag 格式

src/kernel/mm/mmap.c

```
struct mb2_tag_mmap {
    uint32_t type;       // = 6 (MB2_TAG_TYPE_MMAP)
    uint32_t size;       // tag 总字节数
```

```
    uint32_t entry_size; // 每个 entry 的字节数（通常 24）
    uint32_t entry_version; // = 0
    // 后面紧跟 N 个 mb2_mmap_entry
};

struct mb2_mmap_entry {
    uint64_t addr;       // 区域起始物理地址
    uint64_t len;        // 区域长度（字节）
    uint32_t type;       // 1=Available, 2=Reserved, 3=ACPI, ...
    uint32_t reserved;
};
```

思考 8.1

addr 和 len 是 64 位的。在 32 位内核中，我们只能访问低 4GiB 的物理内存。如何处理报告了 4GiB 以上 RAM 的机器？（答：截断到 0xFFFFFFFF——安全忽略高于 4GiB 的区域。）

8.3 可插拔后端架构

8.3.1 pmm_ops_t：后端操作表

src/include/kernel/pmm.h

```
typedef struct pmm_ops {
    const char* name;               // "bitmap" / "buddy"

    void (*init)(void);             // 解析 mmap → 建立数据结构
    void* (*alloc_page)(void);      // 分配一个物理页，返回物理地址
    void (*free_page)(void* page);  // 释放一个物理页

    unsigned (*total_pages)(void);  // 管理的总页数
    unsigned (*free_pages)(void);   // 当前空闲页数
    unsigned (*managed_base)(void); // 管理区域的物理起始地址

    unsigned (*page_addr)(unsigned idx); // 页索引 → 物理地址
    int (*page_is_used)(unsigned idx); // 页索引 → 使用状态
} pmm_ops_t;
```

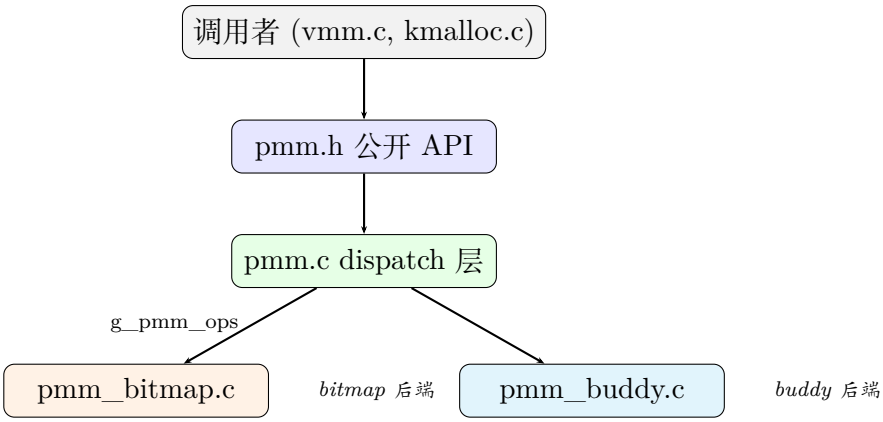

图 8.2: PMM 三层可插拔架构

8.3.2 Dispatch 层：pmm.c

src/kernel/mm/pmm.c

```
static const pmm_ops_t* g_pmm_ops = NULL;

void pmm_register_backend(const pmm_ops_t* ops) {
    g_pmm_ops = ops;
}

void pmm_init(void) {
    if (!g_pmm_ops) g_pmm_ops = pmm_bitmap_get_ops(); // 默认 bitmap
    printk("[pmm] backend: %s\n", g_pmm_ops->name);
    g_pmm_ops->init();
}

void* pmm_alloc_page(void) {
    if (!g_pmm_ops) return NULL;
    return g_pmm_ops->alloc_page();
}

void pmm_free_page(void* page) {
    if (!g_pmm_ops) return;
    g_pmm_ops->free_page(page);
}
// ... 其他函数同理 ...
```

设计决策

这套"ops 函数指针表 + dispatch 薄层" 的模式在本项目中反复出现：

- PMM: `pmm_ops_t` → `pmm.c`
- Heap: `heap_ops_t` → `kmalloc.c`
- VMA: `vma_ops_t` → `vma.c`

这是 Linux 内核 `file_operations` 模式的简化版——接口固定，实现可替换，调用者零改动。

8.4 Bitmap 分配器：pmm_bitmap.c

8.4.1 核心数据结构

src/kernel/mm/pmm_bitmap.c

```
struct pmm_region {
    uint32_t base;            // 区域起始物理地址
    uint32_t pages;           // 管理的总页数
    uint8_t* bitmap;          // 位图指针（每 bit 对应一页）
    uint32_t bitmap_bytes;    // 位图有效字节数 = ceil(pages/8)
    uint32_t bitmap_storage_bytes; // 实际分配字节数（对齐后）
    uint32_t bitmap_pages;    // 位图本身占用的页数
    uint32_t free;            // 当前空闲页数
};

static struct pmm_region g_regions[PMM_MAX_REGIONS]; // 最多 32 个区域
static uint32_t g_region_count = 0;
```

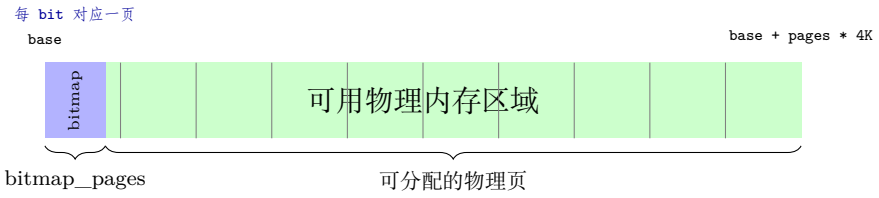

图 8.3: Bitmap 位图放置在区域开头，自身占用几页物理内存

8.4.2 页 → bit 的映射

每个物理页对应位图中的 1 bit：

- bit = 1：页被占用（used/reserved）
- bit = 0：页空闲（free）

src/kernel/mm/pmm_bitmap.c

```c
// 测试第 bit 位是否为 1
static int bitmap_test_r(const struct pmm_region* r, uint32_t bit) {
    uint32_t byte_idx = bit / 8;
    uint8_t bit_mask = (uint8_t)(1u << (bit % 8));
    return (r->bitmap[byte_idx] & bit_mask) != 0;
}

// 置位（标记为 used）
static void bitmap_set_r(struct pmm_region* r, uint32_t bit) {
    r->bitmap[bit / 8] |= (uint8_t)(1u << (bit % 8));
}

// 清位（标记为 free）
static void bitmap_clear_r(struct pmm_region* r, uint32_t bit) {
    r->bitmap[bit / 8] &= (uint8_t)~(1u << (bit % 8));
}
```

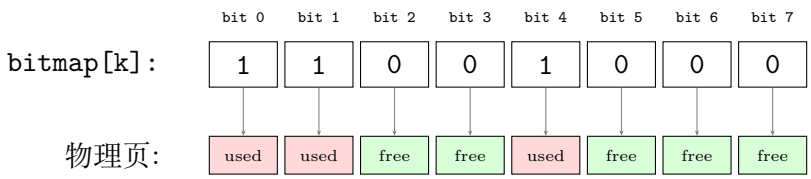

图 8.4: 位图的一个字节（8 bit）对应 8 个连续的物理页

8.4.3 分配算法：Round-Robin + 线性扫描

src/kernel/mm/pmm_bitmap.c

```c
void* pmm_bitmap_alloc_page(void) {
    // Round-robin: 从上次分配的 region 开始，避免总是扫描第一个 region
    for (uint32_t tries = 0; tries < g_region_count; tries++) {
        uint32_t ri = (g_region_rr + tries) % g_region_count;
        struct pmm_region* r = &g_regions[ri];
        if (r->free == 0) continue;

        uint32_t idx;
        if (pmm_find_free_index(r, &idx)) {
```

```
            bitmap_set_r(r, idx);   // 标记为 used
            r->free--;
            g_pmm_total_free--;
            g_region_rr = ri;       // 记住本次从哪个 region 分配的
            return (void*)(uintptr_t)region_index_to_addr(r, idx);
        }
    }
    return NULL; // OOM
}
```

pmm_find_free_index 的核心：先按字节扫描（跳过全 0xFF 的字节），找到有空位的字节后再逐 bit 检查。这把线性扫描的常数因子降低了 8 倍。

思考 8.2

Round-robin 跨 region 分配有什么好处？如果总是从 region 0 开始扫描，region 0 会很快碎片化，而 region 1 始终空闲——分配不均匀。Round-robin 均衡了各 region 的使用率。

8.4.4 释放算法

src/kernel/mm/pmm_bitmap.c

```
void pmm_bitmap_free_page(void* page) {
    uint32_t addr = (uint32_t)(uintptr_t)page;
    // 安全检查：对齐？在管理范围内？
    if (!pmm_addr_is_page_aligned(addr)) return;

    // 找到包含该地址的 region
    for (uint32_t i = 0; i < g_region_count; i++) {
        struct pmm_region* r = &g_regions[i];
        if (!region_contains_addr(r, addr)) continue;

        uint32_t idx = region_addr_to_index(r, addr);
        if (!bitmap_test_r(r, idx)) {
            printk("[pmm] double free: 0x%08x\n", addr); // 防御
            return;
        }
        bitmap_clear_r(r, idx);
        r->free++;
        g_pmm_total_free++;
        return;
```

```
    }
}
```

注意

Double-free 检测：如果 bit 已经是 0 还要清，说明同一个页被 free 了两次。这是严重 bug，打印警告但不执行清除（避免 free count 错乱）。

8.4.5 初始化流程

`pmm_bitmap_init()` 的完整步骤：

1. 解析 Multiboot2 mmap tag，找出所有 type=1（Available）的区域
2. 对每个区域：截断到 $\geq$ 1MiB、$\leq$ 4GiB、页对齐
3. 计算位图大小和放置位置（`pmm_compute_region_layout`）——位图本身也要占物理内存，需要避开内核镜像和 mb2 info
4. 清零位图 → 将位图自身占用的页标记为 used
5. 保留内核镜像区域（`__kernel_phys_start` 到 `__kernel_phys_end`）
6. 保留 Multiboot2 info 区域
7. 重新计算 free count
8. Selftest：分配 4 页 → 写入 pattern → 读回验证 → 释放 → 检查 free 恢复

设计决策

位图放置是初始化中最复杂的部分。位图需要放在可用物理内存中，但它不能覆盖内核镜像或 Multiboot2 info。`pmm_compute_region_layout` 最多尝试 4 次不同的放置方案，直到找到一个不和任何已有数据重叠的位置。

8.5 Buddy 分配器：`pmm_buddy.c`

8.5.1 核心思想

Buddy system 将物理内存分成 2^k 大小的块（order $k = 0, 1, \ldots, 10$）。每个 order 维护一个**空闲链表**：

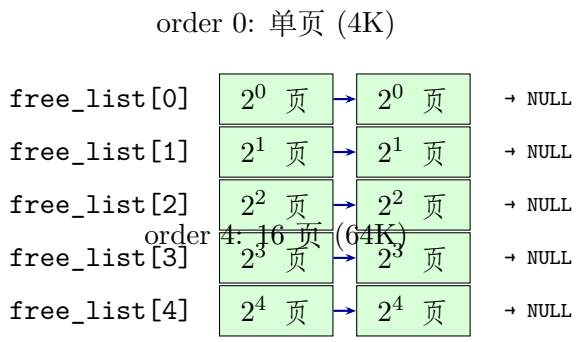

图 8.5: Buddy allocator 的 free_list 数组（每个 order 一个链表）

8.5.2 分配：分裂（Split）

如果请求 order k 但 `free_list[k]` 为空，就从更高 order 取一个块并**分裂**：

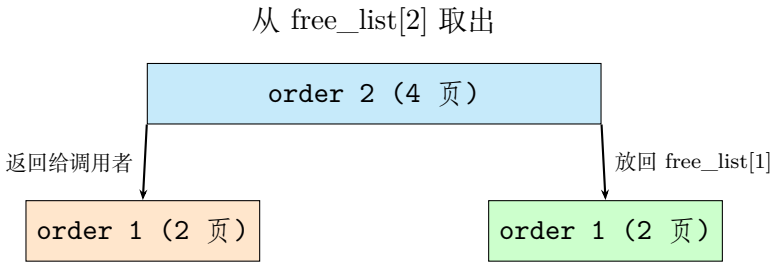

图 8.6: Buddy 分裂：order 2 块拆成两个 order 1 块

8.5.3 释放：合并（Coalesce）

释放一个 order k 块后，检查它的 **buddy** 是否也空闲。如果是，合并为 order $k+1$：

```
// 给定页帧号 P 和 order k, buddy 的帧号:
uint32_t buddy = page_frame ^ (1u << k);
```

思考 8.3

为什么 XOR 能找到 buddy？假设 order 1（2 页），页帧号 4 和 5 是一对，6 和 7 是一对。$4 \oplus 2 = 6$（不是 buddy!）。实际上 buddy 是以**对齐的块**为单位的：order k 块的起始帧号必须是 2^k 的整数倍，所以 $P \oplus 2^k$ 恰好切换到同级的另一半。例如帧 4 的 order-1 buddy $= 4 \oplus 2 = 6$，帧 6 的 buddy $= 6 \oplus 2 = 4$。

8.6 后端切换：kconfig.h

`src/kernel/core/kmain.c`

```c
// kconfig.h
#define KCONFIG_PMM_BACKEND 0 // 0=bitmap, 1=buddy

// kmain.c
#if KCONFIG_PMM_BACKEND == 0
    pmm_register_backend(pmm_bitmap_get_ops());
#elif KCONFIG_PMM_BACKEND == 1
    pmm_register_backend(pmm_buddy_get_ops());
#endif
pmm_init();
```

8.7 验证

```
$ Terminal

szy-kernel > mmap
Available RAM: 0x00000000 - 0x0009FC00 (0MB)
Available RAM: 0x00100000 - 0x07FE0000 (126MB)

szy-kernel > free
PMM: free 32395 / 32768 pages
PMM: free 129580KiB, used 1492KiB

szy-kernel > pmm state
PMM: base=0x00100000, page_size=4096
PMM: total=32768, free=32395, used=373
PMM: backend=bitmap

szy-kernel > pmm alloc 3
pmm alloc: 0x07FC1000
pmm alloc: 0x07FC2000
pmm alloc: 0x07FC3000

szy-kernel > pmm freeall
pmm freeall: freed 3 pages

szy-kernel > pmm dump 0 32
################################ idx 0 addr 0x00100000
```

8.8 思考与练习

练习 8.1

切换到 buddy 后端（`KCONFIG_PMM_BACKEND=1`），运行 `pmm state`。对比 bitmap 和 buddy 的 `free` 数量。buddy 为什么可能更少？（提示：buddy 的元数据——`free_list` 节点和 order 标记——也占物理页。）

练习 8.2

运行 `pmm alloc 100` → `pmm state` → `pmm freeall` → `pmm state`。free 是否完全恢复？如果差了几页，用 `pmm dump` 查看哪些页没被释放。

练习 8.3

在 `pmm_bitmap_alloc_page` 中注释掉 round-robin 逻辑（`g_region_rr = ri`），改为总是从 region 0 开始扫描。连续分配 1000 页后用 `pmm dump` 查看各 region 的分布。和 round-robin 对比有什么不同？

练习 8.4

（挑战）bitmap 分配器不支持连续多页分配。实现一个 `pmm_bitmap_alloc_pages(unsigned count)` 函数：在位图中找到 `count` 个连续的 0 bit，全部置 1 并返回起始物理地址。这比 buddy 的 order 分配更灵活，但扫描开销更大。

8.9 本章小结

PMM 的核心数据结构和算法：

1. **`pmm_ops_t`**：9 个函数指针，定义后端接口
2. **`pmm.c`**：薄 dispatch 层，`g_pmm_ops` 指针转发
3. **Bitmap**：`pmm_region` 结构体 × 多区域，每页 1 bit，线性扫描分配
4. **Buddy**：`free_list[MAX_ORDER+1]`，2^k 分裂/合并
5. **初始化**：解析 mmap → 计算位图放置 → 保留内核 + mb2 → selftest

下一章在 PMM 之上构建虚拟内存管理器（VMM）——两级页表和分页机制。

Chapter 9

VMM：虚拟内存管理

9.1 本章目标

- 理解 x86 32 位两级页表的硬件翻译流程
- 掌握 Page Directory Entry (PDE) 和 Page Table Entry (PTE) 的位域格式
- 实现 `vmm_init`：用 4 KiB 页表替换 `boot.asm` 的临时 PSE 映射
- 实现 `vmm_map_page` / `vmm_unmap_page`：基本映射原语
- 理解 TLB 缓存与 `invlpg` 刷新机制
- 实现 High-Half Kernel 地址转换宏 `PHYS_TO_VIRT` / `VIRT_TO_PHYS`
- 实现 `vmm_alloc_pages` / `vmm_free_pages`：批量虚拟页分配

9.2 背景知识：x86 两级页表

当 `CR0` 的 PG 位（bit 31）被置 1 后，CPU 的每一次内存访问都会经过 **MMU**（Memory Management Unit）进行虚拟 → 物理地址翻译。x86 32 位模式使用**两级页表**结构：

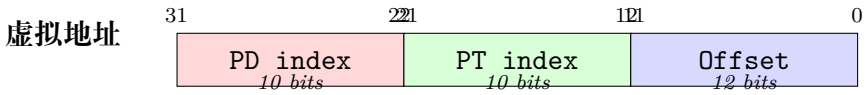

图 9.1: 32 位虚拟地址的三段划分

翻译流程如下：

1. CPU 从 `CR3` 取得 **Page Directory** 的物理基地址。

2. 用虚拟地址的高 10 位（PD index）索引 Page Directory，得到一个 PDE。
3. PDE 的高 20 位指向一个 **Page Table** 的物理地址。
4. 用虚拟地址的中 10 位（PT index）索引 Page Table，得到一个 PTE。
5. PTE 的高 20 位是目标**物理页帧**地址，拼上低 12 位 Offset，即为最终物理地址。

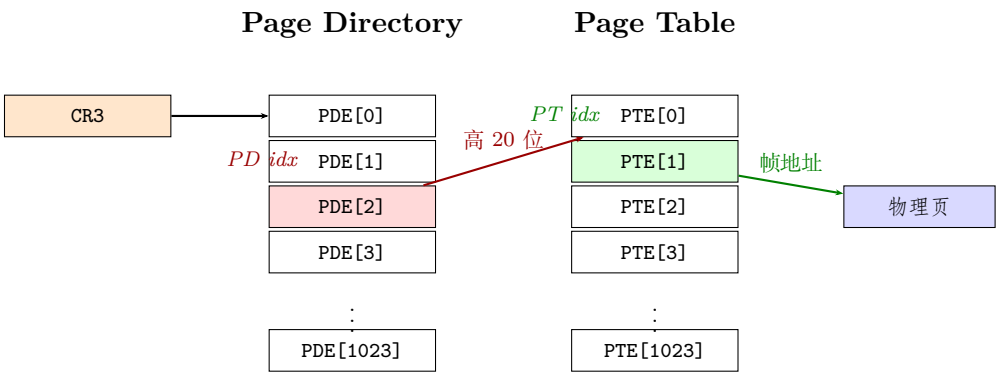

图 9.2: 两级页表翻译流程：CR3 → PDE → PTE → 物理页

为什么？

为什么用两级而不是一级平坦页表?
一级页表需要 2^{20} 个 PTE = 4 MiB 连续内存，即使地址空间大部分为空也要全部分配。两级结构只需 1 个 Page Directory（4 KiB），空闲区域的 PDE 标记为”不存在”，对应的 Page Table 根本不需要分配。大多数进程只用几十个 Page Table，远小于 4 MiB。

9.3 PDE 与 PTE 位域格式

PDE 和 PTE 共享相同的 32 位格式，仅 bit 6–7 的含义略有区别：

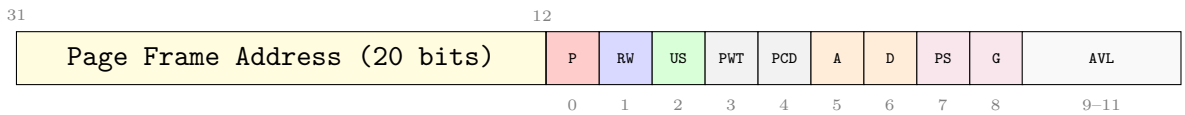

图 9.3: PDE/PTE 32 位格式

Bit	名称	说明
0	P (Present)	1 = 条目有效；0 = 访问触发 #PF (Page Fault)
1	R/W	1 = 可读写；0 = 只读

2	U/S	1 = Ring 3 可访问；0 = 仅 Ring 0
3	PWT	Write-Through 缓存策略（通常置 0）
4	PCD	Cache Disable（通常置 0）
5	A (Accessed)	CPU 访问此页后自动置 1
6	D (Dirty)	CPU 写入此页后自动置 1（PTE 有意义）
7	PS/PAT	PDE: PS=1 启用 4 MiB 大页；PTE: PAT 位
8	G (Global)	1 = TLB 不随 CR3 切换刷新（需 CR4.PGE）
9–11	AVL	软件可用（OS 自定义用途）
12–31	Frame	物理页帧地址的高 20 位（低 12 位隐含为 0，即 4 KiB 对齐）

我们的内核目前只用到三个 flag 宏：

src/include/kernel/vmm.h

```
#define PTE_PRESENT  0x001u /* bit 0: 条目有效 */
#define PTE_WRITABLE 0x002u /* bit 1: 可读写 */
#define PTE_USER     0x004u /* bit 2: 用户态可访问 */

#define PDE_PRESENT  0x001u
#define PDE_WRITABLE 0x002u
#define PDE_USER     0x004u
```

设计决策

PDE flags 遵循"宽松上限"原则：PDE 给足权限（Present + Writable），精细控制放在 PTE 层。例如 PDE 设 Writable 但 PTE 设 Read-Only，最终该页只读；反之 PDE 设 Read-Only，即使 PTE 设 Writable，该页也只读。所以我们在 PDE 层统一设 `PDE_PRESENT | PDE_WRITABLE`，具体的只读/用户态权限在 PTE 中控制。

9.4 数据结构

9.4.1 page_directory_t 与 page_table_t

src/include/kernel/vmm.h

```
typedef struct {
    uint32_t entries[1024]; /* 1024 个 PDE, 每个 4 字节 */
} __attribute__((aligned(4096))) page_directory_t;

typedef struct {
```

```
    uint32_t entries[1024]; /* 1024 个 PTE，每个 4 字节 */
} __attribute__((aligned(4096))) page_table_t;
```

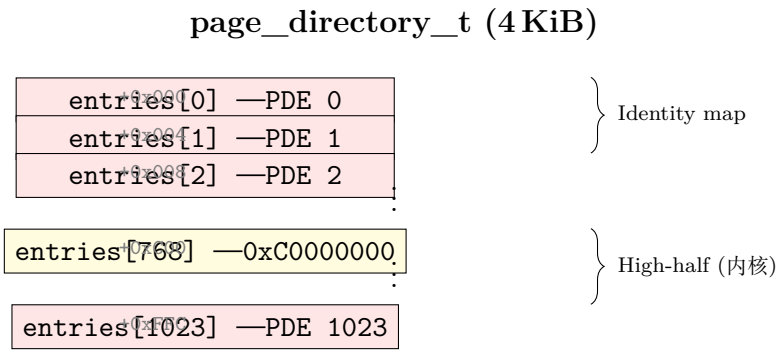

图 9.4: page_directory_t 内存布局——PDE[768] 对应 0xC0000000

为什么？

为什么 page_directory_t 用 __attribute__((aligned(4096)))？
CR3 要求页目录物理地址必须 4 KiB 对齐（低 12 位为 0）。用 aligned 属性声明的静态变量由链接器保证对齐。静态变量放在 BSS 段，启动时自动清零——所有 PDE 初始 Present=0，安全。

思考 9.1

每个 PDE 覆盖 $1024 \times 4\,\text{KiB} = 4\,\text{MiB}$ 的虚拟空间。PDE[768] 对应虚拟地址 $768 \times 4\,\text{MiB} = \texttt{0xC0000000}$ ——正好是 High-Half Kernel 的起始地址。这是巧合吗？（答：不是。0xC0000000 被选为内核基地址，正因为它恰好对齐到 PDE 边界，简化了地址空间划分。）

9.5 地址提取辅助函数

虚拟地址需要拆成 PD index 和 PT index：

src/kernel/mm/vmm.c

```
static inline uint32_t pd_index(uint32_t virt) {
    return (virt >> 22) & 0x3FFu; // 高 10 位
}

static inline uint32_t pt_index(uint32_t virt) {
    return (virt >> 12) & 0x3FFu; // 中 10 位
}
```

例如，虚拟地址 0xC0100000：

- pd_index = 0xC0100000 » 22 = 768 = PDE[768]
- pt_index = (0xC0100000 » 12) & 0x3FF = 256 = PTE[256]
- offset = 0xC0100000 & 0xFFF = 0

9.6 High-Half 地址转换宏

src/include/kernel/vmm.h

```
#define KERNEL_VIRT_OFFSET 0xC0000000u

#define PHYS_TO_VIRT(paddr) ((void*)((uint32_t)(paddr) + KERNEL_VIRT_OFFSET))
#define VIRT_TO_PHYS(vaddr) ((uint32_t)(vaddr) - KERNEL_VIRT_OFFSET)
```

注意

这两个宏**仅适用于内核直接映射区域**——即 vmm_init 中建立的 virt = phys + 0xC0000000 映射。对于动态分配的虚拟地址（如 vmm_alloc_pages 返回的地址），不能使用这两个宏，必须查页表才能得到物理地址。

9.7 核心函数：vmm_ensure_page_table

在写入 PTE 之前，必须确保对应的 Page Table 存在。这是”按需创建”的关键：

src/kernel/mm/vmm.c

```
static page_table_t* vmm_ensure_page_table(uint32_t pd_idx) {
    uint32_t pde = g_kernel_pd.entries[pd_idx];

    if (pde & PDE_PRESENT) {
        // PDE 已有效，取出页表物理地址
        uint32_t pt_phys = pde & ~0xFFFu;
        return (page_table_t*)PHYS_TO_VIRT(pt_phys);
    }

    // PDE 不存在 -> 分配新页表
    uint32_t pt_phys = (uint32_t)(uintptr_t)pmm_alloc_page();
    if (!pt_phys) return NULL;

    // 通过虚拟地址清零（所有 PTE 的 Present=0）
    page_table_t* pt_virt = (page_table_t*)PHYS_TO_VIRT(pt_phys);
    memzero_page(pt_virt);
```

```

    // 填入 PDE: 物理地址 | flags
    g_kernel_pd.entries[pd_idx] = pt_phys | PDE_PRESENT | PDE_WRITABLE;

    return pt_virt;
}
```

步骤详解：

1. 读取 `g_kernel_pd.entries[pd_idx]`，检查 Present 位。
2. **已存在**：用 `& ~0xFFF` 取出高 20 位物理地址，`PHYS_TO_VIRT` 转为虚拟地址后返回。
3. **不存在**：调用 `pmm_alloc_page()` 获取一页物理内存。
4. 用 `memzero_page()` 清零——确保所有 1024 个 PTE 的 Present=0。
5. 将物理地址与 flags 组合后写入 PDE。

注意

清零新页表是**绝对必要**的。未清零的页表中可能残留垃圾数据，CPU 可能把任意非零值当作 Present=1 的 PTE，导致虚拟地址被映射到随机物理页——轻则数据损坏，重则 Triple Fault。

9.8 核心函数：vmm_map_page

src/kernel/mm/vmm.c

```
int vmm_map_page(uint32_t virt, uint32_t phys, uint32_t flags) {
    // 对齐检查
    if ((virt & 0xFFFu) || (phys & 0xFFFu)) {
        printk("[vmm] map: unaligned virt=0x%08x phys=0x%08x\n",
               virt, phys);
        return -1;
    }

    uint32_t pdi = pd_index(virt);
    uint32_t pti = pt_index(virt);

    page_table_t* pt = vmm_ensure_page_table(pdi);
    if (!pt) return -1; // PMM OOM
```

```

    // 写入 PTE: 高 20 位 = 物理帧地址，低 12 位 = flags
    pt->entries[pti] = (phys & ~0xFFFu) | (flags & 0xFFFu);

    // 分页已开启则刷新 TLB
    if (g_vmm_ready) {
        vmm_invlpg(virt);
    }

    return 0;
}
```

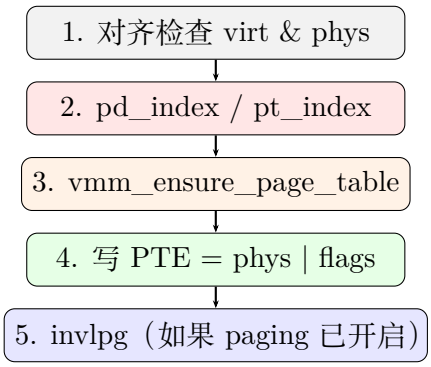

图 9.5: vmm_map_page 执行流程

CPU 状态变化

调用 `vmm_map_page(0xC0200000, 0x200000, PTE_PRESENT | PTE_WRITABLE)` 后：

- PDE[768] 的 Present 位被置 1（如果页表刚创建）
- PDE[768] 指向的 Page Table 的 PTE[512] = `0x200003`（`0x200000` | 0x3）
- 如果 TLB 中缓存了 `0xC0200000` 的旧条目，`invlpg` 使其失效
- 此后访问虚拟地址 `0xC0200000` 将读写物理地址 `0x200000`

9.9 TLB 与 invlpg

TLB（Translation Lookaside Buffer）是 CPU 内部的**页表翻译缓存**。每次虚拟地址翻译都需要两次内存访问（读 PDE + 读 PTE），TLB 将最近的翻译结果缓存起来，命中时可以跳过页表查找。

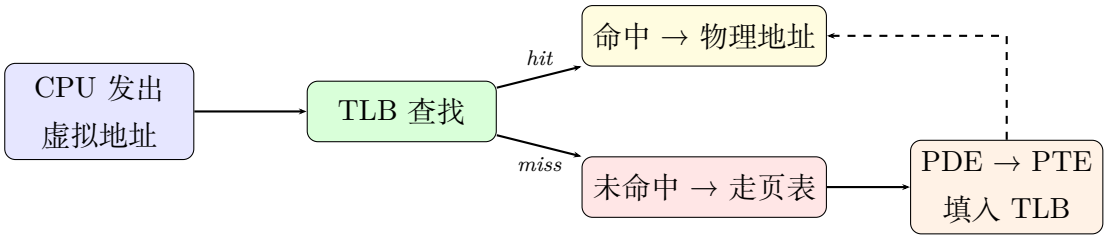

图 9.6: TLB 命中与未命中流程

当我们修改了一个 PTE（改映射或取消映射），TLB 中可能还缓存着**过时**的翻译。必须用 `invlpg` 指令使对应条目失效：

src/kernel/arch/paging_flush.asm

```
; void vmm_invlpg(uint32_t virt_addr);
vmm_invlpg:
    mov eax, [esp + 4]    ; eax = virt_addr
    invlpg [eax]          ; 使该虚拟地址的 TLB 条目失效
    ret
```

为什么？

为什么不每次都重新加载 `CR3`（刷新**全部** TLB）？
重新加载 CR3 会使**所有**非 Global 的 TLB 条目失效，代价远大于 `invlpg` 只失效一条。在高频映射操作中（如缺页处理），`invlpg` 的性能优势很明显。但在大批量拆除映射时（如 `vmm_unmap_identity`），重新加载 CR3 反而更简单高效。

思考 9.2

`vmm_unmap_identity()` 清除了数百个 PDE 后调用 `vmm_load_page_directory()` 重新加载 CR3。如果改成对每个被清除的 PDE 覆盖的虚拟地址逐页 `invlpg`，需要多少次 `invlpg` 调用？(提示：每个 PDE 覆盖 1024 页。假设清除了 16 个 PDE…)

9.10 汇编辅助：paging_flush.asm

src/kernel/arch/paging_flush.asm

```
; void vmm_load_page_directory(uint32_t pd_phys_addr);
;   [CPU STATE] CR3 <- pd_phys_addr
;   副作用：刷新整个 TLB（除 Global 页）
vmm_load_page_directory:
    mov eax, [esp + 4]    ; eax = pd_phys_addr
    mov cr3, eax          ; CR3 <- 页目录物理地址
    ret
```

```

; void vmm_enable_paging(void);
;   [CPU STATE] CR0.PG <- 1, 之后所有内存访问经过 MMU
vmm_enable_paging:
    mov eax, cr0          ; 读出当前 CR0
    or  eax, 0x80000000   ; 设置 bit 31 (PG)
    mov cr0, eax          ; 写回 -> 分页立即生效
    ret
```

CPU 状态变化

`vmm_load_page_directory(pd_phys)` 执行后：

- `CR3` = `pd_phys`（页目录物理地址）
- 整个 TLB 被刷新（非 Global 条目全部失效）
- 下一条指令的取指已经使用新页目录翻译

`vmm_enable_paging()` 执行后：

- `CR0` 的 bit 31 (PG) 从 0 变为 1
- 从 `mov cr0, eax` 的下一条指令 (`ret`) 起，每次内存访问都经过 MMU 翻译
- 如果当前 EIP 所在物理地址没有被 identity map → **Triple Fault**

9.11 `vmm_init`：初始化全流程

`vmm_init()` 负责用正式的 4 KiB 页表替换 `boot.asm` 的临时 4 MiB PSE 映射。

9.11.1 进入时的 CPU 状态

CPU 状态变化

- `CR0`.PG = 1（`boot.asm` 已开启分页，使用 4 MiB PSE 大页）
- `CR3` 指向 `boot_pd`（临时页目录）
- EIP 在虚拟地址 `0xC01xxxxx`（high-half）
- PMM 已初始化完毕，可以调用 `pmm_alloc_page()`

9.11.2 核心步骤

1. **清零页目录**：`memzero_page(&g_kernel_pd)`
   所有 1024 个 PDE 初始化为 0（Present=0）。

2. **计算映射范围**：取内核物理结束地址、PMM 管理范围上限，至少 16 MiB，上限 1 GiB。

3. **建立双重映射**：对 $[0, \text{map_end})$ 的每个 4 KiB 页：

   - Identity mapping: `vmm_map_page(addr, addr, ...)`
   - High-half mapping: `vmm_map_page(addr + 0xC0000000, addr, ...)`

4. **切换 CR3**：`vmm_load_page_directory(VIRT_TO_PHYS(&g_kernel_pd))`
   从 boot 临时页目录切换到 `g_kernel_pd`。

5. **标记就绪**：`g_vmm_ready = 1`

6. **初始化 bump allocator**：设置 `g_next_vaddr` 为直接映射区上方（对齐到 4 MiB）。

src/kernel/mm/vmm.c

```c
void vmm_init(void) {
    printk("[vmm] init: replacing boot PSE with 4KiB page tables...\n");
    memzero_page(&g_kernel_pd);

    // 计算映射范围
    uint32_t kernel_end = (uint32_t)(uintptr_t)__kernel_phys_end;
    uint32_t map_end = kernel_end;
    uint32_t min_map = 16u * 1024u * 1024u;
    if (map_end < min_map) map_end = min_map;
    uint32_t pmm_end = pmm_managed_base()
                    + pmm_total_pages() * VMM_PAGE_SIZE;
    if (pmm_end > map_end) map_end = pmm_end;
    if (map_end > 0x40000000u) map_end = 0x40000000u;

    // 逐页建立双重映射
    for (uint32_t addr = 0; addr < map_end; addr += VMM_PAGE_SIZE) {
        vmm_map_page(addr, addr, PTE_PRESENT | PTE_WRITABLE);
        vmm_map_page(addr + KERNEL_VIRT_OFFSET, addr,
                    PTE_PRESENT | PTE_WRITABLE);
    }

```

```
    // 切换到新页目录
    uint32_t pd_phys = VIRT_TO_PHYS(
        (uint32_t)(uintptr_t)&g_kernel_pd);
    vmm_load_page_directory(pd_phys);
    g_vmm_ready = 1;

    // 初始化 bump allocator 水位线
    uint32_t direct_map_top = KERNEL_VIRT_OFFSET + map_end;
    uint32_t align_4m = 0x400000u;
    g_next_vaddr = (direct_map_top + align_4m - 1u)
                & ~(align_4m - 1u);
}
```

设计决策

为什么保留 identity mapping？

`vmm_init` 运行时，内核已经在 high-half（`0xC0000000+`），按说不需要低地址映射。但多处仍依赖 identity mapping：

- VGA text buffer 在物理 `0xB8000`，identity map 下可直接写 `(char*)0xB8000`
- Multiboot2 info 指针是物理地址
- PMM 内部 bitmap 的物理地址直接当指针用

将来 `vmm_unmap_identity()` 会在所有指针转换完成后拆除低地址映射，把 `[0, 0xBFFFFFFF]` 留给用户态进程。

9.12 vmm_unmap_page 与 vmm_unmap_identity

9.12.1 解除单页映射

src/kernel/mm/vmm.c

```
void vmm_unmap_page(uint32_t virt) {
    if ((virt & 0xFFFu)) return;      // 对齐检查

    uint32_t pdi = pd_index(virt);
    uint32_t pde = g_kernel_pd.entries[pdi];
    if (!(pde & PDE_PRESENT)) return; // 页表不存在

    uint32_t pt_phys = pde & ~0xFFFu;
```

```
    page_table_t* pt = (page_table_t*)PHYS_TO_VIRT(pt_phys);
    pt->entries[pt_index(virt)] = 0;  // PTE 置 0

    if (g_vmm_ready) vmm_invlpg(virt); // 刷新 TLB
}
```

注意

vmm_unmap_page 只断开虚拟 → 物理的映射，**不释放物理页**。物理页可能被多处引用（如共享内存），释放是调用者的责任。典型模式：先 vmm_get_physical() 拿到物理地址，再 vmm_unmap_page()，最后 pmm_free_page() 归还物理页。

9.12.2 拆除 Identity Mapping

src/kernel/mm/vmm.c

```
void vmm_unmap_identity(void) {
    if (!g_vmm_ready) return;

    uint32_t first_kernel_pde = pd_index(KERNEL_VIRT_OFFSET); // 768
    uint32_t cleared = 0;

    for (uint32_t i = 0; i < first_kernel_pde; i++) {
        if (g_kernel_pd.entries[i] & PDE_PRESENT) {
            g_kernel_pd.entries[i] = 0;
            cleared++;
        }
    }

    // 重新加载 CR3 做全局 TLB 刷新
    uint32_t pd_phys = VIRT_TO_PHYS(
        (uint32_t)(uintptr_t)&g_kernel_pd);
    vmm_load_page_directory(pd_phys);
}
```

CPU 状态变化

vmm_unmap_identity() 执行后：

- PDE[0]–PDE[767] 全部清零
- 虚拟地址 0x00000000–0xBFFFFFFF 访问将触发 #PF

- CR3 被重新加载，TLB 全局刷新

9.13 查询辅助函数

VMM 提供几个查询函数供 Shell 命令和上层代码使用：

src/include/kernel/vmm.h

```
// 查询虚拟地址是否已映射（返回 1=已映射，0=未映射，-1=错误）
int vmm_is_mapped(uint32_t virt);

// 查询虚拟地址对应的物理地址
int vmm_get_physical(uint32_t virt, uint32_t* phys);

// 直接读取 PDE / PTE 原始值（供调试命令使用）
uint32_t vmm_get_pde(uint32_t pd_idx);
uint32_t vmm_get_pte(uint32_t virt);
```

9.14 Shell 验证

编译并启动 QEMU 后，可以用 vmm 命令验证页表状态：

```
$ Terminal

$ make iso && make run
...
[vmm] init: replacing boot PSE with 4KiB page tables...
[vmm] mapping phys 0x00000000 - 0x10000000
[vmm] page directory: virt=0xc01xx000 phys=0x001xx000
[vmm] loading new CR3...
[vmm] 4KiB paging active! mapped 262144 KiB (131072 pages, 128 page tables)
[vmm] identity: 0x00000000 - 0x10000000
[vmm] high-half: 0xc0000000 - 0xd0000000
[vmm] alloc area: 0xd0000000 - 0xFFFFFFFF

> vmm
  PD index Phys PT addr Flags
  0        0x001xx000  P W
  1        0x001xx000  P W
  ...
```

```
  768      0x002xx000  P W
  ...

> vmm 0xC0000000
  virt=0xC0000000 -> phys=0x00000000 flags=P W
```

启动日志确认：

- 物理 `0x00000000`–`0x10000000`（256 MiB）被双重映射
- 分配了 128 个 Page Table（identity 64 + high-half 64）
- bump allocator 从 `0xD0000000` 开始

9.15 思考与练习

练习 9.1

手动页表查找：给定虚拟地址 `0xC0B8000`，手工计算 PD index、PT index 和 offset。如果该地址通过 `vmm_init` 被映射到 `phys = virt − 0xC0000000`，写出该 PDE 和 PTE 的完整 32 位值（假设 flags = `PTE_PRESENT | PTE_WRITABLE`）。

练习 9.2

页表内存开销分析：假设 `vmm_init` 需要映射 256 MiB 物理内存（identity + high-half 双重映射），需要多少个 Page Table？这些页表本身占多少物理内存？与 4 MiB 的单级平坦页表相比，节省了多少？（提示：256 MiB / 4 MiB-per-PDE = 64 个 Page Table × 2 = 128 × 4 KiB = 512 KiB）

练习 9.3

拆除 identity mapping 后的陷阱：在 `vmm_unmap_identity()` 执行后，如果内核代码中仍有一处 `*(char*)0xB8000 = 'X';` 尝试直接写 VGA buffer，会发生什么？如何修改这行代码让它在 high-half 环境下正确工作？

练习 9.4

添加只读映射支持：修改 `vmm_map_page`，当 flags 中不包含 `PTE_WRITABLE` 时，映射的页面应该是只读的。编写一个测试：映射一个只读页，尝试写入，观察是否触发 Page Fault。（提示：当前 `CR0.WP=0` 时 Ring 0 不受 Read-Only 限制，需要在 `vmm_enable_paging` 中同时设置 WP 位。）

Chapter 10

High-Half Kernel：高半区内核

10.1 本章目标

- 理解 High-Half Kernel 的地址空间布局：用户态 0–3 GiB / 内核态 3–4 GiB
- 掌握直接映射（Direct Mapping）的原理与公式 virt = phys + `0xC0000000`
- 理解 `boot.asm` 中 PSE 临时映射为何需要同时建立 identity 与 high-half
- 掌握 `PHYS_TO_VIRT` / `VIRT_TO_PHYS` 宏的使用场景与限制
- 实现 `vmm_unmap_identity()`：拆除 identity mapping，释放低地址空间
- 理解指针转换的必要性：`g_mb2_info`、PMM bitmap 等指针的迁移
- 掌握拆除后的 CPU 状态变化与 TLB 刷新

10.2 背景知识：地址空间布局

在 32 位 x86 系统中，虚拟地址空间共 4 GiB（`0x00000000`–`0xFFFFFFFF`）。High-Half Kernel 的经典划分方式是：

- **低 3 GiB**（`0x00000000`–`0xBFFFFFFF`）：用户态进程
- **高 1 GiB**（`0xC0000000`–`0xFFFFFFFF`）：内核

图 10.1: High-Half Kernel 地址空间布局（32 位 x86）

为什么？

为什么内核占高 1 GiB 而不是低 1 GiB?
将内核放在高地址有几个好处：

1. 用户进程总是从 `0x00000000` 附近加载（ELF 默认基址 `0x08048000`），不用跳过内核区域
2. 内核切换进程时只需替换低 3 GiB 的页表（PD[0..767]），高 1 GiB（PD[768..1023]）在所有进程中共享，切换代价小
3. Linux 2.x/3.x、Windows NT 均采用此方案，是业界惯例

10.3 直接映射区（Direct Mapping）

内核启动后，需要频繁访问物理内存（页表、PMM bitmap、设备寄存器等）。**直接映射**将一段连续的物理内存”平移”到内核虚拟地址空间中：

$$\text{virt} = \text{phys} + \texttt{0xC0000000} \tag{10.1}$$

例如：

- 物理 `0x00000000` → 虚拟 `0xC0000000`
- 物理 `0x000B8000`（VGA text buffer）→ 虚拟 `0xC00B8000`
- 物理 `0x00100000`（内核加载地址）→ 虚拟 `0xC0100000`

直接映射区的大小取决于物理内存的总量（但不超过 1 GiB，否则会占满整个内核地址空间）。我们的 vmm_init() 在建立映射时会计算这个范围：

src/kernel/mm/vmm.c

Listing 10.1: 直接映射范围计算（vmm.c 节选）

```
uint32_t map_end = kernel_end;

/* 至少映射 16 MiB（覆盖 VGA、BIOS 区域等） */
if (map_end < 16u * 1024u * 1024u)
    map_end = 16u * 1024u * 1024u;

/* 覆盖 PMM 管理的全部物理页 */
uint32_t pmm_end = pmm_managed_base()
                + pmm_total_pages() * VMM_PAGE_SIZE;
if (pmm_end > map_end)
    map_end = pmm_end;

/* 不超过 1 GiB */
if (map_end > 0x40000000u)
    map_end = 0x40000000u;
```

10.4 PHYS_TO_VIRT 与 VIRT_TO_PHYS 宏

在 vmm.h 中定义了两个核心转换宏：

src/include/kernel/vmm.h

Listing 10.2: 地址转换宏（vmm.h）

```
#define KERNEL_VIRT_OFFSET 0xC0000000u

#define PHYS_TO_VIRT(paddr) \
    ((void*)((uint32_t)(paddr) + KERNEL_VIRT_OFFSET))

#define VIRT_TO_PHYS(vaddr) \
    ((uint32_t)(vaddr) - KERNEL_VIRT_OFFSET)
```

作用域限制

这两个宏**仅适用于内核直接映射区域**。

对于通过 vmm_alloc_pages() 动态映射的虚拟地址（如内核堆），物理页可能是不连续的，virt − 0xC0000000 ≠ phys。这些地址需要通过查询页表

（vmm_get_physical()）来获取物理地址。
简单规则：

- PMM 返回的物理地址 → 用 PHYS_TO_VIRT 转换后解引用
- PDE/PTE 中存储的始终是物理地址（给 CPU/MMU 用）
- 内核堆指针（kmalloc 返回值）→ 不能用 VIRT_TO_PHYS

10.5 boot.asm 中的 PSE 临时映射

在第 9 章中我们已经知道，boot.asm 使用 4 MiB PSE 大页建立临时映射。这里我们详细分析为什么需要**同时**建立 identity mapping 和 high-half mapping。

src/boot/boot.asm

Listing 10.3: boot.asm：构建双重 PSE 映射

```
; PSE PDE: [31:22]=phys_base | PS(bit7) | RW(bit1) | P(bit0)
;  flags = 0x83
xor ecx, ecx            ; ecx = 0..255
.fill_pse:
   mov eax, ecx
   shl eax, 22          ; eax = ecx * 4 MiB
   or  eax, 0x83        ; PS | RW | Present
   mov [boot_pd + ecx*4],     eax ; identity: PD[i]
   mov [boot_pd + 768*4 + ecx*4], eax ; high-half: PD[768+i]
   inc ecx
   cmp ecx, 256
   jb  .fill_pse
```

这段代码会产生如下映射：

PDE 范围	虚拟地址	映射到物理地址
PD[0..255]	0x00000000–0x3FFFFFFF	0x00000000–0x3FFFFFFF
PD[768..1023]	0xC0000000–0xFFFFFFFF	0x00000000–0x3FFFFFFF

为什么？

为什么不能只建 high-half mapping，跳过 identity mapping?
因为在开启分页的那一瞬间，EIP 仍然指向物理地址 ~0x001xxxxx（boot.asm 的 .boot 段链接在低地址）。如果没有 identity mapping，CR0.PG 置 1 后 CPU 取下一条指令时会 Page Fault → Double Fault → Triple Fault → 重启。

时序回顾：

1. `mov cr0, eax` —开启分页，此时 EIP ≈ `0x001xxxxx`
2. CPU 取下一条指令 → 虚拟地址 `0x001xxxxx` → identity mapping 翻译 → 物理 `0x001xxxxx`
3. `jmp _start_high` —跳转到虚拟地址 `0xC01xxxxx`
4. CPU 取指 → `0xC01xxxxx` → high-half mapping 翻译 → 物理 `0x001xxxxx`
5. 从此以后，代码运行在 high-half，identity mapping 变成了”遗产”

开启分页的关键指令序列：

src/boot/boot.asm

Listing 10.4: boot.asm：开启分页并跳转到 high-half

```
; 加载页目录物理地址到 CR3
mov eax, boot_pd
mov cr3, eax

; 开启分页 (CR0.PG = 1)
; [CPU STATE] 从下一条指令开始，所有内存访问经过 MMU
mov eax, cr0
or  eax, 0x80000000   ; bit 31 = PG
mov cr0, eax

; --- 分页已开启，identity mapping 保证 EIP 仍然有效 ---

; 跳转到 high-half 虚拟地址
mov eax, _start_high ; _start_high 链接在 0xC01xxxxx
jmp eax
```

CPU 状态变化

执行 `mov cr0, eax`（PG=1）后：

- CR3 → `boot_pd`（物理地址）
- EIP 仍在低地址（~`0x001xxxxx`），通过 PD[0] 的 identity mapping 继续运行
- `jmp _start_high` 后，EIP 切换到 `0xC01xxxxx`，通过 PD[768] 的 high-half

mapping 运行

- 此后内核栈、全局变量等均位于 `0xC0xxxxxx`+ 虚拟地址

10.6 vmm_init 后的双重映射

经过第 9 章的 `vmm_init()`，临时 PSE 映射被 4 KiB 细粒度页表替换，但 identity mapping 仍然保留。此时每个物理页 P 有两个虚拟地址：

映射类型	虚拟地址
Identity	P（虚拟 = 物理）
High-half	$P + \texttt{0xC0000000}$

这意味着同一块物理内存可以通过两个不同的虚拟地址访问——这是一种浪费，也为将来的用户态进程留下了安全隐患。下一步就是拆除 identity mapping。

10.7 指针转换：拆除前的准备

注意

在调用 `vmm_unmap_identity()` 之前，必须将所有仍指向低地址的指针转换为 high-half 地址。否则拆除 identity mapping 后，解引用这些指针会触发 Page Fault。

在我们的内核中，需要转换的关键指针包括：

10.7.1 g_mb2_info：Multiboot2 信息结构

GRUB 传入的 Multiboot2 info 指针是物理地址（由 `boot.asm` 从 `EBX` 保存）。在 `vmm_init()` 建立 high-half mapping 之后，需要将其转换：

src/kernel/core/kmain.c

Listing 10.5: kmain.c：转换 Multiboot2 指针

```
/* vmm_init 之后、vmm_unmap_identity 之前 */
g_mb2_info = (const void*)PHYS_TO_VIRT(
    (uint32_t)(uintptr_t)g_mb2_info);
```

如果忘记转换会怎样？

- `g_mb2_info` 仍指向 ~`0x00010000`（物理地址）
- 此时 identity mapping 还在，暂时不会出错

- 但 `vmm_unmap_identity()` 之后，PD[0] 被清除
- 下次 shell 命令访问 `g_mb2_info` → `0x00010000` → Page Fault!

10.7.2 PMM bitmap 指针

PMM bitmap 后端在 `pmm_init()` 时将 bitmap 放置在物理内存中。由于 bitmap 后端内部存储的是虚拟地址指针（通过 identity mapping 期间可以等价于物理地址），在 `vmm_init()` 建立 high-half mapping 后，PMM 内部的 bitmap 指针需要通过直接映射区的 high-half 地址来访问。

思考 10.1

如果 PMM bitmap 存储在物理地址 `0x00200000`，在 identity mapping 拆除后，内核应该通过哪个虚拟地址访问它？
答：`0xC0200000`（= `0x00200000` + `0xC0000000`）

10.8 vmm_unmap_identity 实现

一切指针转换完毕后，调用 `vmm_unmap_identity()` 拆除低地址映射：

src/kernel/mm/vmm.c

Listing 10.6: vmm_unmap_identity() 完整实现

```
void vmm_unmap_identity(void) {
    /*
     * 拆除 identity mapping (虚拟地址 0x00000000-0xBFFFFFFF)
     *
     * [WHY] identity mapping 只是 boot→high-half 过渡期的临时需要。
     *   现在内核完全运行在 high-half (0xC0000000+),
     *   所有指针已通过 PHYS_TO_VIRT 转换，可以安全拆除。
     *   拆除后，低地址空间留给将来的用户态进程。
     */

    if (!g_vmm_ready)
        return;

    uint32_t first_kernel_pde = pd_index(KERNEL_VIRT_OFFSET);
    /* first_kernel_pde = 768 (0xC0000000 >> 22) */
    uint32_t cleared = 0;

    /* 步骤 1: 清零 PD[0..767] 中所有有效条目 */
```

```c
    for (uint32_t i = 0; i < first_kernel_pde; i++) {
        if (g_kernel_pd.entries[i] & PDE_PRESENT) {
            g_kernel_pd.entries[i] = 0;
            cleared++;
        }
    }

    /* 步骤 2: 重新加载 CR3 做全局 TLB 刷新 */
    uint32_t pd_phys = VIRT_TO_PHYS(
        (uint32_t)(uintptr_t)&g_kernel_pd);
    vmm_load_page_directory(pd_phys);

    printk("[vmm] identity mapping removed "
           "(%u PDEs cleared)\n", (unsigned)cleared);
}
```

逐步分析：

1. **计算边界**：`KERNEL_VIRT_OFFSET` = `0xC0000000`，右移 22 位得到 PD index = 768。所有低于 768 的 PDE 属于用户态地址空间。
2. **清零 PDE**：遍历 PD[0..767]，将所有 Present 的条目置 0。置 0 后 CPU 查页表会发现 Present=0，触发 #PF。
3. **TLB 刷新**：向 `CR3` 重新写入页目录物理地址。x86 规范：写 CR3 会使整个 TLB 无效化（除 Global 页外）。这比逐页调用 `invlpg` 更高效，因为我们一次性清除了几百个 PDE。

CPU 状态变化

执行 `vmm_unmap_identity()` 后：

- PD[0..767] 全部为 0（Present=0）
- PD[768..1023] 不变（high-half 映射完好）
- TLB 已刷新，旧的 identity mapping 缓存被清除
- 访问 `0x00000000`–`0xBFFFFFFF` 中任何地址 → #PF
- 内核代码继续通过 `0xC0000000`+ 正常运行

注意

必须在调用此函数**之前**完成所有指针转换！
内核的初始化顺序严格为：

1. `vmm_init()` —建立 identity + high-half 双重映射
2. 转换所有低地址指针 → high-half 地址（如 `g_mb2_info`）
3. `vmm_unmap_identity()` —拆除 identity mapping

如果顺序颠倒（先拆除再转换），转换代码本身不会崩溃（因为 `PHYS_TO_VIRT` 只是做加法运算），但在拆除之后访问未转换的旧指针就会 Page Fault。调试这类问题非常困难，因为症状可能延迟很久才出现。

10.9 VGA text buffer 的特殊处理

思考 10.2

VGA text buffer 位于物理地址 `0xB8000`。拆除 identity mapping 后，通过 `0xB8000` 访问 VGA 会触发 Page Fault。内核应该如何继续输出到屏幕？
方案分析：

- 方案 A：通过 high-half 直接映射访问 `0xC00B8000`（= `0xB8000`+`0xC0000000`）
- 方案 B：放弃 VGA，只使用串口（serial port）输出

我们的内核选择了方案 B：`printk` 完全通过串口（I/O 端口 `0x3F8`）输出。串口使用 `in/out` 指令访问 I/O 端口空间，不经过内存映射，因此不受 identity mapping 拆除的影响。
如果将来需要 VGA 输出，只需将 VGA 基地址改为 `0xC00B8000` 即可。这正是直接映射区的方便之处——任何物理设备地址加上 `0xC0000000` 就能访问。

10.10 kmain 中的初始化顺序

我们来看 `kmain.c` 中与本章相关的关键代码片段：

src/kernel/core/kmain.c

Listing 10.7: kmain.c：high-half 切换的完整流程

```
/* Stage 2: 物理内存管理器 */
pmm_init();

```

```c
/* Stage 3: 虚拟内存管理器 (identity + high-half 双重映射) */
vmm_init();

/*
 * [CRITICAL] 转换阶段
 * PMM init 已结束，将 g_mb2_info 从物理地址转换为虚拟地址。
 * 之后 shell 命令通过 high-half 地址访问 Multiboot2 info。
 */
g_mb2_info = (const void*)PHYS_TO_VIRT(
    (uint32_t)(uintptr_t)g_mb2_info);

/* 拆除 identity mapping，低地址空间留给将来的用户态 */
vmm_unmap_identity();

/* Stage 4: 内核堆初始化 (kmalloc) */
kmalloc_init();
```

注意这段代码的三个关键步骤形成了一个”安全窗口”：

1. `vmm_init()` 建立双重映射—此后 high-half 和 identity 都可用
2. 指针转换—所有低地址指针切换到 high-half 地址
3. `vmm_unmap_identity()` —关闭窗口，低地址不再可用

10.11 验证：查看映射状态

拆除 identity mapping 后，可以用 shell 命令验证效果。通过 `vmm_is_mapped()` 查询特定虚拟地址的映射状态：

```
验证 identity mapping 已拆除

> vmm lookup 0x00000000
  virt=0x00000000 -> NOT MAPPED

> vmm lookup 0x000B8000
  virt=0x000B8000 -> NOT MAPPED

> vmm lookup 0xC0000000
  virt=0xC0000000 -> phys=0x00000000 [P RW]

> vmm lookup 0xC00B8000
```

```
  virt=0xC00B8000 -> phys=0x000B8000 [P RW]

> vmm lookup 0xC0100000
  virt=0xC0100000 -> phys=0x00100000 [P RW]
```

可以看到：

- 低地址（0x00000000、0x000B8000）全部显示 NOT MAPPED
- 对应的 high-half 地址（加 0xC0000000）映射正常
- 物理地址 = 虚拟地址 − 0xC0000000，符合直接映射公式

10.12 完整地址空间示意图

拆除 identity mapping 后，内核的地址空间最终布局如下：

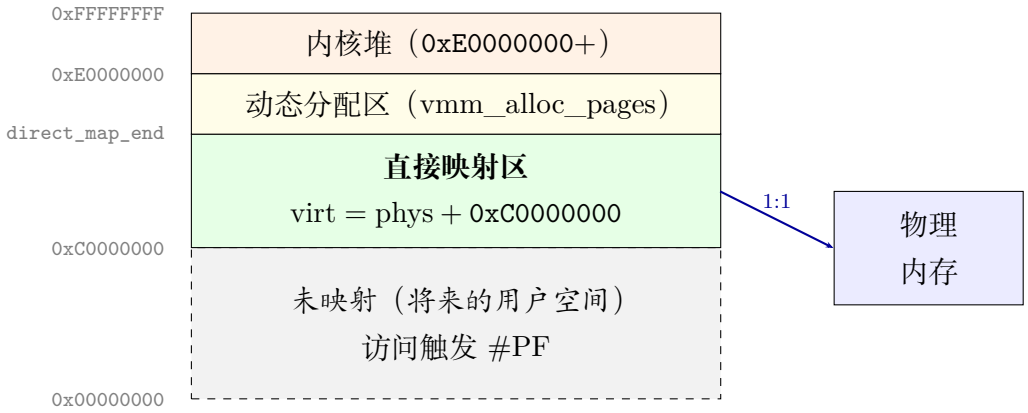

图 10.2: 拆除 identity mapping 后的最终地址空间布局

10.13 思考与练习

练习 10.1

手动计算 PDE index

给定虚拟地址 0xC0100000（内核入口点），请手工计算：

1. PD index（高 10 位）的值是多少？
2. 它落在 PD[768..1023] 中的哪个位置？
3. 如果物理地址是 0x00100000，该 PTE 的内容（含 flags Present+RW）应该是什么？

提示：0xC0100000 ≫ 22 = 0x300 = 768。PT index = (0xC0100000 ≫ 12) & 0x3FF = 0x100 = 256。PTE = 0x00100000 | 0x03 = 0x00100003。

练习 10.2

模拟遗忘转换的后果

假设开发者在 kmain.c 中忘记了这一行：

```
g_mb2_info = (const void*)PHYS_TO_VIRT(
    (uint32_t)(uintptr_t)g_mb2_info);
```

请分析：

1. 在 vmm_unmap_identity() 调用之前，访问 g_mb2_info 会崩溃吗？为什么？
2. 调用之后呢？具体会触发什么异常？CPU 的错误码（error code）会包含哪些信息？
3. 如果使用 GDB 调试，应该在哪里设置断点来定位此问题？

练习 10.3

VGA text mode 输出的 high-half 适配

当前内核的 printk 通过串口输出，不受 identity mapping 拆除影响。请设计并实现一个简单的 VGA text mode 驱动，要求：

1. 定义 VGA buffer 的 high-half 虚拟地址常量
2. 实现 vga_putchar(char c) 和 vga_clear()
3. 考虑：如果 VGA 所在的物理页 0xB8000 没有被直接映射覆盖（map_end < 0xB9000），你的驱动还能工作吗？如何修复？

提示：我们 vmm_init() 至少映射 16 MiB，0xB8000 < 16 MiB，所以直接映射一定覆盖了 VGA 区域。

Chapter 11

Kernel Heap：kmalloc 与 kfree

11.1 本章目标

- 理解内核为什么需要字节级堆分配器——PMM 只能以 4 KiB 页为粒度
- 掌握堆虚拟地址区域规划：`0xE0000000`–`0xF0000000`，256 MiB
- 理解 `heap_ops_t` 可插拔后端接口（与 `pmm_ops_t` 同一模式）
- 实现 First-Fit 空闲链表：`block_header_t`、分配拆分、释放合并
- 了解 Slab 分配器后端：固定大小 cache + bitmap
- 实现 `kmalloc_init`：映射物理页并初始化后端
- 掌握 `kheap_stats_t` 统计信息的含义

11.2 背景知识：为什么需要内核堆？

PMM 以 4 KiB 页为单位分配，VMM 的 `vmm_alloc_pages` 同样以页为粒度。但内核中大量数据结构远小于一页——进程控制块 128 B、VMA 节点 32 B、命令表项十几字节。若每个小对象都分配整页，内部碎片率高达 $1 - 128/4096 \approx 96.9\%$。

为什么？

为什么不直接用全局数组（静态分配）?
静态数组在编译时就固定了容量，无法按运行时需求伸缩；为”以防万一”必须预留最大容量，浪费严重；每新增一种数据结构就要新增一个数组，代码耦合也越来越重。内核堆（`kmalloc`/`kfree`）就是给内核提供任意大小、动态生命周期的分配能力——类比用户态的 `malloc`/`free`。

11.3 堆的虚拟地址区域规划

内核堆需要一段专属连续虚拟地址。在第 10 章高半区布局基础上细分：

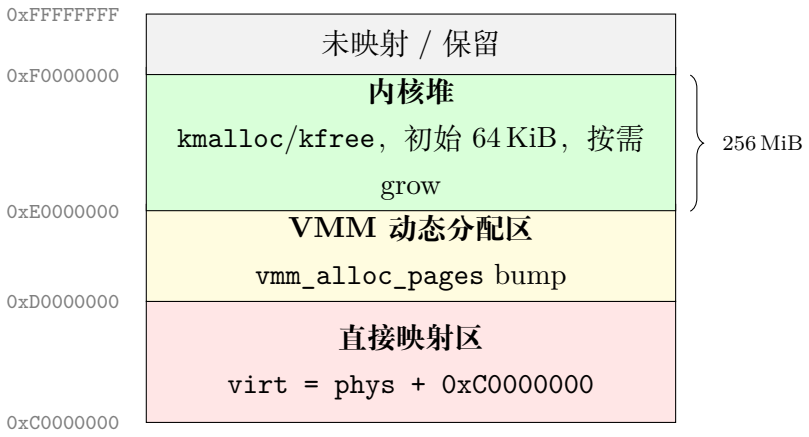

图 11.1: 内核虚拟地址空间细分布局

vmm.h 中定义的三个宏：

src/include/kernel/vmm.h

```
#define KHEAP_START  0xE0000000u
#define KHEAP_MAX_SIZE (256u * 1024u * 1024u) /* 256 MiB */
#define KHEAP_END    (KHEAP_START + KHEAP_MAX_SIZE) /* 0xF0000000 */
```

设计决策

堆区域必须和 vmm_alloc_pages 的地址空间分开。后者内部用 bump allocator（g_next_vaddr 单调递增），如果堆也用同一空间，两个分配器会互相踩踏。隔离到不同区间后各管各的，互不干扰。

11.4 可插拔后端：heap_ops_t 接口

与第 8 章的 pmm_ops_t 相同模式——接口与实现解耦：

src/include/kernel/kmalloc.h

```
typedef struct heap_ops {
    const char* name;
    void (*init)(void* start, size_t size);
    void* (*alloc)(size_t size);
    void (*free)(void* ptr);
    void (*stats)(kheap_stats_t* out);
} heap_ops_t;
```

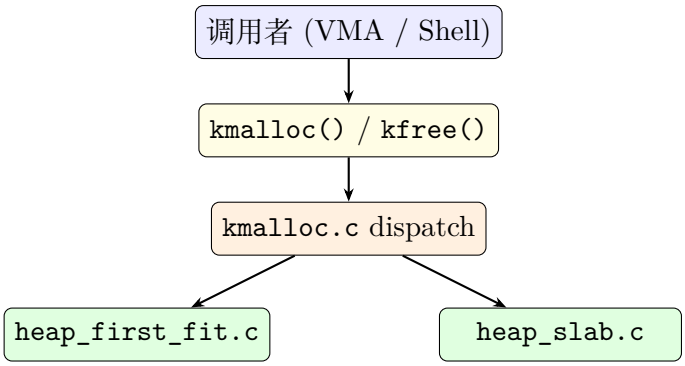

图 11.2: kmalloc 可插拔后端调用链

kconfig.h 编译期选择后端（0=first_fit，1=slab），kmain.c 启动时注册并调用 kmalloc_init()。

思考 11.1

"dispatch + 后端" 模式在 Linux 内核中随处可见（VFS、I/O 调度器、协议栈）。如果不用函数指针表，而在每个调用点用 #if 选择实现，会有什么问题？（提示：代码膨胀与维护成本）

11.5 First-Fit 空闲链表

11.5.1 block_header_t 结构

First-Fit 后端把堆区域切成若干块，每块前面有小 header，所有块串成双向链表：

src/kernel/mm/heap_first_fit.c

```
typedef struct block_header {
    size_t size;              /* 用户数据区大小（不含 header） */
    int is_free;              /* 0=已分配，1=空闲 */
    struct block_header* next;
    struct block_header* prev;
} block_header_t;
#define HEADER_SIZE ((sizeof(block_header_t) + 7u) & ~7u) /* 16B */
#define ALIGN8(x) (((x) + 7u) & ~7u)
```

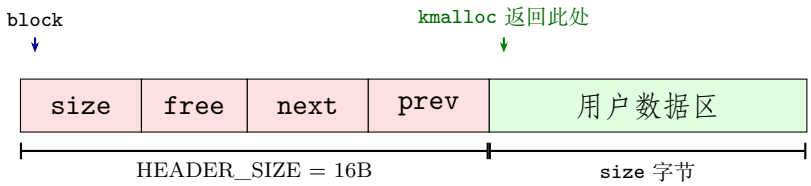

图 11.3: block_header_t 与用户数据区的内存布局

kmalloc 返回 block + HEADER_SIZE；kfree 时往回退 16 字节即找到 header。32 位下 sizeof = 4+4+4+4 = 16，天然 8 字节对齐。

11.5.2 分配：遍历 + 拆分

heap_first_fit_alloc(size) 步骤：对齐 ALIGN8(size)；从头遍历找第一个 is_free && size >= need；若块比请求大得多（余 > HEADER_SIZE + 8）则拆分；is_free = 0，返回数据区指针。

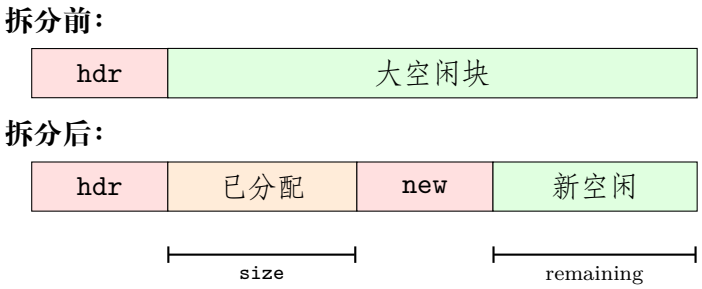

图 11.4: First-Fit 分配时的块拆分

核心拆分代码：

src/kernel/mm/heap_first_fit.c

```
if (curr->size - size > HEADER_SIZE + 8) {
    block_header_t* new_block =
        (block_header_t*)((uint8_t*)curr + HEADER_SIZE + size);
    new_block->size = curr->size - size - HEADER_SIZE;
    new_block->is_free = 1;
    new_block->next = curr->next; new_block->prev = curr;
    if (curr->next) curr->next->prev = new_block;
    curr->size = size;
    curr->next = new_block;
}
curr->is_free = 0;
return (void*)((uint8_t*)curr + HEADER_SIZE);
```

思考 11.2

拆分阈值 HEADER_SIZE + 8 的含义：剩余空间必须够放 header（16 B）加最小数据（8 B），否则拆出的碎片永远不可用。若改成 HEADER_SIZE + 1，返回的指针将不满足 8 字节对齐——许多 CPU 指令（如 SSE）会因此触发异常。

11.5.3 释放与合并

heap_first_fit_free(ptr) 步骤： block = ptr - HEADER_SIZE； 范围检查；is_free = 1； 向后合并（while next 也 free 就 merge_with_next）； 向前合并（若 prev 也 free 让其吞并自己）。

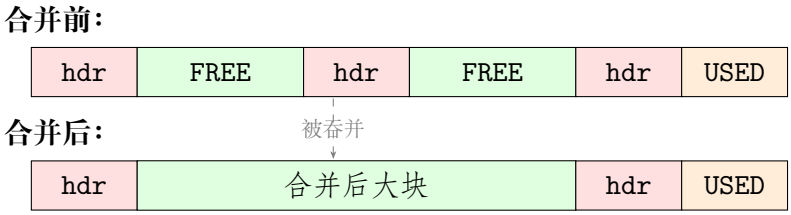

图 11.5: 相邻空闲块的合并

src/kernel/mm/heap_first_fit.c

```
static void merge_with_next(block_header_t* block) {
    block_header_t* victim = block->next;
    block->size += HEADER_SIZE + victim->size;
    block->next = victim->next;
    if (victim->next) victim->next->prev = block;
}
```

为什么？

为什么需要双向链表?
单向链表向后合并（吃 next）没问题，但向前合并需要从 block 找前驱——单向链表要 $O(n)$ 遍历。双向链表多花 4 B 存 prev，换来 $O(1)$ 向前合并，是经典的空间换时间。

11.6 堆的初始化与增长

11.6.1 kmalloc_init：映射初始物理页

kmalloc_init() 在内核启动时调用：逐页从 PMM 分配物理页 → VMM 映射到 0xE0000000 → 调后端 init。

src/include/kernel/kmalloc.h

```
void kmalloc_init(void) {
    size_t initial_size = KHEAP_INITIAL_PAGES * VMM_PAGE_SIZE;
    for (unsigned i = 0; i < KHEAP_INITIAL_PAGES; i++) {
        uint32_t virt = KHEAP_START + i * VMM_PAGE_SIZE;
        uint32_t phys = (uint32_t)(uintptr_t)pmm_alloc_page();
```

```
        vmm_map_page(virt, phys, PTE_PRESENT | PTE_WRITABLE);
    }
    g_heap_ops->init((void*)(uintptr_t)KHEAP_START, initial_size);
}
```

初始页数由 `kconfig.h` 配置：`KCONFIG_HEAP_INITIAL_PAGES = 16`（64 KiB）。

11.6.2 heap_brk：按需增长

First-Fit 后端用 `heap_brk` 跟踪已提交上界：

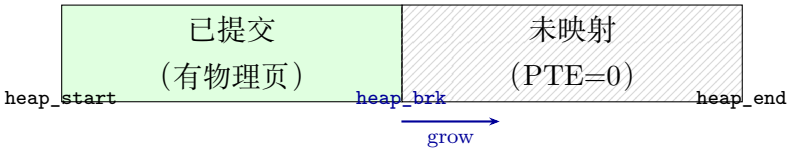

图 11.6: `heap_brk`：已提交区域上界

分配找不到合适块时调 `heap_grow(min_bytes)`——从 PMM 拿页、VMM 映射、推进 `heap_brk`，语义类似用户态 `sbrk()`。

11.7 Slab 分配器概述

First-Fit 每次分配 $O(n)$ 遍历且易碎片化。**Slab 分配器**（源自 Solaris / Linux）针对这两个弱点：按固定大小预切 slot，相同大小 $O(1)$ 取。

11.7.1 7 级 Cache

编号	大小	每页 Slot 数	适用场景
0	32 B	≈ 126	小结构体、链表节点
1	64 B	≈ 63	字符串缓冲区
2	128 B	≈ 31	进程控制块
3	256 B	≈ 15	中型数据
4	512 B	≈ 7	大结构体
5	1024 B	3	页级缓冲
6	2048 B	1	最大 cache

`kmalloc(50)` → cache-64，内部碎片 = 14 B。

11.7.2 Slab 内存布局

每个 slab 占一页（4 KiB），页头放 `slab_header_t`（含 128 位 bitmap）：

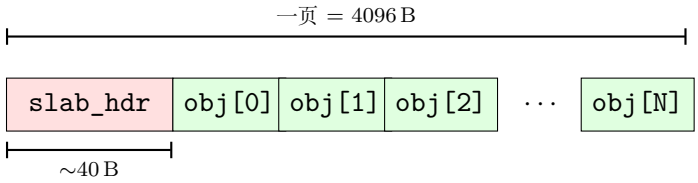

图 11.7: Slab 内存布局

分配：`bitmap_find_first_set` → 清位 → 计算地址，$O(1)$。释放：`ptr & ~0xFFF` 找到页头 header，算 slot index → 置位，$O(1)$。

设计决策

`slab_header_t` 放在页头而非单独分配的三个原因： 避免鸡生蛋——slab 自己就是分配器，metadata 不能再 `kmalloc`； `kfree` 时页对齐即得 header，$O(1)$； 每页只损失 ~40 B（$< 1\%$）。

11.8 统计信息：kheap_stats_t

src/kernel/mm/kmalloc.c

```
typedef struct kheap_stats {
    size_t  heap_size;   /* 已提交区域总大小 */
    size_t  used_bytes;  /* 已分配字节（含 header 开销） */
    size_t  free_bytes;  /* 空闲字节 */
    unsigned alloc_count; /* 活跃分配数 */
    unsigned free_count; /* 空闲块数 */
} kheap_stats_t;
```

注意 `used_bytes + free_bytes ≠ heap_size`——差值是空闲块 header 的开销。`free_count` 很大但 `free_bytes` 很小说明碎片化严重。

11.9 验证：heap 命令

Shell 输入 `heap` 查看堆状态：

```
$ Terminal

> heap
=== Kernel Heap Status ===
```

```
  backend:    first_fit
  heap size:  65536 bytes (64 KiB)
  used:       0 bytes (0 allocations)
  free:       65520 bytes (1 free blocks)
```

初始：整个 64 KiB 是一个大空闲块（$65536 - 16 = 65520$）。执行 `heap test`：

```
$ Terminal

> heap test
[heap] alloc: req=100 aligned=104
[heap] alloc: split -> used 104 + free 65400 @ 0xE0000078
[heap] alloc: return 0xE0000010
test: alloc 100B -> 0xE0000010
...
[heap] free: merge forward ...
test: free all -- OK
```

可验证：100 B 对齐到 104（$\lceil 100/8 \rceil \times 8$）；返回地址 = `0xE0000000` + 16；合并正确执行。

11.10 初始化顺序

src/kernel/core/kmain.c

```
pmm_init(mmap);     /* 1. 物理内存管理器 */
vmm_init();         /* 2. 虚拟内存（页表）*/
vmm_unmap_identity(); /* 3. 拆除 identity mapping */
kmalloc_init();     /* 4. 内核堆 — 依赖 PMM + VMM */
vma_init();         /* 5. VMA — 依赖 kmalloc */
```

依赖链：PMM → VMM → kmalloc → VMA。VMA 在堆之后——因为 VMA 节点需要 `kmalloc` 分配。

11.11 思考与练习

练习 11.1

实现 Best-Fit 分配算法

复制 `heap_first_fit.c` 为 `heap_best_fit.c`，修改 `alloc`：遍历**整个**链表，找 `size` 差值最小的空闲块。在 `kconfig.h` 新增 `KCONFIG_HEAP_BACKEND == 2`。测试：反复分配 32B/128B/64B，释放 128B，再分配 100B——对比两种算法行为。思考：Best-Fit 一定减少碎片吗？在什么负载下反而更差？

练习 11.2

堆增长（`heap_grow`）集成

当前 First-Fit 找不到块就返回 NULL。扩展它：调 `heap_grow(size + HEADER_SIZE)`；找链表最后一个块 last，算末尾 `last_end`；若 last 是 free 就扩 size，否则在 `last_end` 建新空闲块；递归重试分配。

练习 11.3

碎片率统计

给 `kheap_stats_t` 新增 `fragmentation` 字段：

$$\text{fragmentation} = \left(1 - \frac{\max(\text{单块 free size})}{\sum \text{free_bytes}}\right) \times 100\%$$

碎片率 $= 0$ 表示所有空闲内存连续；趋近 100% 表示碎片化严重。在 `heap` 命令中显示该指标。

练习 11.4

Slab 的 `kfree` 流程分析

阅读 `heap_slab.c`，画出 `kfree` 完整流程图（标注数据结构）：`ptr & ~0xFFF` → 读 `cache_idx/obj_size` → 计算 slot index → `bitmap_set_bit` → 若从 full 变非满则移到 partial。

进阶：当 slab 全空（`free_count == capacity`）时，是否应把整页还给 PMM？好处和风险各是什么？

Chapter 12

VMA：虚拟内存区域管理

12.1 本章目标

- 理解 VMA 的核心价值——让 Page Fault handler 区分”合法的按需分页”与”非法访问”
- 掌握 `vma_ops_t` 可插拔后端接口（与 `pmm_ops_t`/`heap_ops_t` 同一模式）
- 理解 `vm_area_t` 结构体中各字段的含义
- 掌握 VMA 权限标志（`VMA_READ`/`WRITE`/`EXEC`）与 PTE 标志位的映射关系
- 理解 `vma.c` dispatch 层的转发逻辑
- 实现排序数组后端：二分查找 $O(\log n)$ find + 有序插入/删除
- 实现红黑树后端：5 条性质、旋转操作、$O(\log n)$ find/add/remove
- 实现 Maple Tree 后端：B+ tree 变体、高扇出缓存友好、节点分裂/上提
- 理解静态节点池的必要性（打破 kmalloc 循环依赖）
- 掌握 Page Fault 集成：三种诊断结果
- 理解引导阶段区域注册与 `vmm_alloc_pages` 的 VMA 自动跟踪

12.2 背景知识：为什么需要 VMA？

在第 9 章我们实现了二级页表：CPU 通过 PDE → PTE → 物理页完成地址翻译。当 PTE 的 Present 位为 0 时，CPU 触发 Page Fault（#PF, ISR 14），但 页表本身不记录这个虚拟地址”本来应不应该”被映射。

考虑以下两种引发 #PF 的场景：

1. **合法的按需分页**——程序声明了一段堆区域，但尚未分配物理页。缺页时内核应分配物理页并建立映射，让程序继续运行。

2. **非法访问**——野指针写到 0x00000000，或跳转到一段没有任何映射的地址。内核应杀死进程或触发 panic。

为什么？

为什么不在 Page Fault handler 里扫描页表来区分?
页表只有两种状态：映射了（Present=1）或没映射（Present=0）。”没映射”既可能是”还没来得及映射”，也可能是”根本不该映射”。VMA 显式注册每个合法的虚拟地址区间及其权限，使 #PF handler 有了第二层判据——*该地址属不属于某个已注册的 VMA？*

VMA（Virtual Memory Area）的职责就是 ** 维护一张虚拟地址区间注册表 **。每个区间记录 [start，end)、权限标志和可读名称。Page Fault handler 查 VMA 表，即可做出三种判断（详见第 12.11 节）。

12.3 vm_area_t 结构体

VMA 系统中最基本的数据结构是 vm_area_t——描述一段虚拟内存区域：

src/include/kernel/vma.h

```
typedef struct vm_area {
    uint32_t  start;     /* 起始虚拟地址（包含，页对齐） */
    uint32_t  end;       /* 结束虚拟地址（不包含，页对齐） */
    uint32_t  flags;     /* VMA_READ | VMA_WRITE | VMA_EXEC */
    const char* name;    /* 人类可读名称，如 "direct-map", "kheap" */
} vm_area_t;
```

约定与 Linux 一致：[start，end）左闭右开，start 和 end 都必须页对齐，不同 VMA 之间不允许地址重叠。

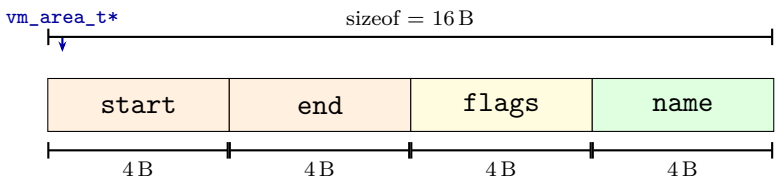

图 12.1: vm_area_t 内存布局（32 位平台）

注意：vm_area_t 是公开的只读视图，不包含后端内部管理字段（如红黑树颜色、父/子指针等）。这保持了接口与实现的解耦——调用者只读 vm_area_t，后端的内部节点可以包含任意附加字段。

12.4 VMA 权限标志与 PTE 标志的关系

src/include/kernel/vma.h

```
#define VMA_READ 0x01u  /* 可读 */
#define VMA_WRITE 0x02u /* 可写 */
#define VMA_EXEC 0x04u  /* 可执行（配合 NX 位使用） */
```

VMA 标志描述的是语义层级的权限意图；PTE 标志是硬件层级的访问控制。它们之间的映射关系如表 12.1 所示。

VMA 标志	对应 PTE 操作	说明
VMA_READ	PTE_PRESENT	页面存在即可读
VMA_WRITE	PTE_WRITABLE	设置 R/W 位
VMA_EXEC	清除 NX 位（PAE/64-bit）	32 位无 NX，留作扩展

表 12.1: VMA 权限标志到 PTE 标志的映射

思考 12.1

在 32 位非 PAE 模式下，x86 没有 NX（No-Execute）位——所有可读页面都可以执行。这意味着 VMA_EXEC 在当前实现中其实不会产生硬件层面的约束。那为什么还要定义它？

提示：考虑将来迁移到 PAE 或 64 位模式、以及软件层面的审计需求。

12.5 可插拔后端：vma_ops_t 接口

与 PMM（第 8 章）和 kmalloc（第 11 章）完全相同的"dispatch + 后端" 模式：

src/include/kernel/vma.h

```
typedef struct vma_ops {
    const char* name;
    void (*init)(void);
    int (*add)(uint32_t start, uint32_t end,
               uint32_t flags, const char* name);
    int (*remove)(uint32_t start);
    const vm_area_t* (*find)(uint32_t addr);
    void (*dump)(void);
    unsigned (*count)(void);
} vma_ops_t;
```

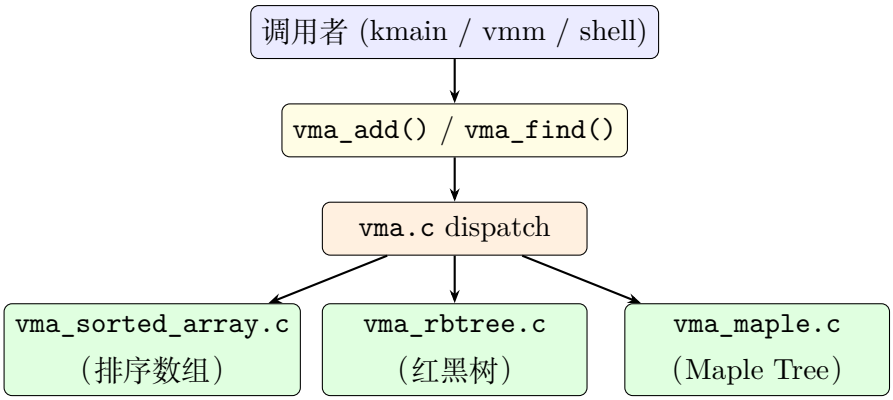

图 12.2: vma_ops_t 可插拔后端调用链——三种后端通过 kconfig.h 选择

12.6 Dispatch 层：vma.c 实现

vma.c 的职责非常简单——校验后端是否已注册，然后转发：

src/kernel/mm/vma.c

```
static const vma_ops_t* g_vma_ops = NULL;
static int g_vma_ready = 0;

void vma_register_backend(const vma_ops_t* ops) {
    g_vma_ops = ops;
}

void vma_init(void) {
    if (!g_vma_ops) {
        printk("[vma] no backend registered\n");
        return;
    }
    g_vma_ops->init();
    g_vma_ready = 1;
    printk("[vma] backend: %s, init ok\n", g_vma_ops->name);
}

int vma_add(uint32_t start, uint32_t end,
            uint32_t flags, const char* name) {
    if (!g_vma_ops || !g_vma_ready) return -1;
    return g_vma_ops->add(start, end, flags, name);
}
```

其余 vma_remove/vma_find/vma_dump/vma_count 格式完全一致——if (!ready) return fallback; return g_vma_ops->xxx(...);。

设计决策

Dispatch 层看似”什么都没做”，但它带来三个好处：

1. **编译期解耦**——调用者只 `#include "vma.h"`，不需要知道后端头文件；
2. **运行时切换**——`vma_register_backend` 在 init 前随时可换后端；
3. **安全守卫**——未初始化时所有 API 返回安全默认值，不会空指针崩溃。

12.7 早期实现：排序数组后端

红黑树是 VMA 后端的终极方案，但它代码量大、调试困难，不适合内核开发的早期阶段。我们先实现一个**排序数组**（sorted array）后端——代码不到 150 行，却足以让 VMA 子系统完整运行，为后续所有章节提供基础。

设计决策

排序数组的核心权衡：

- **优势**：实现极其简单，不依赖 `kmalloc`（静态数组），`find` 用二分查找 $O(\log n)$，`dump` 天然按地址排序
- **劣势**：`add`/`remove` 需要搬移数组元素 $O(n)$
- **适用场景**：VMA 数量 < 64（内核启动到单进程阶段绰绰有余）
- **升级路径**：Stage 13 引入 per-process VMA 后切换到红黑树后端，接口完全兼容，调用者零改动

12.7.1 数据结构

排序数组直接复用公开的 `vm_area_t`，不需要额外的内部节点类型：

src/kernel/mm/vma_sorted_array.c

```
#define VMA_MAX_AREAS 256

static vm_area_t g_areas[VMA_MAX_AREAS];
static unsigned g_count = 0;
```

为什么？

为什么是 256?
每个 vm_area_t = 16 字节，256 × 16 = 4096 字节 = 恰好 1 页。256 个不重叠区间足以管理 4 GiB 地址空间（平均每个区间 16 MiB）。引导阶段只用 2 个（direct-map + kheap），VMM 动态分配约 20 个——远不会用完。

数组中 g_areas[0..g_count) 始终按 start 字段升序排列，g_count 跟踪当前已注册的 VMA 数量。

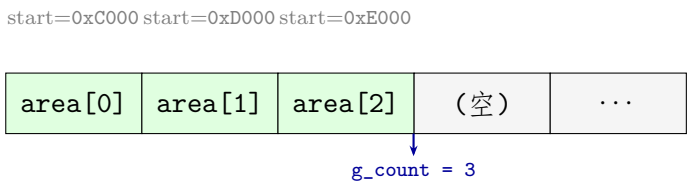

图 12.3: 排序数组示意——前 3 个槽位有效，按 start 升序

与红黑树后端的静态节点池类似，排序数组也完全不依赖 kmalloc——它是一个编译期 static 数组。这避免了第 12.10 节讨论的循环依赖问题。

12.7.2 二分查找辅助函数

sa_add、sa_remove、sa_find 都需要在有序数组上做二分查找，区别仅在于比较条件（< vs <=）。我们抽出两个辅助函数避免重复代码：

src/kernel/mm/vma_sorted_array.c

```
/* lower_bound: 第一个 start >= target 的下标 */
static unsigned sa_lower_bound(uint32_t target)
{
    unsigned left = 0, right = g_count;
    while (left < right) {
        unsigned mid = left + (right - left) / 2;
        if (g_areas[mid].start < target)
            left = mid + 1;
        else
            right = mid;
    }
    return left;
}

/* upper_bound: 第一个 start > target 的下标 */
static unsigned sa_upper_bound(uint32_t target)
```

```
{
    unsigned left = 0, right = g_count;
    while (left < right) {
        unsigned mid = left + (right - left) / 2;
        if (g_areas[mid].start <= target)
            left = mid + 1;
        else
            right = mid;
    }
    return left;
}
```

两者的唯一区别是比较时是否包含等号：lower_bound 用 <（找 ≥），upper_bound 用 <= （找 >）。sa_add/sa_remove 用 lower_bound 找精确位置，sa_find 用 upper_bound 找" 最后一个 ≤ addr" 的候选。

12.7.3 插入：保持有序 + 重叠检测

sa_add 的核心逻辑分四步：

1. **参数校验**——容量上限、start < end、页对齐（低 12 位为零）
2. **重叠检查**——遍历数组，确认新 [start, end) 不与任何已有 VMA 重叠。两个区间重叠的充要条件是 a.start < b.end && b.start < a.end
3. **找插入位置**——因数组有序，找到第一个 g_areas[i].start > start 的位置
4. **后移 + 写入**——从尾部往回搬，腾出插入位，写入新 VMA

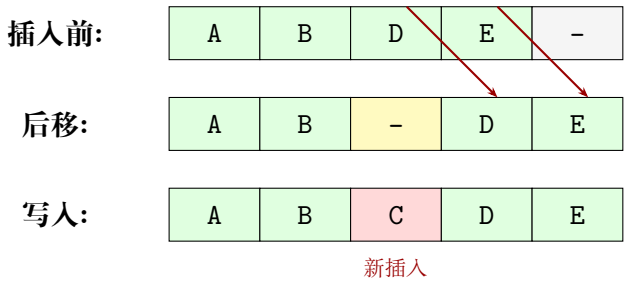

图 12.4: sa_add 插入过程：后移元素 → 写入新 VMA

12.7.4 查找：二分搜索

sa_find(addr) 调用 sa_upper_bound 找到第一个 start > addr 的位置，减 1 即为候选者：

src/kernel/mm/vma_sorted_array.c

```c
static const vm_area_t* sa_find(uint32_t addr)
{
    if (g_count == 0)
        return NULL;

    unsigned idx = sa_upper_bound(addr);
    if (idx == 0)
        return NULL;

    const vm_area_t* candidate = &g_areas[idx - 1];
    return (addr < candidate->end) ? candidate : NULL;
}
```

算法步骤：

1. 初始化 `left = 0`, `right = g_count`
2. 当 `left < right` 时，计算 `mid = left + (right - left) / 2`
3. 如果 `g_areas[mid].start <= addr`，则 `left = mid + 1`（`mid` 可能是答案，但看右边有没有更后面的候选者）
4. 否则 `right = mid`（`mid` 的 `start` 太大，答案在左边）
5. 循环结束后，`left - 1` 是最后一个 `start <= addr` 的下标
6. 检查 `addr < candidate->end`，是则命中，否则落在空洞中

为什么？

为什么用 upper_bound 而不是 lower_bound?
我们要找的是" 最后一个 `start <= addr` 的 VMA"。`upper_bound` 找的是第一个 `start > addr` 的位置，减 1 就是我们要的答案。这是二分查找最常见的变体之一，值得牢记。
如果 `left == 0`（所有 VMA 的 `start` 都大于 `addr`），直接返回 NULL——不存在包含该地址的 VMA。

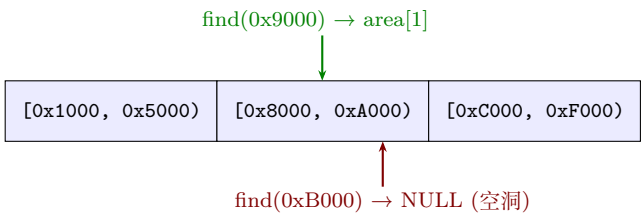

图 12.5: 二分查找示例：0x9000 命中 area[1]；0xB000 落在两个 VMA 之间的空洞

12.7.5 删除：前移覆盖

`sa_remove(start)` 用 `sa_lower_bound` 二分定位后，将后续元素前移一格覆盖：

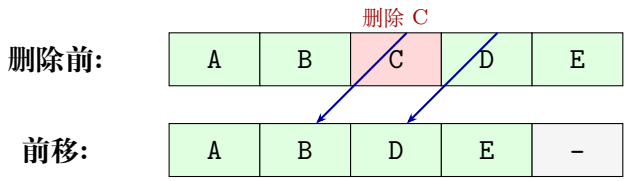

图 12.6: `sa_remove` 删除过程：前移元素覆盖被删除位置

12.7.6 复杂度总结与适用阶段

操作	排序数组	适用场景
`find`	$O(\log n)$ 二分	每次 #PF 都要调用，必须快
`add`	$O(n)$ 搬移	仅启动/分配时调用，频率低
`remove`	$O(n)$ 搬移	仅释放时调用，频率低
`dump`	$O(n)$ 顺序遍历	仅调试命令，不影响性能

表 12.2: 排序数组后端复杂度——`find` 快，`add`/`remove` 可接受

在内核启动到单进程阶段（Stage 9 – Stage 12），VMA 数量 $n < 20$。此时 $O(n)$ 的插入/删除在绝对耗时上几乎无开销（搬移 20 个 16 字节的结构体 $\approx$ 几十个 `mov` 指令）。当多进程引入 per-process VMA 后再切换红黑树，是更合理的渐进式开发策略。

12.8 红黑树后端：`vma_rbtree.c`

排序数组已经满足了早期内核的需求，但当进程管理引入后，VMA 数量会急剧增长。红黑树在所有单次操作上都保持 $O(\log n)$，是 Linux 内核历史上长期使用的方案（Linux 2.4 $\sim$ 6.0，整整 20 年）。

操作	链表	排序数组	红黑树	Maple Tree
`find`(addr)	$O(n)$	$O(\log n)$	$O(\log n)$	$O(\log_B n)$
`add`	$O(n)$	$O(n)$	$O(\log n)$	$O(\log_B n)$
`remove`	$O(n)$	$O(n)$	$O(\log n)$	$O(\log_B n)$
`dump`（遍历）	$O(n)$	$O(n)$	$O(n)$	$O(n)$

表 12.3: 不同数据结构的 VMA 操作复杂度对比（B = B-tree 扇出度）

12.8.1 红黑树的 5 条性质

红黑树是一种自平衡二叉搜索树，每个节点带一个颜色位（红/黑），且满足以下 5 条性质：

1. 每个节点要么是红色，要么是黑色。
2. 根节点是黑色。
3. 所有叶子节点（NIL 哨兵）是黑色。
4. 红色节点的两个子节点必须是黑色（不能有连续的红节点）。
5. 从任意节点到其所有后代叶子节点的路径上，黑色节点数相同（黑高相等）。

性质 4 + 5 共同保证了树的高度不超过 $2\log_2(n+1)$，从而使查找、插入、删除都是 $O(\log n)$。

12.8.2 内部节点结构

每个红黑树节点嵌入一个 `vm_area_t` 公开视图，外加颜色位和三个指针：

src/kernel/mm/vma_rbtree.c

```
#define RB_MAX_NODES 256
#define RB_BLACK 0
#define RB_RED 1

typedef struct rb_node {
    vm_area_t     area;  /* 公开视图（第一个字段） */
    int           color; /* RB_BLACK or RB_RED */
    struct rb_node* parent;
    struct rb_node* left;
    struct rb_node* right;
} rb_node_t;
```

树使用一个共享的 NIL 哨兵节点（颜色始终为黑）替代 NULL，消除了每次访问子指针前的判空检查，极大简化旋转和修复代码。

12.8.3 旋转操作

当插入或删除破坏了红黑性质时，需要通过**旋转**（rotation）恢复平衡。旋转分为左旋和右旋，它们互为镜像操作：

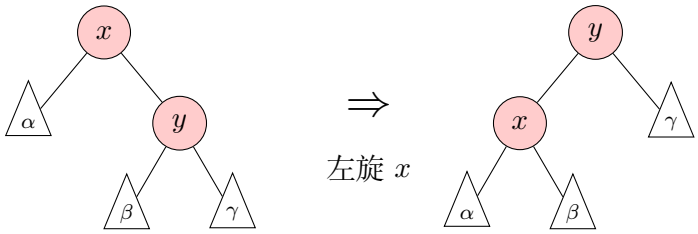

图 12.7: 红黑树左旋示意图（右旋为其镜像）

旋转只改变指针指向，不改变 BST 的中序遍历顺序——因此旋转前后所有 VMA 的地址排序仍然正确。

src/kernel/mm/vma_rbtree.c

```
static void rotate_left(rb_node_t* x)
{
    rb_node_t* y = x->right;
    x->right = y->left;
    if (y->left != NIL)
        y->left->parent = x;
    y->parent = x->parent;
    if (x->parent == NIL)
        g_root = y;
    else if (x == x->parent->left)
        x->parent->left = y;
    else
        x->parent->right = y;
    y->left = x;
    x->parent = y;
}
```

右旋 (rotate_right) 是完全对称的镜像操作，交换 left/right 即可。

12.8.4 插入与修复

新节点默认为红色，BST 插入后可能违反性质 4（连续红节点）。修复分 3 种情况（加镜像共 6 种）：

1. **叔节点为红**——父和叔变黑，祖父变红，向上递归。最坏 $O(\log n)$ 次重着色。
2. **叔节点为黑 + z 是内侧孩子**——旋转父节点，转为情况 3。
3. **叔节点为黑 + z 是外侧孩子**——旋转祖父 + 重着色，修复完成。

最坏情况：$O(\log n)$ 次重着色 + 最多 2 次旋转。

12.8.5 删除与修复

删除一个黑色节点会破坏性质 5（黑高不等），修复分 4 种情况（加镜像共 8 种）。这是红黑树最复杂的部分，但最坏也只需 $O(\log n)$ 次重着色 + 最多 3 次旋转。

12.8.6 区间查找

BST 按 `start` 排序，但 VMA 是区间 `[start, end)`。查找算法从根下降，每步做三路判断：

src/kernel/mm/vma_rbtree.c

```
static const vm_area_t* rb_find(uint32_t addr)
{
    rb_node_t* cur = g_root;
    while (cur != NIL) {
        if (addr < cur->area.start)
            cur = cur->left;
        else if (addr >= cur->area.end)
            cur = cur->right;
        else
            return &cur->area; /* 命中 */
    }
    return NULL;
}
```

12.8.7 中序遍历 dump

利用 parent 指针做迭代中序遍历（不递归，避免栈溢出风险），天然按地址升序输出。

思考 12.2

如果 VMA 后端改用简单的有序链表（插入时遍历找位置），在 VMA 数量为 $n = 200$ 时，`find` 的最坏情况要遍历多少个节点？红黑树呢？（提示：$\lceil \log_2 201 \rceil = 8$）在什么场景下链表反而比红黑树更合适？（提示：VMA 数量极少且变化频繁——旋转的常数开销）

12.9 Maple Tree 后端：`vma_maple.c`

Linux 6.1（2022 年 12 月）用 Maple Tree 取代了沿用 20 年的红黑树来管理 VMA。我们实现了一个教学级的 B+ tree 变体，保留 Maple Tree 的核心设计理念。

为什么？

为什么 Linux 从红黑树换到 Maple Tree?

1. **缓存友好**：B-tree 节点包含多个键值对（扇出度高），一次缓存行加载可比较多个键，减少缓存 miss。红黑树每个节点只有一个键，每次比较都可能 cache miss。
2. **RCU 安全**：Maple Tree 天然支持 Read-Copy-Update，读者无需加锁即可遍历。红黑树的旋转在 RCU 下很难正确实现。
3. **区间原生支持**：以 `[start, end)` 区间为键，不像红黑树只按 `start` 排序后再检查 `end`。
4. **减少指针追逐**：紧凑数组存储，指针数更少。

12.9.1 节点结构

每个节点包含最多 9 个分割键（pivot）和 10 个子节点/数据槽位：

src/kernel/mm/vma_maple.c

```
#define MAPLE_NODE_SLOTS 10
#define MAPLE_MAX_PIVOTS (MAPLE_NODE_SLOTS - 1) /* 9 */

typedef struct maple_node {
    uint32_t    pivots[MAPLE_MAX_PIVOTS];
    uint8_t     nr_entries;
    uint8_t     is_leaf;
    maple_node_t* parent;
    union {
        maple_node_t* children[MAPLE_NODE_SLOTS]; /* 内部节点 */
        vm_area_t*  slots[MAPLE_NODE_SLOTS]; /* 叶节点 */
    };
} maple_node_t;
```

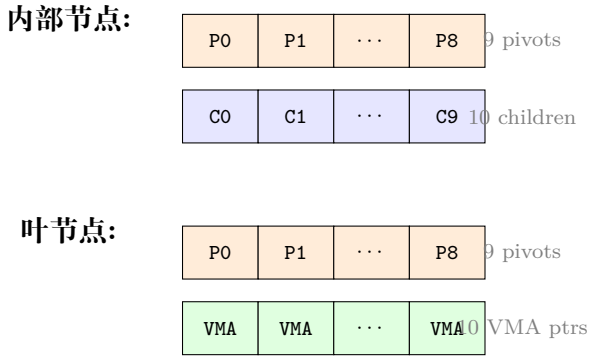

图 12.8: Maple Tree 节点布局——内部节点存子指针，叶节点存 VMA 指针

为什么？

为什么扇出度选 10?
Linux 的 `maple_range_64` 有 16 个 slot，每节点 256 字节（4 个缓存行）。我们的 32 位系统中，10 个 pivot + 10 个 child + 元数据 $\approx$ 96 字节（$<$ 2 个缓存行）。扇出度 10 意味着 256 个 VMA 只需树高 3（$10^3 = 1000 > 256$），每次查找最多 3 次节点访问，每次访问时同一节点的 pivot 在同一缓存行中。

12.9.2 查找：从根下降到叶

与红黑树不同，Maple Tree 的查找直接沿着 B+ tree 结构下降到叶节点，然后在叶中线性扫描 ≤ 10 个条目：

src/kernel/mm/vma_maple.c

```
static const vm_area_t* maple_find(uint32_t addr)
{
    maple_node_t* node = g_maple_root;
    while (!node->is_leaf) {
        unsigned idx = internal_find_child(node, addr);
        node = node->children[idx];
    }
    for (unsigned i = 0; i < node->nr_entries; i++) {
        vm_area_t* vma = node->slots[i];
        if (vma && addr >= vma->start && addr < vma->end)
            return vma;
    }
    return NULL;
}
```

12.9.3 插入：分裂上提

当叶节点满了（10 个条目），需要分裂：

1. 分配新叶节点，把当前叶的后半部分移到新叶
2. 把中间键上提到父节点
3. 如果父节点也满了，递归分裂——这是 B-tree 增高的唯一方式

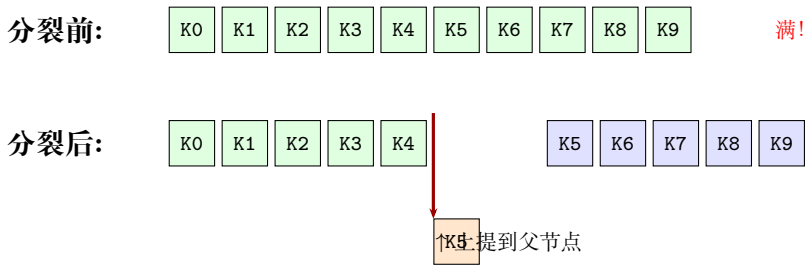

图 12.9: Maple Tree 叶节点分裂——后半部分移到新节点，中间键上提

12.9.4 与红黑树的对比

设计决策

两种后端的适用场景：

- **红黑树**：通用自平衡 BST，实现经典，适合教学。每个节点只存一个 VMA，指针追逐多，但代码逻辑清晰。
- **Maple Tree**：面向现代 CPU 缓存层次优化。每次节点访问比较多个键（同一缓存行），树更矮，总缓存 miss 更少。代价是分裂/合并逻辑比旋转更复杂。

在 VMA 数量 < 256 的内核启动阶段，三种后端的性能差异可忽略。选择哪个主要看代码风格偏好和教学目标。

12.10 静态节点池：打破循环依赖

回顾初始化顺序（第 11 章）：

src/kernel/mm/vma.c

```
pmm_init();      /* 1. 物理内存 */
vmm_init();      /* 2. 页表 */
kmalloc_init();  /* 3. 内核堆 */
vma_init();      /* 4. VMA — 依赖 kmalloc */
```

VMA 初始化在 kmalloc_init() 之后——所以后端可以用 kmalloc 分配内部节点。但存在一个微妙问题：

为什么？

如果 kmalloc 的堆增长（heap_grow）需要调 vmm_alloc_pages，而 vmm_alloc_pages 内部想注册 VMA（跟踪新分配的虚拟地址区间），VMA 的 add 又要 kmalloc 分配红黑树节点——循环依赖！
解决方案：红黑树后端使用**静态节点池**（编译期 static 数组），预分配固定数量的节点（如 256 个），完全绕开 kmalloc。代价是 VMA 上限固定，但内核启动阶段区域数量很少，256 足够。

静态节点池的实现使用空闲链表，实现 $O(1)$ 的分配和释放：

src/kernel/mm/vma_rbtree.c

```
static rb_node_t g_pool[RB_MAX_NODES];
static rb_node_t* g_free_head; /* 空闲链表头 */

static void pool_init(void)
{
    g_free_head = &g_pool[0];
    for (unsigned i = 0; i < RB_MAX_NODES - 1; i++)
        g_pool[i].right = &g_pool[i + 1];
    g_pool[RB_MAX_NODES - 1].right = NULL;
}

static rb_node_t* pool_alloc(void)
{
    if (!g_free_head) return NULL;
    rb_node_t* n = g_free_head;
    g_free_head = n->right;
    n->color = RB_RED; /* 新节点默认红色 */
    n->parent = n->left = n->right = NIL;
    return n;
}

static void pool_free(rb_node_t* n)
{
    n->right = g_free_head;
    g_free_head = n;
}
```

用 `right` 指针串联空闲节点，省掉额外的 `next` 字段。分配时从头部取，释放时插回头部——均为 $O(1)$。

Maple Tree 后端同理，使用独立的节点池（`maple_node_t g_node_pool[64]`）和 VMA 数据池（`vm_area_t g_vma_pool[256]`）。

12.11 Page Fault 集成

#PF handler(ISR 14)收到故障地址 `cr2` 和错误码 `err_code` 后，调用 `vma_find(cr2)` 可以产生三种诊断结果：

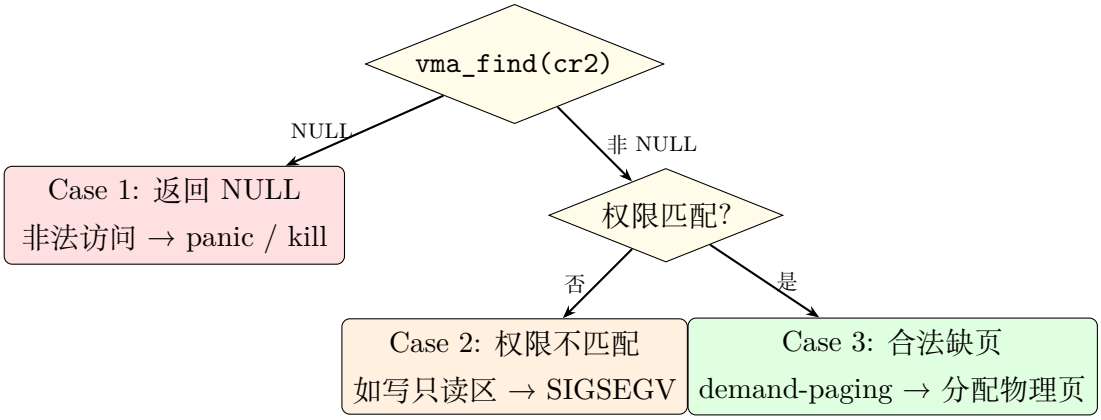

图 12.10: #PF handler 中的 VMA 三种诊断

1. **Case 1: 无 VMA**（`vma_find` 返回 NULL）——该地址不属于任何已注册区域，是真正的非法访问。内核态触发则 panic；用户态触发则杀死进程。

2. **Case 2: 权限不匹配**——地址属于某个 VMA，但操作违反权限。例如写入一个仅 `VMA_READ` 的区域。对应 Linux 的 `SIGSEGV`。

3. **Case 3: 合法缺页（demand paging candidate）**——地址属于 VMA 且权限匹配，只是物理页尚未分配。分配物理页 → 建立映射 → 返回，程序继续运行。

当前实现中我们尚未启用 demand paging，所有映射在 `vmm_alloc_pages` 时一步到位。但 VMA 框架为将来的按需分页奠定了基础。

12.12 引导阶段区域注册

在 `kmain.c` 中，VMA 初始化后立即注册两个引导时建立的内核区域：

src/kernel/core/kmain.c

```
vma_init();

```

```
if (vma_is_ready()) {
    /* 1. 直接映射区：内核代码/数据 + 直接映射的物理内存 */
    vma_add(KERNEL_VIRT_OFFSET, vmm_direct_map_end(),
            VMA_READ | VMA_WRITE | VMA_EXEC, "direct-map");

    /* 2. 内核堆区 */
    vma_add(KHEAP_START,
            KHEAP_START + KCONFIG_HEAP_INITIAL_PAGES * VMM_PAGE_SIZE,
            VMA_READ | VMA_WRITE, "kheap");
}
```

- direct-map：覆盖 0xC0000000 到 vmm_direct_map_end()，包含内核代码（需要 EXEC）、只读数据和读写数据。权限给足 rwx，更细粒度的分段保护留给将来的 .text/.rodata 拆分。
- kheap：覆盖 0xE0000000 开始的初始堆区域。堆只做数据 rw，无需 x。堆增长时应同步调用 vma_add 或更新 end 来跟踪新区域。

设计决策

注册 VMA 的时机是”谁建立映射，谁负责注册”：

- vmm_init() 建立直接映射 → kmain 注册 direct-map
- kmalloc_init() 建立堆映射 → kmain 注册 kheap
- vmm_alloc_pages() 将来可在内部自动调用 vma_add

这比集中在一处注册更不容易遗漏——映射与注册在同一上下文中完成。

12.13 vmm_alloc_pages/free_pages 的 VMA 自动跟踪

当前 vmm_alloc_pages 只做 PMM 分配 + 页表映射，不通知 VMA。理想的流程是在分配/释放时自动跟踪：

src/kernel/mm/vmm.c

```
void* vmm_alloc_pages(unsigned count) {
    uint32_t vaddr = bump_next();          /* 选虚拟地址 */
    for (unsigned i = 0; i < count; i++) {
        uint32_t phys = pmm_alloc_page();
        vmm_map_page(vaddr + i * PAGE_SIZE, phys,
                     PTE_PRESENT | PTE_WRITABLE);
    }
```

```
    /* 自动注册 VMA */
    if (vma_is_ready()) {
        vma_add(vaddr, vaddr + count * PAGE_SIZE,
                VMA_READ | VMA_WRITE, "vmm-alloc");
    }
    return (void*)vaddr;
}
```

vmm_free_pages 的逆操作则调用 vma_remove(vaddr)。这样 Page Fault handler 对所有动态映射都有完整的 VMA 覆盖，不会误判合法区域为非法访问。

12.14 验证：Shell 命令

12.14.1 vma list——列出所有 VMA

```
$ Terminal

> vma list
=== VMA list (sorted-array, 2 entries) ===
  [0xC0000000, 0xD0000000) rwx direct-map (256 MiB)
  [0xE0000000, 0xE0010000) rw- kheap      (64 KiB)
```

初始状态有两个 VMA：直接映射区和内核堆。地址按升序排列（红黑树中序遍历），权限用 rwx 紧凑表示。

12.14.2 vma find <addr>——查找指定地址

```
$ Terminal

> vma find 0xC1000000
0xC1000000 -> VMA [0xC0000000, 0xD0000000) 'direct-map'
  size: 262144 KiB, offset: 0x1000000, flags: rwx

> vma find 0xA0000000
0xA0000000 -> no VMA (unmapped / untracked)
```

12.14.3 vma test——自测试

```
$ Terminal

> vma test
[vma-test] === VMA selftest ===
[vma-test] test 1: add + find
[vma-test] PASS
[vma-test] test 2: find outside
[vma-test] PASS
[vma-test] test 3: overlap detection
[vma-test] PASS
[vma-test] test 4: remove + find
[vma-test] PASS
[vma-test] === ALL PASS ===
```

测试使用 0xF1000000–0xF1010000（64 KiB）作为临时区域，验证 add/find/overlap/remove 四个基本操作的正确性。

12.15 内核虚拟地址空间全景与 VMA 覆盖

将第 11 章的地址空间图补充 VMA 信息后：

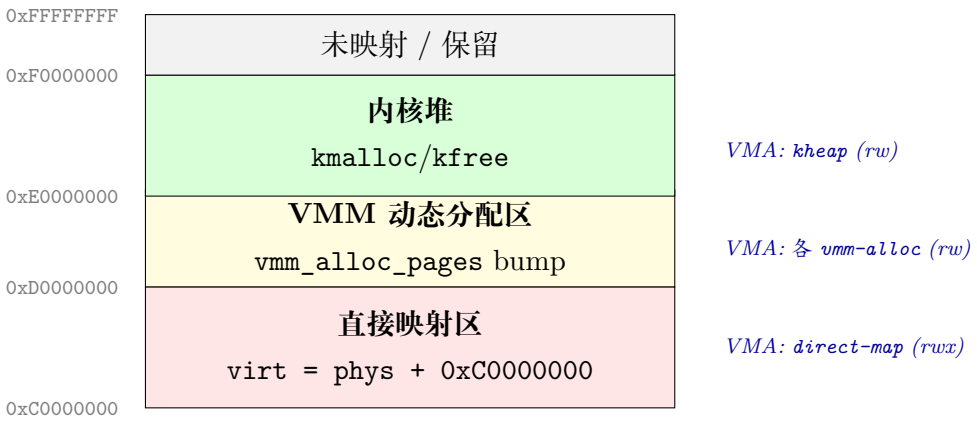

图 12.11: 内核虚拟地址空间与 VMA 覆盖关系

12.16 后端切换：kconfig.h

三种后端已全部实现，通过 kconfig.h 的编译期开关选择：

src/include/kernel/kconfig.h

```
/* 0 = sorted-array — 排序数组，简单稳定，早期默认
```

```
 * 1 = rbtree       — 红黑树，O(log n) 全操作
 * 2 = maple-tree   — B+ tree 变体，高扇出缓存友好
 */
#define KCONFIG_VMA_BACKEND 0
```

kmain.c 中根据宏值选择后端：

src/kernel/core/kmain.c

```
#if KCONFIG_VMA_BACKEND == 0
    vma_register_backend(vma_sorted_array_get_ops());
#elif KCONFIG_VMA_BACKEND == 1
    vma_register_backend(vma_rbtree_get_ops());
#elif KCONFIG_VMA_BACKEND == 2
    vma_register_backend(vma_maple_get_ops());
#endif
```

修改 KCONFIG_VMA_BACKEND 后 make iso，用 vma count 命令确认当前加载的后端名称。vma test 自测试对所有三种后端均通过。

12.17 思考与练习

练习 12.1

#PF handler 中集成 VMA 检查

修改 irq.c 中的 Page Fault handler：

1. 读取 CR2（故障地址）
2. 调用 vma_find(cr2) 获取 VMA
3. 如果返回 NULL：打印 "SEGFAULT: addr=0x... not in any VMA" 并 panic
4. 如果返回非 NULL 但权限不匹配：打印 "PERMISSION DENIED" 并 panic
5. 如果权限匹配：打印 "demand-page candidate"（暂不实现实际分页）

测试：将 0xA0000000 解引用，确认触发 Case 1 的 panic 输出。

练习 12.2

VMA 区域合并

当新增 VMA 与相邻 VMA 满足以下条件时自动合并：

- 新 VMA 的 start == 已有 VMA 的 end（或反之）
- 两者的 flags 完全相同

合并后更新 `end`（或 `start`）并移除多余节点。这减少了 VMA 总数，使红黑树更扁平、查找更快。
思考：合并可能影响 `vma_remove(start)` 的语义——如果用户按原始 `start` 移除，但该区域已被合并到更大的 VMA 中，应该怎么处理？

练习 12.3

VMA 统计与碎片分析

给 `vma_ops_t` 新增 `stats` 函数指针，收集以下信息：

1. 已注册 VMA 总数
2. 已覆盖的虚拟地址总量（KiB）
3. VMA 之间最大空洞的大小——即相邻 VMA 之间最大的 `gap`
4. 节点池利用率（`pool_used / VMA_MAX_NODES`）

在 `vma count` 命令中显示这些统计信息。地址空间碎片化可定义为：

$$\text{fragmentation} = 1 - \frac{\max(\text{gap})}{\text{total unmapped space}}$$

Part IV

进程与用户态

Chapter 13

TSS 与 Ring 3：进入用户态

13.1 本章目标

- 理解 x86 特权级（Ring 0 – Ring 3）与 CPL/DPL/RPL 检查机制
- 掌握 Task State Segment（TSS）的结构与作用——为什么只用 SS0:ESP0
- 在 GDT 中添加用户态代码/数据段（DPL=3）和 TSS 描述符
- 理解段选择子的格式：`0x1B`（User Code）与 `0x23`（User Data）
- 用 `iret` 从 Ring 0 跳转到 Ring 3 执行用户代码
- 理解 PDE/PTE 的 U/S 位在两级页表中的”与”逻辑
- 验证 Ring 3 触发 GP Fault 能安全回到内核

设计决策

本章是里程碑 D（进程与用户态）的第一步。后续章节将在此基础上依次添加系统调用（`syscall_ops_t`）、ELF 加载器（`loader_ops_t`）、进程管理和调度器。TSS + GDT 扩展 + `iret` 是所有这些机制的硬件基础。

13.2 概念：x86 特权级模型

x86 保护模式提供 4 级保护环（Ring 0 – Ring 3），实现硬件级别的权限隔离。实际上大多数操作系统只用两级：

- **Ring 0**（内核态）：可执行所有指令，访问所有内存、I/O 端口
- **Ring 3**（用户态）：只能访问标记为 User 的页，不能执行特权指令（如 `hlt`、`lgdt`、`mov cr0`）

为什么？

为什么需要特权分离?

1. **故障隔离**：用户程序的 bug（空指针、越界写）不会破坏内核数据结构。
2. **安全性**：恶意程序无法直接操作硬件（磁盘、网卡），必须通过系统调用请求内核服务。
3. **最小特权原则**：每个组件只拥有完成工作所需的最低权限。

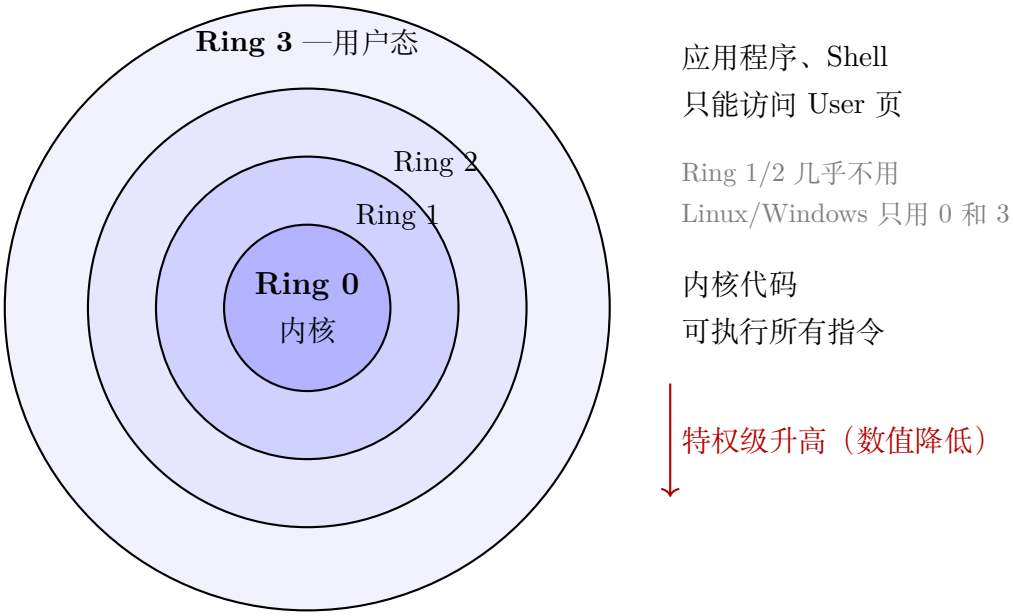

图 13.1: x86 四级保护环模型

13.2.1 CPL、DPL、RPL 三级权限检查

x86 有三个相关的特权级字段，理解它们的关系是掌握保护模式的关键：

CPL（Current Privilege Level） 当前正在执行的代码的特权级。存在 **CS 段寄存器的低 2 位**。CPU 每次取指令时都会检查 CPL。

DPL（Descriptor Privilege Level） 段描述符或门描述符中声明的”目标权限级别”。表示”要访问这个段/门，调用方至少需要这个特权级”。

RPL（Requested Privilege Level） 段选择子的低 2 位。表示”调用方声称自己的权限”。RPL 的作用是防止内核代表用户态去访问不该访问的资源。

访问检查规则：

$$\max(\mathrm{CPL}, \mathrm{RPL}) \leq \mathrm{DPL}$$

即 CPL 和 RPL 中更低特权的那个（数值更大），不能超过目标的 DPL。

思考 13.1

为什么需要 RPL？如果只有 CPL 和 DPL 两级检查，存在什么安全隐患？
提示：考虑用户态通过系统调用请求内核读取一个段。如果没有 RPL，内核（CPL=0）代替用户去读数据段时，DPL 检查会通过——即使用户本身无权访问。RPL 让内核可以"以用户身份"去做权限检查。

13.2.2 特权级切换的硬件机制

特权级切换有两个方向，机制完全不同：

Ring 3 → Ring 0（向上切换——中断/异常/系统调用）

当 CPU 在 Ring 3 执行时遇到中断、异常或 `int` 指令，会自动执行以下步骤：

1. 从 TSS 读取目标特权级的 SS:ESP（即 `SS0:ESP0`）
2. 切换到内核栈：加载 SS0 到 SS，ESP0 到 ESP
3. 将旧的 SS、ESP、EFLAGS、CS、EIP 依次压入**内核栈**
4. 如果异常带错误码（如 #GP、#PF），额外压入 error code
5. 从 IDT 门描述符加载新的 CS:EIP（跳转到中断处理程序）

CPU 状态变化

Ring 3 → Ring 0 切换后：

- CPL 从 3 变为 0
- SS:ESP 从用户栈切换到 TSS.SS0:ESP0 指向的内核栈
- 旧的用户态上下文已安全保存在内核栈上
- EFLAGS.IF 被 interrupt gate 自动清零（禁止嵌套中断）

Ring 0 → Ring 3（向下切换——`iret`）

`iret` 原本用于”从中断返回”。它从栈上弹出保存的 EIP/CS/EFLAGS。如果检测到目标 CS 的 RPL（低 2 位）大于当前 CPL，说明要”返回到更低特权级”，CPU 会额外弹出 ESP 和 SS：

1. 弹出 EIP → 设为新的指令指针
2. 弹出 CS → 设为新的代码段（RPL=3 → CPL 变为 3）
3. 弹出 EFLAGS → 恢复标志寄存器
4. 弹出 ESP → 设为新的栈指针
5. 弹出 SS → 设为新的栈段

注意

x86 没有”直接降级到 Ring 3”的指令。`iret` 是唯一的”向下切换”方式。我们的技巧是在 Ring 0 手动构造一个”假的中断返回帧”，让 CPU 以为自己在从 Ring 3 的中断中返回。

13.3 TSS 的作用与结构

Task State Segment（TSS）是 x86 保护模式中的一个特殊数据结构，大小为 104 字节。它的原始设计目的是支持**硬件任务切换**——CPU 可以自动保存/恢复所有寄存器到 TSS 中，实现任务切换。

但现代操作系统（Linux、Windows、macOS）都不用硬件任务切换，而是用**软件任务切换**（手动保存/恢复寄存器）。原因是：

- 硬件任务切换速度慢（保存/恢复全部寄存器），且不灵活
- 软件任务切换可以只保存必要的寄存器，性能更好
- 软件方式更可控，便于实现 COW fork 等高级功能

但即使不用硬件任务切换，TSS 仍然**不可或缺**——CPU 做特权级切换（Ring 3 → Ring 0）时，**必须**从 TSS 读取 `SS0:ESP0` 来获取内核栈位置。这是硬件的硬性要求，无法绕过。

设计决策

我们的策略：整个系统只维护一个 TSS 实例，只使用其中两个字段：

- ss0 = 0x10（内核数据段选择子）——固定不变
- esp0 = 内核栈顶——将来做进程切换时更新为当前进程的内核栈

其余 100 字节全部保持 0。

13.3.1 TSS 结构体定义

src/include/arch/tss.h

```
typedef struct __attribute__((packed)) {
    uint32_t prev_tss; /* 0x00 链接到前一个 TSS（不用） */
    uint32_t esp0;    /* 0x04  Ring 0 栈指针 */
    uint32_t ss0;     /* 0x08  Ring 0 栈段选择子 */
    uint32_t esp1;    /* 0x0C Ring 1（不用） */
    uint32_t ss1;     /* 0x10 */
    uint32_t esp2;    /* 0x14 Ring 2（不用） */
    uint32_t ss2;     /* 0x18 */
    uint32_t cr3;     /* 0x1C 页目录（不用） */
    uint32_t eip;     /* 0x20 */
    uint32_t eflags; /* 0x24 */
    uint32_t eax, ecx, edx, ebx; /* 0x28-0x34 */
    uint32_t esp, ebp, esi, edi; /* 0x38-0x44 */
    uint32_t es, cs, ss, ds, fs, gs; /* 0x48-0x5C */
    uint32_t ldt;     /* 0x60 LDT 选择子（不用） */
    uint16_t trap;    /* 0x64 调试陷阱标志（不用） */
    uint16_t iomap_base;/* 0x66 I/O 位图偏移 */
} tss_t; /* 总计 104 字节 = 0x68 */
```

其中标注 的 esp0 和 ss0 是我们唯一需要关心的两个字段。

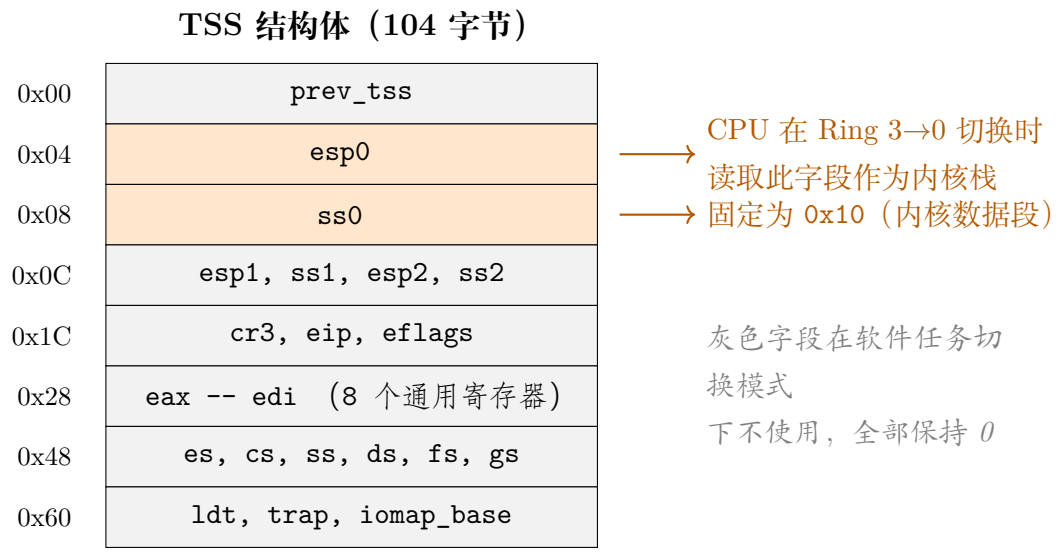

图 13.2: TSS 结构体布局——仅 `esp0` 和 `ss0` 被实际使用

13.3.2 TSS 描述符在 GDT 中的格式

TSS 描述符是一个**系统段描述符**（S 位 = 0），与代码/数据段描述符（S = 1）格式不同。关键字段：

`bit 0-3` Type = 1001b → 32-bit TSS (Available)。被 `ltr` 加载后自动变为 1011b (Busy)

`bit 4` S = 0 → 系统段（非代码/数据）

`bit 5-6` DPL = 0 → 只有 Ring 0 能执行 `ltr` 指令

`bit 7` P = 1 → 描述符有效

合并后 access byte = `0x89` = `10001001b`。

flags 字节（gran 高 4 位）：G=0（粒度为字节，TSS 通常 < 4KiB），D/B=0（TSS 描述符中无意义），L=0，AVL=0。合并后 flags = `0x00`。

13.4 GDT 扩展：添加用户态段

之前的 GDT 只有 3 项（null + 内核代码 + 内核数据）。现在我们需要扩展到 6 项，新增用户态段和 TSS：

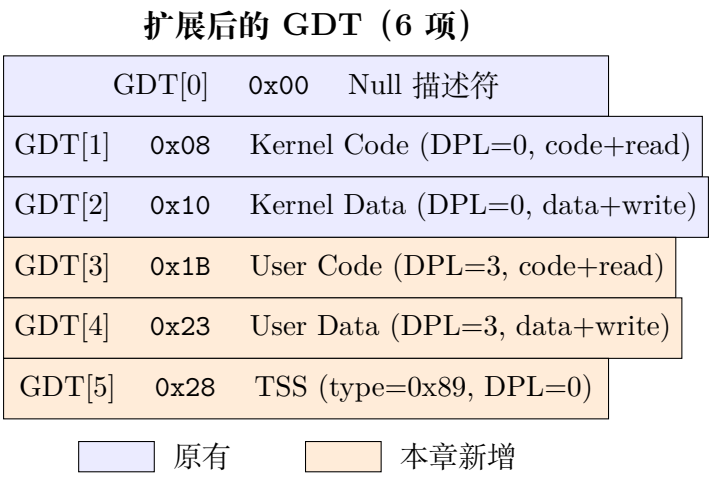

图 13.3: GDT 扩展——新增 User Code/Data 段和 TSS 描述符

13.4.1 用户代码段与用户数据段

用户态段和内核段的**唯一区别**是 DPL 从 0 改为 3。其他所有参数(base=0, limit=4GiB, 平坦段）完全相同：

段	access	DPL	含义
Kernel Code	`0x9A`	0	P=1, DPL=0, S=1, code+read
Kernel Data	`0x92`	0	P=1, DPL=0, S=1, data+write
User Code	`0xFA`	3	P=1, DPL=3, S=1, code+read
User Data	`0xF2`	3	P=1, DPL=3, S=1, data+write

13.4.2 段选择子的计算

段选择子 = `(GDT index << 3) | RPL`。对于用户态段，RPL=3：

- User Code: `(3 << 3) | 3` = `0x18 | 0x03` = `0x1B`
- User Data: `(4 << 3) | 3` = `0x20 | 0x03` = `0x23`
- TSS: `(5 << 3) | 0` = `0x28`（DPL=0，只有内核能 `ltr`）

13.4.3 代码实现：`gdt_init()` 扩展

src/kernel/arch/gdt.c（扩展部分）

```
/* GDT 条目从 3 扩展到 6 */
static gdt_entry_t gdt[6];

void gdt_init(void) {
```

```
    gdt_set_entry(0, 0, 0, 0, 0);       /* null */
    gdt_set_entry(1, 0, 0xFFFFF, 0x9A, 0xC0); /* kernel code */
    gdt_set_entry(2, 0, 0xFFFFF, 0x92, 0xC0); /* kernel data */

    /* 新增：用户态段（DPL=3） */
    gdt_set_entry(3, 0, 0xFFFFF, 0xFA, 0xC0); /* user code */
    gdt_set_entry(4, 0, 0xFFFFF, 0xF2, 0xC0); /* user data */

    /* TSS 位置先设为空，tss_init() 会调用 gdt_set_tss_entry() 填写 */
    gdt_set_entry(5, 0, 0, 0, 0);

    gdtr.limit = (uint16_t)(sizeof(gdt) - 1);
    gdtr.base = (uint32_t)(uintptr_t)&gdt[0];
    gdt_flush(&gdtr);
}
```

src/include/arch/gdt.h

```
enum {
    GDT_KERNEL_CODE_SEL = 0x08, /* 1 << 3     */
    GDT_KERNEL_DATA_SEL = 0x10, /* 2 << 3     */
    GDT_USER_CODE_SEL = 0x1B, /* (3 << 3) | RPL=3 */
    GDT_USER_DATA_SEL = 0x23, /* (4 << 3) | RPL=3 */
    GDT_TSS_SEL       = 0x28, /* 5 << 3       */
};

void gdt_init(void);
void gdt_set_tss_entry(uint32_t base, uint32_t limit);
```

思考 13.2

为什么 gdt_set_tss_entry() 要单独作为一个函数暴露出去，而不是直接在 gdt_init() 中完成 TSS 描述符的写入？

提示：*TSS 描述符需要知道 TSS 结构体的地址（base）和大小（limit），而 TSS 结构体定义在 tss.c 中。如果在 gdt_init() 就写入，需要在 gdt.c 中* ***#include "tss.h"****，增加了模块间的耦合。*

13.5 TSS 初始化

tss_init() 做 4 件事：清零、设置 SS0:ESP0、写 GDT 描述符、加载 TR。

src/kernel/arch/tss.c

```c
static tss_t g_tss;
extern uint32_t stack_top; /* boot.asm 中的内核栈顶 */

void tss_init(void) {
    /* 1. 清零 TSS (所有不用的字段 = 0) */
    kmemset(&g_tss, 0, sizeof(g_tss));

    /* 2. 设置 Ring 0 栈段选择子 */
    g_tss.ss0 = GDT_KERNEL_DATA_SEL; /* 0x10 */

    /* 3. 设置 Ring 0 栈顶指针 */
    g_tss.esp0 = (uint32_t)(uintptr_t)&stack_top;

    /* 4. I/O 位图偏移 = sizeof(tss), 表示没有 I/O 位图
     *    → Ring 3 执行 IN/OUT 指令会触发 #GP */
    g_tss.iomap_base = sizeof(tss_t);

    /* 5. 在 GDT[5] 写入 TSS 描述符 */
    gdt_set_tss_entry((uint32_t)(uintptr_t)&g_tss,
                      sizeof(tss_t) - 1); /* limit = 103 */

    /* 6. ltr 加载到 TR 寄存器 */
    ltr(GDT_TSS_SEL); /* 0x28 */
}
```

13.5.1 ltr 指令封装

```c
static inline void ltr(uint16_t sel) {
    __asm__ volatile("ltr %0" : : "r"(sel));
}
```

CPU 状态变化

`ltr 0x28` 执行后：

- TR 寄存器指向 GDT[5] 的 TSS 描述符
- CPU 内部缓存 TSS 的基址和 limit
- GDT[5] 的 type 自动从 `0x89`（Available）变为 `0x8B`（Busy）
- 之后发生 Ring 3 → Ring 0 切换时，CPU 会从 `g_tss.esp0` 获取内核栈

13.5.2 tss_set_kernel_stack() ——为进程切换预留

将来做进程切换时，每个进程有独立的内核栈。切换进程后需要更新 TSS.ESP0：

```
void tss_set_kernel_stack(uint32_t esp0) {
    g_tss.esp0 = esp0;
}
```

当前阶段只有一个内核栈，此函数暂时不会被调用，但接口先准备好。

13.5.3 初始化时机与顺序

src/kernel/core/kmain.c

```
gdt_init();   /* GDT 先就位 */
idt_init();   /* IDT 先就位（处理 Ring 3 异常） */
tss_init();   /* TSS 依赖 GDT，且需要 IDT 已安装 */
```

为什么？

为什么 tss_init() 必须在 gdt_init() 之后？
因为 tss_init() 会调用 gdt_set_tss_entry() 修改 GDT[5]，然后用 ltr 加载 TSS——ltr 会去 GDT 查找描述符。如果 GDT 尚未初始化（gdtr 没有指向有效表），ltr 会触发异常。

13.6 跳转到用户态：iret

目标：从 Ring 0 跳到 Ring 3 执行一段用户态代码。关键是构造一个 iret 帧——让 CPU 以为自己在从中断返回到 Ring 3。

13.6.1 iret 帧的构造

iret 从栈上依次弹出 EIP → CS → EFLAGS。当检测到目标 CS 的 RPL > 当前 CPL 时（跨特权级返回），还会额外弹出 ESP → SS。

所以我们需要从高到低依次 push 5 个值：

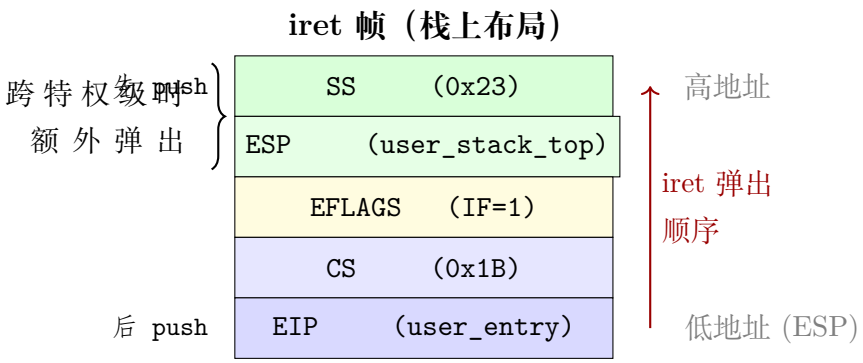

图 13.4: iret 帧布局——跨特权级返回时的 5 个栈元素

13.6.2 汇编实现：jump_to_ring3

src/kernel/arch/tss_flush.asm

```
USER_CODE_SEL equ 0x1B ; GDT[3] | RPL=3
USER_DATA_SEL equ 0x23 ; GDT[4] | RPL=3

; void jump_to_ring3(uint32_t eip, uint32_t esp3);
jump_to_ring3:
    mov eax, [esp + 4]  ; eax = eip (用户态入口)
    mov ecx, [esp + 8]  ; ecx = esp3 (用户态栈顶)

    ; 先切换 DS/ES/FS/GS 到用户数据段
    mov dx, USER_DATA_SEL
    mov ds, dx
    mov es, dx
    mov fs, dx
    mov gs, dx

    ; 构造 iret 帧
    push dword USER_DATA_SEL ; SS
    push ecx                 ; ESP
    pushfd                   ; EFLAGS
    or dword [esp], 0x200    ; 确保 IF=1
    push dword USER_CODE_SEL ; CS
    push eax                 ; EIP

    iret                     ; 跳转到 Ring 3!
```

注意

为什么要在 `iret` 前切换 DS/ES/FS/GS？

如果不切换，`iret` 后 DS 仍指向内核数据段（DPL=0），但 CPL 已变为 3。用户态代码第一次访问 DS 时，CPU 检查发现 $\max(\mathrm{CPL}=3, \mathrm{RPL}) > \mathrm{DPL}=0$，立即触发 #GP。

所以必须在 `iret` 之前把 DS/ES/FS/GS 切换到 DPL=3 的用户数据段（`0x23`）。

CPU 状态变化

`iret` 执行后：

- CPL 从 0 变为 3（用户态）
- CS 从 `0x08` 变为 `0x1B`（User Code）
- SS 从 `0x10` 变为 `0x23`（User Data）
- ESP 切换到用户态栈（参数 `esp3`）
- EIP 指向用户态代码入口（参数 `eip`）
- EFLAGS.IF = 1（中断保持打开，键盘和定时器仍然工作）
- 后续中断发生时，CPU 自动从 TSS 读取 SS0:ESP0 切回内核栈

13.6.3 为什么要确保 IF=1？

`pushfd` 保存的 EFLAGS 可能 IF=0（如果在关中断的上下文中调用）。`or dword [esp]`，`0x200` 强制设置 bit 9（IF），确保用户态运行时中断处于打开状态——否则键盘和定时器中断都不会触发，系统假死。

思考 13.3

如果忘记设置 IF=1，用户态代码执行了怎样的循环会导致系统完全无响应？

提示：任何循环都会，因为 IF=0 时所有可屏蔽中断（包括键盘 IRQ1）都被禁止，没有任何机制能打断 Ring 3 的循环回到内核。

13.7 PDE_USER 标志传播：两级页表的”与”逻辑

在实现过程中我们遇到了一个重要问题：即使 PTE 设置了 `PTE_USER`（U/S=1），用户态代码仍然触发了 #PF（protection violation）。

注意

x86 两级页表的权限检查是"与"逻辑：
要让用户态（Ring 3）访问一个页，**必须同时满足**：

- PDE 的 U/S 位 = 1（用户态可访问该 4MiB 区域）
- PTE 的 U/S 位 = 1（用户态可访问该 4KiB 页面）

即 PDE.US ∧ PTE.US。如果 PDE 的 U/S = 0，即使 PTE 的 U/S = 1，用户态也会 #PF。

之前的 `vmm_ensure_page_table()` 创建新页表时，PDE 固定设为 `PDE_PRESENT | PDE_WRITABLE`——没有 `PDE_USER`。这对内核映射（高半部分）是正确的，但对用户地址空间就不够了。

修复方案：在 `vmm_map_page()` 中，当 flags 包含 `PTE_USER` 时，同步设置 PDE 的 `PDE_USER` 位。

src/kernel/mm/vmm.c（修复）

```
int vmm_map_page(uint32_t virt, uint32_t phys, uint32_t flags) {
    /* ... 对齐检查、ensure_page_table ... */

    /* 当映射用户页时，PDE 也需要 USER 标志 */
    if (flags & PTE_USER) {
        g_kernel_pd.entries[pdi] |= PDE_USER;
    }

    /* 写入 PTE */
    pt->entries[pti] = (phys & ~0xFFFu) | (flags & 0xFFFu);
    /* ...TLB 刷新... */
}
```

用 `|=`(追加)而非 `=`(覆盖)是因为 PDE 的 flags 还包含 `PDE_PRESENT` 和 `PDE_WRITABLE`，我们只是额外添加第三个标志位。

思考 13.4

同一个页表可能同时包含内核页（PTE_USER=0）和用户页（PTE_USER=1）吗？如果可以，设置 PDE_USER=1 后，内核页的安全性是否会受到影响？
提示：PDE.US=1 只是放宽了"PDE 层面的限制"。最终权限还要看 PTE：如果某个 PTE 没有设 US=1，用户态仍然不能访问那一页。PDE 是上限，PTE 才是精确控制。

13.8 验证

我们通过 `ring3 test` shell 命令来验证整个 TSS + Ring 3 机制。

13.8.1 测试流程

src/kernel/cmds/cmd_ring3.c

```c
static int ring3_test(void) {
    /* 1. 分配物理页并映射到用户代码地址 */
    uint32_t code_phys = (uint32_t)(uintptr_t)pmm_alloc_page();
    vmm_map_page(USER_CODE_VADDR, code_phys,
                 PTE_PRESENT | PTE_USER);

    /* 2. 分配物理页并映射到用户栈地址 */
    uint32_t stack_phys = (uint32_t)(uintptr_t)pmm_alloc_page();
    vmm_map_page(USER_STACK_VADDR, stack_phys,
                 PTE_PRESENT | PTE_WRITABLE | PTE_USER);

    /* 3. 将 HLT 指令 (0xF4) 复制到用户代码页 */
    kmemcpy((void*)USER_CODE_VADDR,
            user_test_code, sizeof(user_test_code));

    /* 4. 注册 VMA (便于 #PF handler 诊断) */
    vma_add(USER_CODE_VADDR, ..., VMA_READ | VMA_EXEC, "user-code");
    vma_add(USER_STACK_VADDR, ..., VMA_READ | VMA_WRITE, "user-stack");

    /* 5. 跳转到 Ring 3 —— 不返回! */
    jump_to_ring3(USER_CODE_VADDR, USER_STACK_TOP);
}
```

地址选择：

- 用户代码页：0x00400000（4MiB 处，避开 NULL 区域）
- 用户栈页：0x00401000，栈顶 = 0x00402000（栈向低地址增长）

13.8.2 用户态测试代码

测试代码只有 3 字节：

```
0xF4       ; hlt — Ring 3 执行此指令触发 #GP
0xEB, 0xFE ; jmp $ — 无穷循环（安全网）
```

HLT 是特权指令——只有 Ring 0 可以执行。Ring 3 执行 HLT 时，CPU 会触发 #GP（General Protection Fault, vector 13）。

13.8.3 预期输出

```
> ring3 test

szy-kernel > ring3 test
[ring3] Preparing Ring 3 test...
[ring3] code page: virt=0x00400000 phys=0x001b1000
[ring3] stack page: virt=0x00401000 phys=0x001b3000 (top=0x00402000)
[ring3] test code copied (3 bytes): HLT instruction
[ring3] Jumping to Ring 3 (eip=0x00400000, esp=0x00402000)...
[ring3] Expected: #GP fault (HLT is privileged)

[isr] #GP General Protection vector=13 err=0x00000000 eip=0x00400000
[isr] Fault from Ring 3 (user mode)
[isr] User CS=0x001b SS=0x0023 ESP=0x00402000
Kernel panic: #GP General Protection
```

关键验证要点：

1. `Fault from Ring 3 (user mode)` ——ISR 正确识别异常来自用户态
2. `CS=0x001b` ——用户代码段选择子（GDT[3] | RPL=3）
3. `SS=0x0023` ——用户数据段选择子（GDT[4] | RPL=3）
4. `eip=0x00400000` ——故障发生在用户代码页的入口地址
5. `err=0x00000000` ——#GP 错误码为 0 表示常规保护违规

为什么？

为什么 ISR 能正确打印"Fault from Ring 3"？
当 #GP 从 Ring 3 触发时，CPU 自动执行以下操作：

1. 从 TSS 读取 SS0:ESP0，切换到内核栈
2. 在内核栈上压入旧的 SS/ESP/EFLAGS/CS/EIP 和 error code
3. 跳转到 IDT[13] 的处理程序（我们的 `isr13`）

ISR 的 `isr_common_stub` 把这些值打包成 `regs_t` 结构体传给 C。C 代码检查 `r->cs & 0x3`：CS 的低 2 位 = RPL = 异常发生时的 CPL。如果 RPL=3，就打

印"Ring 3"。
结构体末尾的 `user_esp` 和 `user_ss` 字段在跨特权级中断时自动出现在栈上(CPU 额外压入)，同特权级时不存在。

13.9 本章小结与练习

13.9.1 本章小结

本章完成了从 Ring 0 到 Ring 3 的完整通路：

1. **GDT 扩展**：新增 User Code（`0x1B`）、User Data（`0x23`）和 TSS（`0x28`）三个描述符
2. **TSS 初始化**：设置 SS0:ESP0，让 CPU 知道" 回到 Ring 0 时用哪个栈"
3. **`ltr` 加载**：告诉 CPU TSS 描述符在 GDT 中的位置
4. **`iret` 跳转**：构造假的中断返回帧，从 Ring 0 切换到 Ring 3
5. **PDE_USER 传播**：修复两级页表的" 与" 逻辑，确保用户页可访问
6. **ISR 增强**：检测跨特权级异常，打印用户态 CS/SS/ESP

目前用户态代码无法请求内核服务——执行任何特权操作都会 #GP。下一章实现**系统调用机制**（`syscall_ops_t`），在 Ring 3 和 Ring 0 之间建立受控通信通道。

13.9.2 新增文件清单

文件	说明
`src/include/arch/tss.h`	TSS 结构体 + 段选择子枚举 + API 声明
`src/kernel/arch/tss.c`	TSS 初始化 + `ltr` + `tss_set_kernel_stack`
`src/kernel/arch/tss_flush.asm`	`jump_to_ring3` 汇编（iret 帧构造）
`src/kernel/cmds/cmd_ring3.c`	`ring3 test` shell 命令

13.9.3 修改文件清单

文件	变更
src/include/arch/gdt.h	新增 User Code/Data/TSS 选择子枚举 + gdt_set_tss_entry 声明
src/kernel/arch/gdt.c	GDT 扩展到 6 项 + gdt_set_tss_entry() 实现
src/kernel/arch/idt.c	regs_t 添加 user_esp/user_ss + Ring 3 异常检测
src/kernel/mm/vmm.c	vmm_map_page 添加 PDE_USER 传播
src/kernel/core/kmain.c	添加 tss_init() 调用
src/kernel/core/shell.c	注册 ring3 命令
src/boot/boot.asm	导出 stack_top 符号

13.9.4 练习

练习 1：Ring 3 读取内核地址

修改 user_test_code，把 HLT 替换为读取内核地址 0xC0100000 的指令：

```
mov eax, [0xC0100000] ; 尝试读取内核页
```

预期会触发什么异常？错误码的各位分别是什么含义？

练习 2：Ring 3 写用户栈

修改 user_test_code，先往用户栈 push 一个值，再执行 HLT：

```
push 0x12345678 ; 往用户栈写入
hlt             ; 然后触发 #GP
```

验证 push 不会触发异常（栈页有 PTE_WRITABLE），只有 HLT 才会 #GP。

练习 3：iomap_base 实验

将 tss.iomap_base 从 sizeof(tss_t) 改为 0，再从 Ring 3 执行 in al, 0x60（读 PS/2 键盘端口）。观察行为变化：是否仍然触发 #GP？理解 I/O 权限位图的作用。

提示：iomap_base = 0 意味着 I/O 位图从 TSS 偏移 0 开始，但那不是有效的位图（是 prev_tss 字段），所以行为取决于该内存位置的值。

Chapter 14

系统调用

14.1 本章目标

- 理解系统调用的本质：用户态通过受控入口请求内核服务
- 掌握 i386 系统调用寄存器约定：EAX=syscall nr, EBX~EDI=args
- 设计可插拔 `syscall_ops_t` 接口（与 `pmm_ops_t`/`vma_ops_t` 同一模式）
- 实现 dispatch 层 + syscall table（O(1) 查表分发）
- 注册第一批 syscall handler：`sys_write`/`sys_exit`/`sys_brk`
- 在 `kconfig.h` 预留 `KCONFIG_SYSCALL_BACKEND` 供后续后端切换

设计决策

本章只搭建系统调用的**框架**——接口、dispatch、syscall table、handler 占位。真正的系统调用**入口**（汇编 stub + IDT/MSR 配置）在下一节（D-3: `int 0x80` 后端）实现。框架先行的好处是：后端只需关注" 如何从 Ring 3 切换到 Ring 0 并提取寄存器参数"，dispatch 和 handler 逻辑完全复用。

14.2 概念：为什么需要系统调用

上一章我们成功从 Ring 0 跳转到了 Ring 3。然而用户态代码几乎什么都做不了——不能输出字符（`out` 是特权指令）、不能停机（`hlt` 会 #GP）、不能访问内核内存（PTE.US=0 的页会触发 #PF）。

那用户程序怎么打印 "Hello World"？答案就是**系统调用**（system call）。

为什么？

系统调用是用户态进入内核的**唯一受控入口**。与普通函数调用不同，它涉及：

1. **特权级切换**：CPL 从 3 升到 0，CPU 自动换栈
2. **参数验证**：内核必须检查用户传入的指针是否合法
3. **安全审计**：内核决定"允许做什么"而非用户

类比：系统调用就像银行柜台——你坐在玻璃窗外面（Ring 3）填单子，柜员（Ring 0）审核后帮你执行操作。你不能直接进保险库。

14.2.1 系统调用 vs 普通函数调用

初学者容易把 `write()` 当成普通的 C 函数调用。实际上用户态的 `write()` 是一个**薄封装**（wrapper），内部执行的是 `int $0x80` 或 `sysenter` 指令，触发 CPU 的特权级切换机制。

项目	普通函数调用	系统调用
特权级	不变（Ring 3 → Ring 3）	切换（Ring 3 → Ring 0）
栈	同一个用户栈	CPU 自动切换到内核栈（TSS.ESP0）
开销	几纳秒（`call`+`ret`）	数百纳秒（中断流程/MSR 切换）
参数传递	栈或寄存器（cdecl/fastcall）	寄存器（避免访问不可信用户栈）
安全	无检查	内核验证每个参数

14.2.2 三种系统调用入口机制

x86 提供了三种从 Ring 3 进入 Ring 0 的机制，它们的目的相同但性能和复杂度不同：

1. `int N`（软中断）——最传统的方式。Linux i386 早期使用 `int 0x80`。CPU 查 IDT[0x80]，走完整的中断流程（保存上下文 → 切换栈 → 执行 handler）。优点：简单、调试友好；缺点：比较慢（需要查 IDT + 保存完整帧）。
2. `sysenter/sysexit`（Intel 快速系统调用）——Pentium II 引入。通过 MSR（Model Specific Register）硬编码入口点，跳过 IDT 查表和完整帧保存。显著（约 10×）快于 `int`，但编程复杂度更高。
3. `syscall/sysret`（AMD64）——64 位 long mode 专用。本项目是 32 位 i386，暂不涉及。

设计决策

我们将 `int 0x80` 和 `sysenter` 设计为可切换的**后端**。本章先搭框架（接口 + dispatch + table），D-3 实现 `int 0x80`，D-4 实现 `sysenter`。切换只需改 `KCONFIG_SYSCALL_BACKEND`。

14.2.3 系统调用全路径概览

从用户态发起一个 `write(1, "hello", 5)` 到串口看到输出，经历以下步骤：

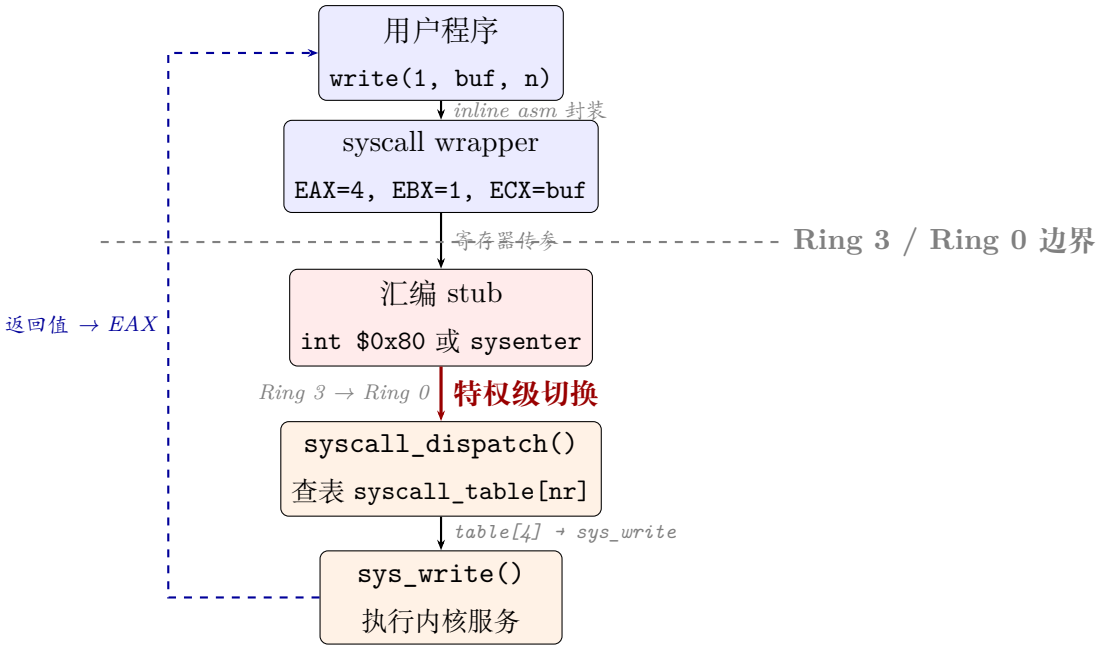

图 14.1: 系统调用全路径：用户态 → 汇编 stub → 特权级切换 → 内核 handler → 返回

这条路径中，本章负责中间的"dispatch 层 + handler" 部分。汇编 stub 和特权级切换由后端（`int 0x80` / `sysenter`）在下一章实现。

14.3 调用约定：寄存器传参

系统调用通过寄存器传递参数，这和普通的 C cdecl 函数调用（通过栈）不同。

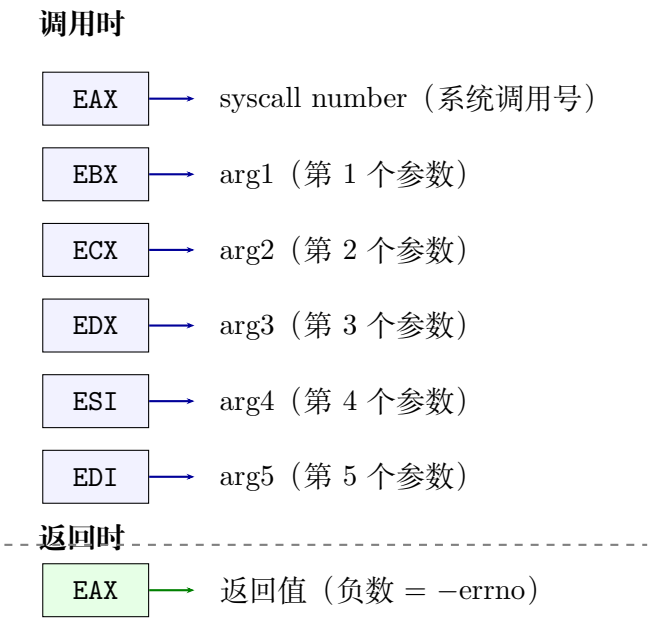

图 14.2: i386 系统调用寄存器约定（与 Linux 一致）

为什么？

为什么用寄存器而不是栈传参?

`int 0x80` 触发特权级切换时，CPU 会从 TSS 读取 SS0:ESP0 并自动切换到内核栈。此时用户栈指针（SS3:ESP3）已被保存到内核栈上，但内核**不应该信任用户栈内容**——恶意程序可能伪造栈上的数据。

寄存器在特权级切换前后由 CPU 保持不变（除了 ESP/SS 被换掉），是最安全、最直接的传参方式。Linux i386 从 1.0 到 2.6 一直使用这套约定。

14.3.1 参数快照结构体：`syscall_regs_t`

后端的汇编 stub 从寄存器中提取参数后，打包成一个结构体传给 C 的 dispatch 函数。这样 dispatch 层和具体 handler 都不依赖特定后端的寄存器布局。

src/include/kernel/syscall.h

```
typedef struct syscall_regs {
    uint32_t nr;      /* EAX: 系统调用号 */
    uint32_t arg1;    /* EBX: 参数 1 */
    uint32_t arg2;    /* ECX: 参数 2 */
    uint32_t arg3;    /* EDX: 参数 3 */
    uint32_t arg4;    /* ESI: 参数 4 */
    uint32_t arg5;    /* EDI: 参数 5 */
} syscall_regs_t;
```

思考 14.1

为什么不直接把 `regs_t`（ISR 的寄存器快照）传给 syscall handler?
提示：`regs_t` 包含了所有通用寄存器和段寄存器（共 17 个字段），其中大部分对系统调用无用。更重要的是，`regs_t` 的布局和汇编 stub 的 push 顺序绑定——不同后端（int 0x80 vs sysenter）的栈布局不同。`syscall_regs_t` 是后端无关的"参数传递契约"。

14.3.2 系统调用号定义

每个系统调用都有一个唯一的编号。用户态把编号放到 EAX，内核查表分发。我们的编号参考 Linux i386 但不强求完全一致——只实现需要的子集。

src/include/kernel/syscall.h

```
#define SYS_EXIT 1      /* 终止当前进程 */
#define SYS_WRITE 4     /* 写数据到文件描述符 */
#define SYS_BRK  45     /* 调整进程数据段末尾 */

#define SYSCALL_MAX 256 /* syscall table 容量上限 */
```

为什么？

为什么预留 0 号不使用?
如果用户态忘记设置 EAX（或 EAX 被意外清零），`syscall_table[0] = NULL` 会让 dispatch 返回 −ENOSYS，而不是误调某个 handler。这是一种防御性编程——让常见的 bug 产生可预测的错误。

14.4 可插拔接口：syscall_ops_t

与 `pmm_ops_t`（第 8 章）、`heap_ops_t`（第 11 章）、`vma_ops_t`（第 12 章）完全相同的"dispatch + 后端" 模式。不同的系统调用入口机制被抽象为后端，共享同一套 dispatch 层和 syscall table。

src/include/kernel/syscall.h

```
typedef struct syscall_ops {
    const char* name;    /* "int0x80", "sysenter" */

    /*
     * init -- 初始化后端
     *
     * int 0x80 后端：在 IDT[0x80] 安装 DPL=3 中断门
```

```
     * sysenter 后端：配置 IA32_SYSENTER_CS/EIP/ESP MSR
     */
    void (*init)(void);
} syscall_ops_t;
```

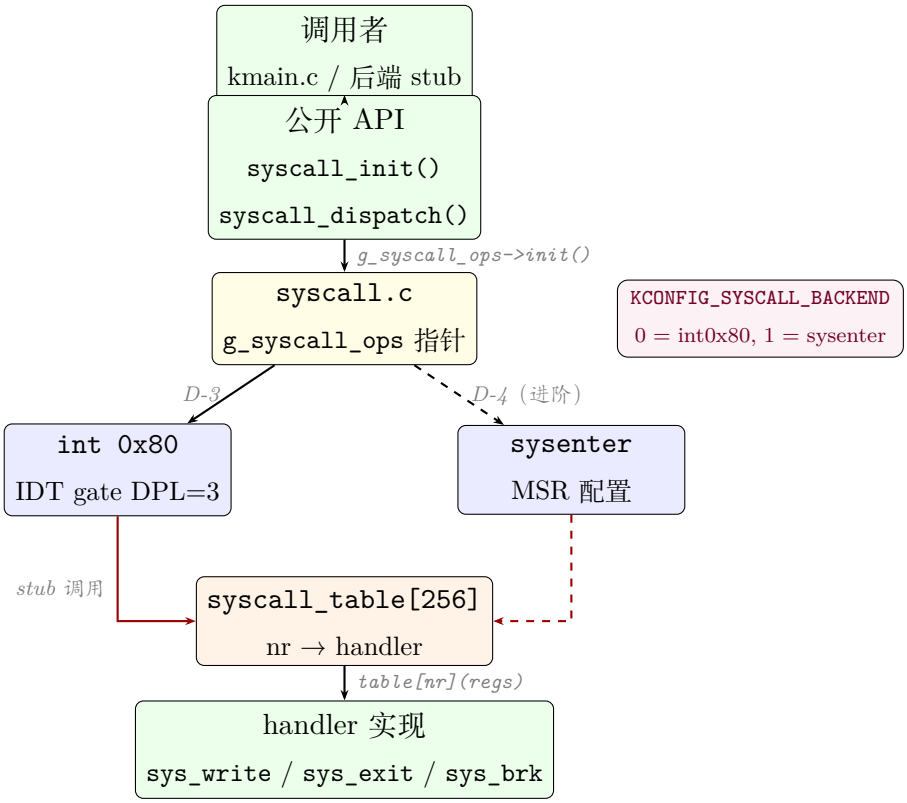

图 14.3: syscall_ops_t 可插拔后端架构——后端负责入口，dispatch 负责分发

设计决策

为什么 syscall_ops_t 只有一个 init 函数指针？

与 vma_ops_t（7 个函数指针）不同，系统调用后端只需做一件事：**设置入口点**。一旦入口安装完毕，后续所有系统调用都走同一条路径：用户态 → 汇编 stub → syscall_dispatch() → handler。

后端不需要 dispatch 或 handle 函数指针，因为汇编 stub 直接调用 dispatch 层的 C 函数。将来如果需要后端特定的 teardown（例如 MSR 清理），可以添加 fini 函数指针——但现在遵循 YAGNI 原则，不提前设计。

14.4.1 后端注册 API

src/include/kernel/syscall.h

```
/* 注册后端（在 syscall_init 之前调用） */
void syscall_register_backend(const syscall_ops_t* ops);
```

```

/* 返回当前后端名称，NULL=未注册 */
const char* syscall_backend_name(void);

/* 系统调用子系统是否已初始化 */
int syscall_is_ready(void);
```

14.4.2 handler 函数签名

每个具体的系统调用（如 `sys_write`）实现为此签名的函数，注册到 syscall table 中：

```
typedef int32_t (*syscall_handler_t)(const syscall_regs_t* regs);
```

- 参数：`syscall_regs_t` 包含了调用号和最多 5 个参数
- 返回值：由后端写回用户态 EAX。负数表示 $-\text{errno}$（如 $-38 = -\text{ENOSYS}$）

14.4.3 注册单个 handler

```
/*
 * syscall_register -- 注册/替换一个 syscall handler
 *
 * @param nr      系统调用号（0 < nr < SYSCALL_MAX）
 * @param handler 处理函数
 * @return        0=成功，-1=nr 越界
 */
int syscall_register(uint32_t nr, syscall_handler_t handler);
```

这个 API 不仅供内核初始化使用，将来用户态驱动（微内核架构）也可以通过系统调用注册新的 handler——实现内核服务的动态扩展。

14.5 Dispatch 层：`syscall.c` 实现

`syscall.c` 是系统调用子系统的核心——持有 syscall table，实现后端注册、handler 注册、和调用分发。

14.5.1 syscall table

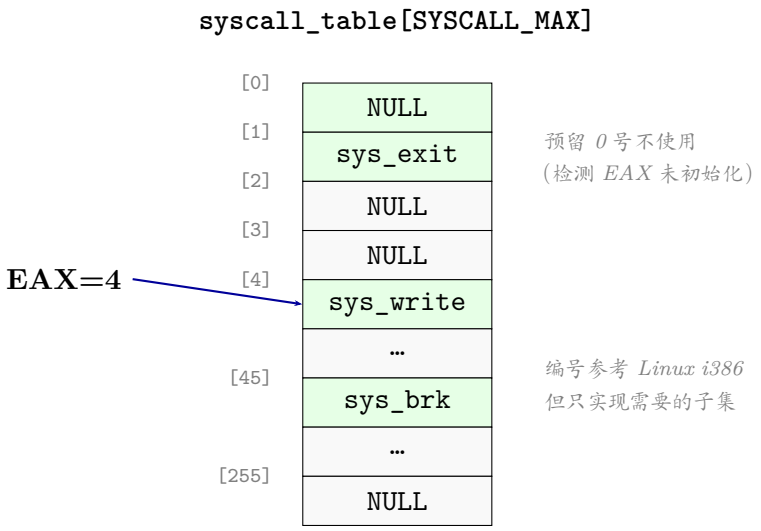

图 14.4: syscall table：系统调用号直接索引函数指针数组

src/kernel/core/syscall.c

```
static syscall_handler_t syscall_table[SYSCALL_MAX];

/* 当前注册的后端 */
static const syscall_ops_t* g_syscall_ops = NULL;
static int g_syscall_ready = 0;
```

为什么？

为什么用静态数组而非链表或哈希表?

1. 系统调用号是小整数（通常 < 256），数组索引 $O(1)$——没有比这更快的了
2. 无动态内存分配——启动早期 kmalloc 可能还没初始化
3. 256 个指针只占 1 KiB，内存开销可忽略
4. 未注册的 slot 为 NULL，dispatch 时一次判断即可

14.5.2 后端注册

```
void syscall_register_backend(const syscall_ops_t* ops) {
    g_syscall_ops = ops;
}

```

```c
const char* syscall_backend_name(void) {
    return g_syscall_ops ? g_syscall_ops->name : NULL;
}

int syscall_is_ready(void) {
    return g_syscall_ready;
}
```

这与 vma_register_backend() 完全同一套模式——一行赋值即完成注册。

14.5.3 handler 注册

```c
int syscall_register(uint32_t nr, syscall_handler_t handler) {
    if (nr == 0 || nr >= SYSCALL_MAX) {
        printk("[syscall] register: invalid nr=%u\n", nr);
        return -1;
    }
    syscall_table[nr] = handler;
    return 0;
}
```

注意

nr == 0 被拒绝——0 号保留为" 未初始化 EAX" 的安全网。nr >= SYSCALL_MAX 防止数组越界。这两个检查在系统边界上是必要的，即使当前只有内核自己调用 syscall_register。

14.5.4 syscall_dispatch：调用分发

后端的汇编 stub 从寄存器提取参数，打包成 syscall_regs_t，然后调用此函数。这是系统调用路径上最关键的 C 函数。

```c
#define ENOSYS 38

int32_t syscall_dispatch(const syscall_regs_t* regs) {
    if (!regs) {
        return -ENOSYS;
    }

    uint32_t nr = regs->nr;

```

```
    if (nr >= SYSCALL_MAX || !syscall_table[nr]) {
        printk("[syscall] unknown syscall nr=%u\n", nr);
        return -ENOSYS;
    }

    return syscall_table[nr](regs);
}
```

逻辑极简：

1. 边界检查（nr 不超过 table 大小）
2. NULL 检查（该 slot 是否注册了 handler）
3. 调用 handler，返回结果

思考 14.2

为什么返回 −ENOSYS（−38）而不是 −1？
提示：这是 POSIX 约定。ENOSYS 表示"Function not implemented"，是 Linux 内核对未实现系统调用的标准返回值。遵循这个约定，将来移植 GCC/libc 时用户态 errno 能正确设置。

14.6 第一批 syscall handler

本阶段实现三个 handler 的初始版本。它们在 D-2 阶段是**占位实现**（stub），功能有限但足以验证 dispatch 路径正确。D-3（int 0x80 后端）完成后，这些 handler 会被真正的 Ring 3 代码所调用。

14.6.1 sys_exit：终止进程

src/kernel/core/syscall.c

```
/*
 * sys_exit -- 终止当前进程
 *
 * arg1 (EBX) = exit status
 *
 * 当前没有进程管理，exit 只能 halt。
 * 将来 D-7/D-8 会做 ZOMBIE 状态转换和资源回收。
 */
static int32_t sys_exit(const syscall_regs_t* regs) {
    printk("[syscall] exit(status=%d)\n", (int)regs->arg1);
```

```

    for (;;) {
        __asm__ volatile("hlt");
    }

    return 0; /* unreachable */
}
```

sys_exit 目前直接 halt——因为还没有进程管理，没有”下一个进程”可以调度。将来实现 PCB 和调度器后，exit 会将进程状态设为 ZOMBIE 并释放资源。

14.6.2 sys_write：写数据

```
/*
 * sys_write -- 写数据到文件描述符
 *
 * arg1 (EBX) = fd     (当前只支持 1=stdout, 2=stderr)
 * arg2 (ECX) = buf    (用户态缓冲区地址)
 * arg3 (EDX) = count  (字节数)
 *
 * 返回值 = 实际写入字节数, -1=错误
 */
static int32_t sys_write(const syscall_regs_t* regs) {
    uint32_t fd  = regs->arg1;
    uint32_t buf = regs->arg2;
    uint32_t count = regs->arg3;

    /* 只接受 stdout(1) 和 stderr(2) */
    if (fd != 1 && fd != 2) {
        return -1;
    }

    /* 安全检查: buf 必须来自用户空间 */
    if (buf >= 0xC0000000u) {
        printk("[syscall] write: bad user pointer 0x%08x\n", buf);
        return -1;
    }

    /* 上限截断, 防止恶意大 count */
    if (count > 4096) {
```

```
        count = 4096;
    }

    const char* p = (const char*)(uintptr_t)buf;
    for (uint32_t i = 0; i < count; i++) {
        printk("%c", p[i]);
    }

    return (int32_t)count;
}
```

注意

用户指针安全检查是系统调用中最重要的安全措施之一。

`buf >= 0xC0000000` 是粗略的检查——内核空间从 `0xC0000000` 开始，用户态缓冲区地址不应该落在这个范围内。如果恶意用户程序传入一个内核地址，`sys_write` 会拒绝而不是泄露内核数据。

将来实现 VFS 后，这里还需要更精细的检查：验证 `[buf, buf+count)` 整个范围都在合法的用户 VMA 中。

14.6.3 sys_brk：堆管理

```
/*
 * sys_brk -- 调整进程数据段末尾
 *
 * arg1 (EBX) = new_brk (0 = 查询当前 brk)
 * 返回值 = 当前 brk 地址
 *
 * 当前只返回占位值。将来 F-6 (mmap) 会和 VMA 集成。
 */
static int32_t sys_brk(const syscall_regs_t* regs) {
    (void)regs;
    printk("[syscall] brk(0x%08x) -- stub\n", regs->arg1);
    return 0x00400000;
}
```

`brk` 是 Unix 传统的堆管理方式——移动数据段末尾来分配/释放内存。用户态的 `malloc` 内部就是调用 `brk`（小分配）或 `mmap`（大分配）。

14.7 初始化：syscall_init()

syscall_init() 做三件事：清空 table、注册 handler、调用后端 init。

src/kernel/core/syscall.c

```
void syscall_init(void) {
    /* 1. 清空 syscall table */
    for (unsigned i = 0; i < SYSCALL_MAX; i++) {
        syscall_table[i] = NULL;
    }

    /* 2. 注册内置 syscall handler */
    syscall_register(SYS_EXIT, sys_exit);
    syscall_register(SYS_WRITE, sys_write);
    syscall_register(SYS_BRK, sys_brk);

    printk("[syscall] table: %u handlers registered "
           "(exit=%u, write=%u, brk=%u)\n",
           3, SYS_EXIT, SYS_WRITE, SYS_BRK);

    /* 3. 初始化后端（安装 IDT gate 或配置 MSR） */
    if (g_syscall_ops) {
        printk("[syscall] backend: %s\n", g_syscall_ops->name);
        g_syscall_ops->init();
    } else {
        printk("[syscall] no backend registered "
               "(dispatch only)\n");
    }

    g_syscall_ready = 1;
    printk("[syscall] init ok\n");
}
```

14.7.1 kmain.c 集成

syscall_init() 在 VMA 初始化之后调用。这个顺序有讲究：

src/kernel/core/kmain.c

```
        vma_init();

        if (vma_is_ready()) {
            vma_add(KERNEL_VIRT_OFFSET, vmm_direct_map_end(),
```

```
                VMA_READ | VMA_WRITE | VMA_EXEC,
                "direct-map");
        vma_add(KHEAP_START,
                KHEAP_START + KCONFIG_HEAP_INITIAL_PAGES
                            * VMM_PAGE_SIZE,
                VMA_READ | VMA_WRITE, "kheap");
    }

    /*
     * Stage D-2: 系统调用子系统初始化
     *
     * 在 VMA 之后，因为 sys_write 需要通过 VMA
     * 验证用户态指针的合法性。
     */
    syscall_init();
```

为什么？

为什么 syscall_init 要在 VMA 之后?
sys_write 需要验证用户传入的 buf 指针不在内核空间。将来更精确的检查会查询 VMA——确认 [buf, buf+count) 落在合法的用户 VMA 中。如果 VMA 还没初始化，这些检查就无法执行。
另一方面，syscall_init 不依赖后端——即使没有注册后端，dispatch 层也能正常工作（只是没有用户态入口点）。

14.7.2 kconfig.h：后端选择

src/include/kernel/kconfig.h

```
/*
 * 系统调用后端
 *
 *   0 = int0x80 -- 传统软中断 (IDT[0x80] DPL=3)
 *   1 = sysenter -- Intel 快速系统调用 (MSR 配置)
 */
#define KCONFIG_SYSCALL_BACKEND 0
```

目前还没有后端实现，所以 kmain.c 中暂不调用 syscall_register_backend()。D-3 实现 int 0x80 后端后，会在 kmain.c 中添加基于 KCONFIG_SYSCALL_BACKEND 的选择逻辑，和 PMM/VMA 的后端选择完全一致。

14.8 验证

D-2 阶段没有后端，用户态代码还不能真正触发系统调用。我们用两种方式验证框架的正确性。

14.8.1 QEMU 启动日志

编译并启动内核，在串口输出中应看到：

```
$ QEMU 启动输出

[vma] backend: sorted-array
[vma] init ok
[syscall] table: 3 handlers registered (exit=1, write=4, brk=45)
[syscall] no backend registered (dispatch only, no user-mode entry point)
[syscall] init ok
```

关键点：

- 三个 handler 成功注册（编号正确）
- 明确报告"no backend"——提醒我们 D-3 还没实现
- 已有测试（`pmm test`/`heap test`/`vma test`）全部回归通过

14.8.2 dispatch 路径内部验证

虽然用户态还不能触发系统调用，但我们可以在内核态直接调用 `syscall_dispatch()` 来验证 table 分发逻辑：

```
/* 验证代码（可在 kmain.c 中临时添加） */

/* 测试 1: 有效调用号 → handler 被调用 */
syscall_regs_t r = { .nr = SYS_WRITE, .arg1 = 1,
                     .arg2 = (uint32_t)"test\n",
                     .arg3 = 5 };
int32_t ret = syscall_dispatch(&r);
/* 预期: 串口输出 "test", ret = 5 */

/* 测试 2: 无效调用号 → 返回 -ENOSYS */
syscall_regs_t bad = { .nr = 999 };
ret = syscall_dispatch(&bad);
/* 预期: printk "[syscall] unknown", ret = -38 */
```

注意

上面的直接调用只是临时验证手段。正式流程中，`syscall_dispatch()` 只应被后端的汇编 stub 调用（从 Ring 3 触发的路径）。验证完毕后删除临时代码。

14.9 后端预告：`int 0x80` 与 `sysenter`

本章搭建了系统调用的完整框架，但用户态还不能真正触发系统调用——因为没有安装入口点。接下来两节将实现两个后端：

14.9.1 `int 0x80`（D-3）

传统的软中断方式。需要：

1. 在 IDT 中安装 `gate[0x80]`，设置 **DPL=3**（`type_attr = 0xEE`，允许 Ring 3 触发）
2. 编写汇编 stub：保存寄存器 → 加载内核段 → 从寄存器提取参数 → 打包 `syscall_regs_t` → 调用 `syscall_dispatch()` → 返回值写入 EAX → 恢复寄存器 → `iret`
3. 编写用户态 inline asm wrapper（`syscall1`/`syscall2`/`syscall3`）
4. 验证：Ring 3 执行 `write(1, "hello", 5)` → 串口看到输出

14.9.2 `sysenter`（D-4，进阶）

Intel 快速系统调用路径。需要：

1. 配置三个 MSR：
   - `IA32_SYSENTER_CS` (`0x174`) = 内核代码段
   - `IA32_SYSENTER_ESP` (`0x175`) = 内核栈顶
   - `IA32_SYSENTER_EIP` (`0x176`) = 内核入口函数
2. 编写汇编入口（`sysenter` 不保存返回地址，用户端需用 ECX/EDX 传递）
3. 通过 `KCONFIG_SYSCALL_BACKEND=1` 切换

两个后端共享本章实现的 dispatch 层和 syscall table，只有入口机制不同——这就是可插拔架构的价值。

14.10 本章小结与练习

14.10.1 本章小结

本章完成了系统调用的**框架层**:

1. **概念**: 理解系统调用是用户态请求内核服务的唯一受控入口，涉及特权级切换、参数验证、安全审计
2. **调用约定**:EAX=syscall nr, EBX~EDI=arg1~arg5,返回值在 EAX(负数 = −errno), 与 Linux i386 ABI 一致
3. **可插拔接口**: `syscall_ops_t` (name/init)，与 `pmm_ops_t`/`vma_ops_t` 同一模式
4. **dispatch 层**: `syscall_table[256]` 静态数组，`syscall_dispatch()` 查表分发，未注册返回 −ENOSYS
5. **handler 占位**:`sys_exit`(halt)、`sys_write`(串口输出 + 用户指针校验)、`sys_brk`(占位)
6. **配置**: `KCONFIG_SYSCALL_BACKEND` 预留后端切换

有了这个框架，下一章只需实现一个”入口”(`int 0x80` 后端的汇编 stub + IDT 配置)，用户态代码就能调用 `write`、`exit` 等系统调用了。

14.10.2 新增文件清单

文件	说明
`src/include/kernel/syscall.h`	`syscall_ops_t` 接口 + 调用号 + `syscall_regs_t` + API
`src/kernel/core/syscall.c`	dispatch 层 + syscall table + 内置 handler

14.10.3 修改文件清单

文件	变更
`src/include/kernel/kconfig.h`	新增 `KCONFIG_SYSCALL_BACKEND`
`src/kernel/core/kmain.c`	VMA 之后添加 `syscall_init()` 调用

14.10.4 练习

练习 1：添加 sys_getpid 占位

在 `syscall.h` 中定义 `SYS_GETPID = 20`（和 Linux 一致），实现一个 handler 始终返回 1（PID 1 = init 进程），注册到 syscall table 中。在内核态直接调用 `syscall_dispatch({.nr=20})` 验证返回值。

练习 2：统计 syscall 调用次数

在 `syscall.c` 中添加 per-syscall 计数器数组 `syscall_count[SYSCALL_MAX]`。每次 dispatch 成功时 `++syscall_count[nr]`。添加一个 `syscall_dump_stats()` 函数打印非零计数。
思考：这个统计功能对调试和性能分析有什么帮助？

练习 3：对比 int 0x80 与 call 的开销

查阅 Intel 软件开发手册，比较以下两条指令在 Pentium 4 上的时钟周期：

- `int 0x80`（软中断，经过 IDT + 特权级切换）
- `call [addr]`（普通间接调用，无特权级切换）

为什么 `sysenter` 的引入是重要的性能优化？

练习 4：安全漏洞分析

如果 `sys_write` 中删掉 `buf >= 0xC0000000` 的检查，恶意用户程序可以传入什么地址来泄露内核数据？
提示：考虑 `write(1, 0xC0100000, 1024)` 会做什么——它会把内核代码段的 1024 字节输出到串口。

14.11 int 0x80 后端实现（D-3）

在第 14.9 节的预告中，我们描述了 `int 0x80` 后端的设计意图。D-3 将它完整落地：三个新文件协同工作，让 Ring 3 代码能够真正执行系统调用。

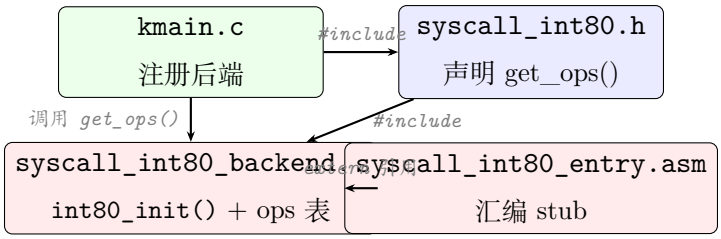

图 14.5: `int 0x80` 后端的文件组成

14.11.1 IDT 门安装：`idt_install_gate` 与 `type_attr`

第一步是在 IDT 的第 `0x80` 槽安装一个允许 Ring 3 触发的中断门。

`type_attr` 字节：`0xEE`

IDT 门描述符中有一个关键的 `type_attr` 字节，编码了”谁能触发、进入时是否关中断”两个属性。`int 0x80` 使用的值是 `0xEE`：

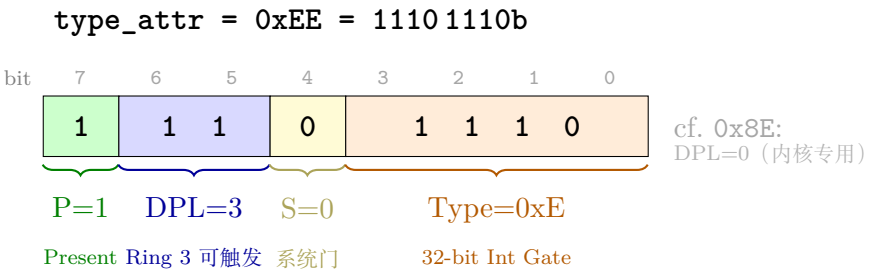

图 14.6: `type_attr = 0xEE` 的位域解析（DPL=3，32-bit Interrupt Gate）

`bit 7` $\mathbf{P = 1}$ 描述符有效（Present）。若 P=0，CPU 触发 #NP（Segment Not Present）。

`bits 6--5` $\mathbf{DPL = 11_2 = 3}$ 允许 Ring 3 的软件 `int n` 指令触发此门。若 DPL=0，Ring 3 执行 `int 0x80` 时 CPU 检查 CPL(3) ≤ DPL(0) 不成立，直接触发 #GP。

`bit 4` $\mathbf{S = 0}$ 系统描述符（Gate 类型），而非代码/数据段。

`bits 3--0` $\mathbf{Type = 1110_2 = 0xE}$ 32-bit Interrupt Gate。进入处理程序时 CPU 自动清除 EFLAGS.IF（关中断），防止 syscall 处理期间被硬件中断打断。

对比内核异常/IRQ 使用的 `0x8E`：两者 Type 字段相同，只有 DPL 不同——`0x8E` 的 DPL=0，仅内核态可软件触发。

注意

Interrupt Gate vs Trap Gate

选择 Interrupt Gate（Type=`0xE`，进入时清 IF）而非 Trap Gate（Type=`0xF`，保

持 IF）是出于当前阶段的简化考量。关中断意味着 syscall 处理期间不会被时钟中断打断，避免了不完整的内核栈被调度器看到的问题。
Linux 的 `int 0x80` 实际使用 Trap Gate 以支持内核抢占。当本书引入内核线程调度时，可将 `0xEE` 改为 `0xEF` 切换到 Trap Gate。

idt_install_gate 接口

为了让后端模块在 `idt_init()` 完成后仍能动态安装向量，我们在 `idt.h` 中新增了一个公开接口：

src/include/arch/idt.h

```
void idt_install_gate(uint8_t vector, void (*handler)(void),
                      uint16_t selector, uint8_t type_attr);
```

实现上只是调用原有的 `static idt_set_gate()`——把它从模块内部提升为可导出符号。因为 IDTR 指向的是同一片 `idt[]` 数组，修改表项后 CPU 下次查该向量时就会用新值，无需重新执行 `lidt`。

14.11.2 汇编入口 Stub：syscall_int80_entry

汇编 stub 是 IDT 门直接跳到的第一段内核代码。它的职责是：在内核栈上构造 `syscall_regs_t` 结构体 → 切换数据段 → 调用 C 的 dispatch 函数 → 恢复现场 → `iret` 返回用户态。

进入时的 CPU 状态

Ring 3 执行 `int 0x80` 之后、汇编第一条指令运行之前，CPU 已完成：

1. 从 TSS 读取 `SS0:ESP0`，切换到内核栈（来自第 13 章配置的 TSS）
2. 向内核栈依次压入：`SS_user` / `ESP_user` / `EFLAGS` / `CS_user` / `EIP_user`（完整跨特权级帧）
3. 清除 EFLAGS.IF（Interrupt Gate 自动关中断）
4. 将 CS 设置为 IDT gate 中的 selector（内核代码段 `0x08`），跳转到 stub

注意：DS/ES/FS/GS **仍然是用户态的值**（`0x23`），必须由 stub 手动切换。

内核栈布局快照

下图展示了即将调用 `syscall_dispatch` 时内核栈的完整状态：

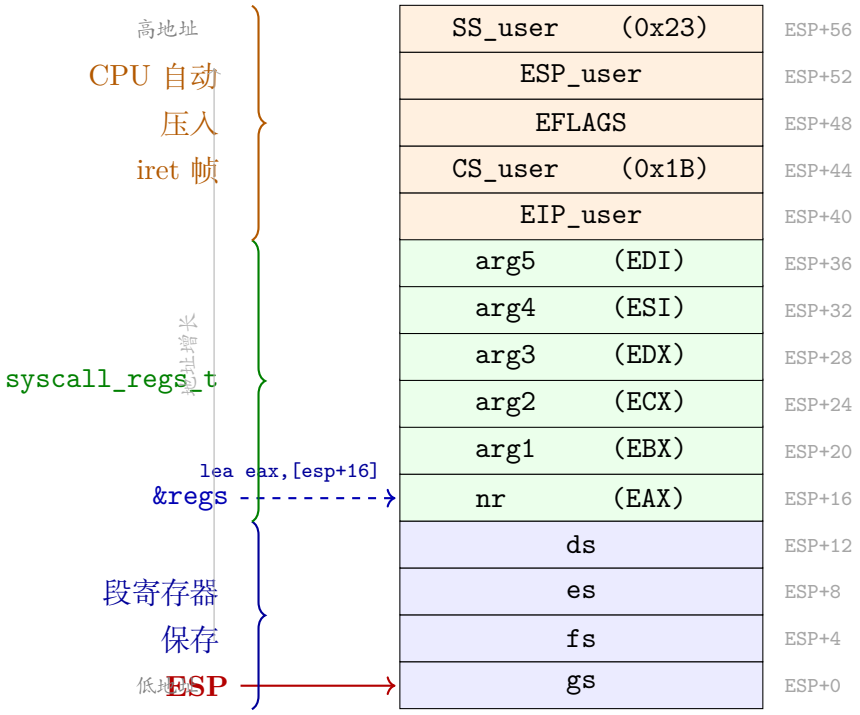

图 14.7: `syscall_int80_entry` 中，`call syscall_dispatch` 前的内核栈布局

蓝色区域（ESP+0 … +12）保存用户态段寄存器；绿色区域（ESP+16 … +36）是 `syscall_regs_t` 结构体，`&regs = ESP+16`；橙色区域（ESP+40 … +56）是 CPU 自动压入的 `iret` 帧。

完整汇编实现

src/kernel/arch/syscall_int80_entry.asm

```
extern syscall_dispatch
global syscall_int80_entry

syscall_int80_entry:
    ; 步骤 1: 构造 syscall_regs_t (逆序压栈，使结构体从低到高按顺序排列)
    push edi        ; arg5 offset+20
    push esi        ; arg4 offset+16
    push edx        ; arg3 offset+12
    push ecx        ; arg2 offset+8
    push ebx        ; arg1 offset+4
    push eax        ; nr   offset+0 ← ESP 现在指向结构体起始

```

```
    ; 步骤 2: 保存段寄存器，切换到内核数据段 (0x10)
    push ds
    push es
    push fs
    push gs
    mov ax, 0x10  ; GDT_KERNEL_DATA_SEL
    mov ds, ax
    mov es, ax
    mov fs, ax
    mov gs, ax

    ; 步骤 3: 调用 syscall_dispatch(&regs)
    ; &regs = ESP+16 (段寄存器占了 4×4=16 字节)
    lea eax, [esp + 16]
    push eax            ; 参数: syscall_regs_t*
    call syscall_dispatch
    add esp, 4          ; 清理参数

    ; 步骤 4: 恢复段寄存器 (DS/ES/FS/GS 回到用户态值)
    pop gs
    pop fs
    pop es
    pop ds

    ; 步骤 5: 把 syscall 返回值写入 nr 槽，恢复用户寄存器
    mov [esp], eax ; 返回值 → nr 槽 (pop eax 时取出)
    pop eax       ; EAX = 返回值 (用户态通过 EAX 接收结果)
    pop ebx       ; 恢复 arg1
    pop ecx       ; 恢复 arg2
    pop edx       ; 恢复 arg3
    pop esi       ; 恢复 arg4
    pop edi       ; 恢复 arg5

    ; 步骤 6: iret 返回 Ring 3
    iret
```

为什么？

为什么用 `lea eax, [esp+16]` 而不是直接 `push esp`？

此时 ESP 指向的是刚压入的 gs（段寄存器保存区的最低地址），而 `syscall_regs_t` 的起始（nr 字段）在它上方 16 字节处（4 个段寄存器 × 4 字节）。若直接 `push esp`，C 函数收到的指针会指向 gs，读出的 nr 值是 DS 选择子，而非 EAX。`lea` 加上偏移量才能拿到结构体的真正起始地址。

为什么？

为什么要把返回值先写入 nr 槽，再 `pop eax`？

`syscall_dispatch()` 的返回值存在 EAX 中，但我们需要用一系列 `pop` 来同步弹出整个 `syscall_regs_t` 并恢复寄存器。第一个 `pop eax` 会弹出 nr 槽的内容——如果不先覆盖它，弹出的就是系统调用号而非返回值。`mov [esp], eax` 把返回值写入 nr 槽，再 `pop eax` 就能同时完成"取返回值 + 调整 ESP"两步。

CPU 状态变化

`iret` 执行后（Ring 0 → Ring 3）：

- EIP ← `EIP_user`（`int 0x80` 之后的下一条指令）
- CS ← `CS_user`（`0x1B`，DPL=3）→ CPL 变回 3
- EFLAGS ← 用户态 EFLAGS（IF 等标志恢复）
- ESP ← `ESP_user`（用户态栈指针）
- SS ← `SS_user`（`0x23`，DPL=3）
- EAX = syscall 返回值（用户代码通过 EAX 读取结果）

14.11.3 C 后端：`syscall_int80_backend.c`

C 后端实现 `syscall_ops_t` 接口，并在 `init()` 中完成 IDT 门的安装：

src/kernel/arch/syscall_int80_backend.c

```c
/* 0xEE = 1110_1110b: P=1, DPL=11, S=0, Type=1110 (32-bit int gate) */
#define INT_GATE_DPL3 0xEE

extern void syscall_int80_entry(void); /* 汇编入口（链接时解析） */

static void int80_init(void) {
    idt_install_gate(0x80,
```

```
                    syscall_int80_entry, /* 汇编 stub 地址 */
                    GDT_KERNEL_CODE_SEL, /* selector = 0x08 */
                    INT_GATE_DPL3);    /* type_attr */

    printk("[syscall/int0x80] IDT[0x80] installed "
           "(DPL=3, selector=0x%02x, entry=%p)\n",
           GDT_KERNEL_CODE_SEL,
           (void *)syscall_int80_entry);
}

static const syscall_ops_t int80_ops = {
    .name = "int0x80",
    .init = int80_init,
};

const syscall_ops_t *syscall_int80_get_ops(void) {
    return &int80_ops;
}
```

为什么？

为什么文件名用 syscall_int80_backend.c？

Makefile 用 patsubst 把所有 .c 和 .asm 文件映射到同名的 .o。若此文件叫 syscall_int80.c，会与 syscall_int80_entry.asm 产生同名目标文件，导致链接重复。项目中 tss.c + tss_flush.asm 遵循了相同的命名惯例。

14.11.4 kmain.c 集成：后端注册与编译期切换

src/kernel/core/kmain.c

```
/* 头文件包含（编译期选择后端）*/
#if KCONFIG_SYSCALL_BACKEND == 0
#include "syscall_int80.h"
#endif

/* 在 kmain() 中，idt_init() 之后 */
#if KCONFIG_SYSCALL_BACKEND == 0
    syscall_register_backend(syscall_int80_get_ops());
#endif
syscall_init();
```

CPU 状态变化

`syscall_init()` 执行后（`KCONFIG_SYSCALL_BACKEND=0`）：

- `IDT[0x80].offset` = `&syscall_int80_entry`
- `IDT[0x80].selector` = `0x08`（内核代码段）
- `IDT[0x80].type_attr` = `0xEE`（P=1, DPL=3, 32-bit Int Gate）
- Ring 3 执行 `int 0x80`：DPL 检查通过 → CPU 切换到 TSS.SS0:ESP0 → 压入 iret 帧 → 跳转到 stub

设计决策

`KCONFIG_SYSCALL_BACKEND` 的意义

值	后端
0	`int 0x80`（D-3，本节实现）
1	`sysenter`（D-4，进阶，需配置 MSR）

两个后端共享同一 dispatch 层和 syscall table，切换时只需修改此编译宏并重新编译——这正是第 14.4 节可插拔架构的价值所在。

14.11.5 用户态测试代码：PIC 技巧

`user_test_code.asm` 中新增了 `user_syscall_start/end` 片段，用于完整验证系统调用路径。

为什么需要位置无关代码（PIC）

内核将这段代码当作字节数组复制到用户地址空间（`0x00400000`），但汇编时编译器并不知道运行时地址。代码中内嵌了字符串字面量 `sc_msg`，若直接用绝对地址引用，复制后地址就失效了。

解决方案是 **call/pop** 技巧：

```
    call sc_get_ip ; 把 sc_get_ip 的地址压栈，然后跳转到 sc_get_ip
sc_get_ip:
    pop esi        ; ESI = sc_get_ip 的运行时地址
```

`call` 指令执行时，CPU 把紧跟其后的指令地址（即 `sc_get_ip` 标签处）压入用户栈，然后跳到那里。`pop esi` 弹出的正是 `sc_get_ip` 的**运行时**地址。之后用 `[esi + (sc_msg - sc_get_ip)]` 计算任何其他标签的运行时地址——括号内的偏移量在编译

期已知，无论代码被加载到哪里都保持正确。

完整测试代码

src/kernel/arch/user_test_code.asm

```
user_syscall_start:
    ; PIC: 获取 sc_get_ip 的运行时地址
    call sc_get_ip
sc_get_ip:
    pop esi                         ; ESI = 运行时 sc_get_ip 地址

    ; write(fd=1, buf=sc_msg, count=18)
    mov eax, 4                      ; SYS_WRITE
    mov ebx, 1                      ; fd = 1 (stdout)
    lea ecx, [esi + (sc_msg - sc_get_ip)]; buf (运行时地址)
    mov edx, sc_msg_len             ; count
    int 0x80                        ; ← 触发系统调用

    ; exit(status=0)
    mov eax, 1                      ; SYS_EXIT
    xor ebx, ebx                    ; status = 0
    int 0x80                        ; ← 触发系统调用

    jmp $                           ; 安全网（不应执行到此处）

sc_msg:  db "hello from ring3!", 0x0A ; 18 字节（含换行符）
sc_msg_len equ ($ - sc_msg)
user_syscall_end:
```

两次 int 0x80 将分别触发完整的：

$$\text{Ring 3} \xrightarrow{\texttt{int 0x80}} \texttt{syscall_int80_entry} \rightarrow \texttt{syscall_dispatch} \rightarrow \textit{handler}$$

第一次调用 sys_write（nr=4），第二次调用 sys_exit（nr=1，执行 hlt 令 CPU 停机）。

思考 14.3

call sc_get_ip 会把返回地址压入**用户栈**，而非内核栈。int 0x80 触发时 CPU 只保存/恢复 ESP_user，用户栈上的这个额外字值不会被内核看到，也不影响后续 syscall_dispatch 的执行。为什么用户栈上的内容不需要显式清理？

> 提示：*call sc_get_ip* 的 *call* 指令本身已经跳转到 *sc_get_ip*，它不会"返回"到 *call* 之后。用户栈上的返回地址只是作为 *PIC* 的"临时载体"被 *pop esi* 消耗掉了。

14.12 验证：ring3 syscall 测试

D-3 的端到端验证通过 `ring3 syscall` 命令完成。它把用户态代码复制到 `0x00400000`，跳转到 Ring 3，然后经由 `int 0x80` 完成一次 `write` 和一次 `exit`。

14.12.1 内核启动日志

内核启动时，`syscall_init()` 内部依次调用后端 `init()` 和 `syscall_register_handler()`，串口应输出：

```
QEMU 串口：内核初始化阶段

[syscall/int0x80] IDT[0x80] installed (DPL=3, selector=0x08, entry=0
    xc01xxxxx)
[syscall] backend registered: int0x80
[syscall] handler registered: nr=1 (exit)
[syscall] handler registered: nr=4 (write)
```

这四行确认：IDT 门已安装（DPL=3），后端与两个 handler 均已就绪。

14.12.2 执行 ring3 syscall 命令

内核 shell 就绪后，输入命令：

src/kernel/cmds/cmd_ring3.c

```
> ring3 syscall：完整预期输出

szy-kernel > ring3 syscall
[ring3] Preparing Ring 3 syscall test...
[ring3] code page: virt=0x00400000 phys=0x001b1000
[ring3] stack page: virt=0x00401000 phys=0x001b3000 (top=0x00402000)
[ring3] syscall test code copied (46 bytes)
[ring3] Jumping to Ring 3 (syscall test)...
[ring3] Expected: write -> 'hello from ring3!' on serial, then exit -> halt
hello from ring3!
[syscall] exit(status=0)
```

```
System halted.
```

14.12.3 执行流程追踪

从命令输入到 CPU 停机，完整的执行路径经过 7 个阶段：

1. **Ring 0：准备阶段**（`ring3_syscall()` in `cmd_ring3.c`）
   - `pmm_alloc_page()` 各分配一张物理页，用于代码和用户栈
   - `vmm_map_page(0x00400000, code_phys, PTE_PRESENT | PTE_USER)`
     代码页设 `PTE_USER`，用户态可读/执行；不需要写权限
   - `vmm_map_page(0x00401000, stack_phys, PTE_PRESENT | PTE_WRITABLE | PTE_USER)`
     栈页需要写权限（Ring 3 的 `push/call` 会写栈）
   - `kmemcpy(0x00400000, user_syscall_start, size)`
     将测试代码字节拷贝到用户地址空间
   - `jump_to_ring3(0x00400000, 0x00402000)`
     构造 `iret` 帧，CPL 0 → 3，EIP → `0x00400000`
2. **Ring 3：PIC 获取运行时 EIP**
   - `call sc_get_ip`：CPU 将 `sc_get_ip` 的运行时地址压入用户栈，跳转过去
   - `pop esi`：ESI = `sc_get_ip` 运行时地址
   - `lea ecx, [esi + offset]`：计算 `sc_msg` 的运行时地址
3. **第一次 `int 0x80` (`write`)：Ring 3 → Ring 0**
   - 寄存器：EAX=4, EBX=1, ECX=&msg, EDX=18
   - CPU 查 IDT[`0x80`]：DPL=3，检查 CPL(3) ≤ DPL(3) 通过
   - 从 TSS 读 SS0:ESP0，切换到内核栈
   - 压入 SS/ESP/EFLAGS/CS/EIP（iret 帧），清除 IF
   - 跳转到 `syscall_int80_entry`
4. **Ring 0：汇编 stub 与 dispatch**
   - `push edi..eax`：在内核栈上构造 `syscall_regs_t`
   - `push ds..gs`：保存用户段寄存器，切换 DS/ES/FS/GS 到 `0x10`
   - `lea eax, [esp+16]; call syscall_dispatch`

- `syscall_dispatch`：查表 `syscall_table[4]`，得到 `sys_write`
- `sys_write(1, msg_addr, 18)`：调用 `printk`，串口输出 `hello from ring3!`
- 返回值 18（写入字节数）存入 EAX

5. **Ring 0 → Ring 3：`iret` 返回**
   - stub 恢复 DS/ES/FS/GS；`mov [esp], eax` 把返回值写入 nr 槽
   - `pop eax..edi`：恢复用户寄存器，EAX=18（`write` 返回值）
   - `iret`：CS/EFLAGS/SS/ESP 从 iret 帧恢复，CPL 回 3
   - 继续执行 `int 0x80` 后的下一条指令（`mov eax, 1`）
6. **第二次 `int 0x80` (`exit`)：Ring 3 → Ring 0**
   - 寄存器：EAX=1（SYS_EXIT），EBX=0（status）
   - 同样路径进入 stub → dispatch → `syscall_table[1]` → `sys_exit(0)`
7. **`sys_exit` → 系统停机**
   - `sys_exit` 打印 `[syscall] exit(status=0)`
   - 执行 `hlt`，CPU 进入停机状态，串口输出 `System halted.`

14.12.4 验证要点

每行输出都对应着一个关键的正确性断言：

1. `[syscall/int0x80] IDT[0x80] installed`
   `int80_init()` 成功执行，IDT[0x80] 已安装 DPL=3 的门。
2. `hello from ring3!`
   Ring 3 代码成功通过 `int 0x80` 触发了 `sys_write`。字符串能正确打印，证明 PIC 技巧工作正常（buf 地址计算无误）。
3. `[syscall] exit(status=0)`
   `sys_exit` 被调用，参数 status=0 经由 EBX 正确传递。
4. `System halted.`
   `sys_exit` 执行 `hlt`，整条 Ring 3 → syscall → handler 路径完整走通。

注意

排查：出现 #GP 而非 `hello from ring3!`

最常见原因：用户代码页的 PDE 没有设置 User 位。`vmm_map_page` 写入 PTE 时若只设了 PTE 的 `PTE_USER`，而 PDE 仍是内核级（User bit = 0），CPU 在 Ring 3 访问该页时会检测到 PDE 级别的特权违规并触发 #PF 或 #GP。

修复方式：在 `vmm_map_page()` 内部确保当 `flags` 含 `PTE_USER` 时，同步把该 PDE 的 User 位也置 1（见第 13 章 `pde_user` 标志传播一节）。

思考 14.4

如果把 `INT_GATE_DPL3`（`0xEE`）改成 `0x8E`（DPL=0），执行 `ring3 syscall` 时会看到什么现象？为什么？

提示：Ring 3 执行 `int 0x80` 时，CPU 检查 CPL(3) ≤ DPL(0)——不满足。CPU 直接触发 #GP(0)，ISR 打印 "Fault from Ring 3" 和 "Kernel panic: #GP"，`syscall_int80_entry` 根本不会被调用。

Chapter 15

ELF 加载器

15.1 本章目标

- 理解可执行文件格式的作用与分类
- 深入掌握 ELF32 文件格式（ELF header、Program header、PT_LOAD 段）
- 设计可插拔 `loader_ops_t` 接口，支持未来扩展其他格式
- 实现 ELF32 加载器后端：解析 → 映射 → VMA 注册
- 验证从内存加载最小 ELF 并跳转执行

15.2 概念：可执行文件与加载

15.2.1 ELF32 结构详解

15.3 可插拔接口：`loader_ops_t`

15.4 ELF32 加载器后端

15.5 数据结构

15.6 验证

15.7 本章小结

ELF 加载器通过可插拔 `loader_ops_t` 接口，将文件格式解析与内核加载逻辑解耦。ELF32 后端完成了从文件到地址空间的映射，配合 VMA 记录各段的权限。下一章

实现进程管理——让每个程序拥有独立的 PCB、页表和 VMA 树。

Chapter 16

进程管理

16.1 本章目标

- 理解进程的本质：独立地址空间 + 执行上下文 + 资源集合
- 设计进程控制块（PCB / `task_struct`）数据结构
- 实现 per-process 页目录与 VMA 树（内核共享、用户独立）
- 实现进程状态机：CREATED → READY → RUNNING → BLOCKED → ZOMBIE
- 实现 `fork`（COW + VMA 复制）、`exec`、`exit`、`waitpid`
- 验证父子进程完整生命周期

16.2 概念：进程抽象

16.2.1 进程状态机

16.2.2 进程树与 PID

16.3 PCB 数据结构：`task_struct`

16.4 进程地址空间

16.5 fork：进程复制

16.6 exec：加载新程序

16.7 exit + waitpid：进程终止与回收

16.8 验证

16.9 本章小结

进程管理让内核能同时承载多个独立程序。每个进程拥有独立的 PCB、页目录和 VMA 树。`fork`（COW）、`exec`、`exit`、`waitpid` 四件套构成了 Unix 进程模型的核心。下一章实现调度器，让这些进程分时共享 CPU。

Chapter 17

调度器

17.1 本章目标

- 理解协作式与抢占式调度的区别
- 设计可插拔 `sched_ops_t` 接口，解耦调度算法
- 配置 PIT 8253 定时器产生周期中断（IRQ0）
- 实现上下文切换汇编（保存/恢复寄存器 + CR3 + TSS.ESP0）
- 实现 Round-Robin 调度器后端
- 实现优先级调度器后端（进阶）
- 通过 `KCONFIG_SCHED_BACKEND` 一键切换

17.2 概念：CPU 调度

17.2.1 调度算法分类

17.3 可插拔接口：`sched_ops_t`

17.4 PIT 定时器配置

17.5 上下文切换

CPU 状态变化

上下文切换后：

- CR3 指向新进程的页目录 → 地址空间完全切换
- TSS.ESP0 指向新进程的内核栈 → 下次中断用正确的栈
- ESP 指向新进程上次保存的栈帧 → `popad` 恢复所有通用寄存器
- `ret` 跳到新进程上次被 `schedule()` 切走时的下一条指令

17.6 后端一：Round-Robin 调度器

17.7 后端二：优先级调度器（进阶）

17.8 验证

17.9 本章小结

调度器通过可插拔 `sched_ops_t` 接口，将调度算法与内核核心解耦。Round-Robin 提供了最简单的公平调度，优先级调度允许差异化的 CPU 分配。配合 PIT 定时器的抢占式设计，保证了任何用户进程都无法独占 CPU。至此”进程与用户态”里程碑 D 全部完成。下一部分进入文件系统。

Part V

文件系统

Chapter 18

VFS：虚拟文件系统

18.1 本章目标

- 理解 Unix "一切皆文件" 哲学与 VFS 的意义
- 设计可插拔 `fs_ops_t` 接口，解耦文件系统实现
- 实现 VFS dispatch 层（superblock/inode/dentry/file 四大对象）
- 实现 per-process 文件描述符表（fd table）
- 集成系统调用：`sys_open/sys_read/sys_write/sys_close/sys_stat`

18.2 概念：为什么需要 VFS

18.2.1 文件描述符

18.3 可插拔接口：`fs_ops_t`

18.4 核心数据结构

18.5 系统调用集成

18.6 验证

18.7 本章小结

VFS 通过可插拔 `fs_ops_t` 接口，让不同文件系统共享统一的 `open/read/write/close` API。下一章实现第一个具体文件系统后端——ramfs，让用户程序能读取打包在内核镜

像中的文件。

Chapter 19

ramfs：内存文件系统

19.1 本章目标

- 实现 ramfs 后端：内存中的简易文件系统
- 实现 initrd 加载：GRUB Multiboot2 module → ramfs 根目录
- ELF 加载器通过 VFS 读取文件，而非硬编码内存地址
- 验证 `exec("/hello")` 从 initrd 加载 ELF 并运行

19.2 概念：initrd 与内存文件系统

19.2.1 打包格式选择

19.3 ramfs 后端实现

19.4 initrd 加载

19.5 验证

19.6 本章小结

ramfs 是 `fs_ops_t` 的第一个具体后端，证明了 VFS 可插拔架构的可行性。配合 initrd，用户程序无需磁盘驱动即可被加载执行。下一章实现块设备抽象和磁盘文件系统，让内核能访问持久化存储。

Chapter 20

块设备与磁盘文件系统

20.1 本章目标

- 理解块设备抽象与扇区寻址
- 设计可插拔 `blkdev_ops_t` 接口，解耦磁盘驱动
- 实现 ATA PIO 驱动后端
- 理解 ext2 磁盘布局（超级块 / 块组 / inode 表）
- 实现 ext2 只读文件系统后端（`fs_ops_t`）
- 通过 `KCONFIG_BLKDEV_BACKEND` 一键切换

20.2 概念：块设备

20.3 可插拔接口：`blkdev_ops_t`

20.4 后端一：ATA PIO 驱动

20.5 ext2 文件系统概念

20.6 ext2 只读后端

20.7 ext2 写入支持（进阶）

20.8 验证

20.9 本章小结

通过可插拔 `blkdev_ops_t` 和 `fs_ops_t` 双层抽象，磁盘驱动与文件系统格式完全解耦——ATA PIO 可替换为 virtio-blk，ext2 可替换为 FAT32。下一章实现字符设备框架，将串口、键盘等硬件也纳入“一切皆文件”的统一模型。

Chapter 21

字符设备

21.1 本章目标

- 理解 Unix 设备模型（主设备号 / 次设备号）
- 设计可插拔 `chardev_ops_t` 接口 + cdev 注册框架
- 实现基础字符设备：`/dev/null`、`/dev/zero`、`/dev/serial`、`/dev/console`
- 通过 VFS 统一访问设备文件
- 里程碑 E 集成测试

21.2 概念：Unix 设备模型

21.3 可插拔接口：`chardev_ops_t`

21.4 基础字符设备实现

21.5 验证

21.6 本章小结

字符设备通过可插拔 `chardev_ops_t` 接口纳入 VFS "一切皆文件" 体系。至此里程碑 E（文件系统）全部完成：VFS 抽象层 + ramfs/initrd + ext2 磁盘 + 字符设备四层递进。下一部分进入 POSIX 兼容层——信号、管道、mmap、libc 和用户态 Shell。

Part VI

POSIX 兼容层

Chapter 22

信号

22.1 本章目标

- 理解信号的本质：进程间异步通知机制
- 掌握信号生命周期：产生 → 挂起（pending）→ 投递（delivery）→ 处理
- 实现 per-process 信号表（31 个标准信号 + pending/blocked 位图）
- 实现信号投递机制 + 内核态 → 用户态信号跳板（signal trampoline）
- 实现 `sigaction` 系统调用（用户自定义信号处理函数）
- 验证 `Ctrl+C` → `SIGINT` → 终止前台进程

22.2 概念：信号机制

22.2.1 信号在 PCB 中的表示

22.3 信号投递与跳板

22.4 系统调用

22.5 验证

22.6 本章小结

信号机制为进程提供了异步通知能力。通过 pending/blocked 位图 + signal trampoline，内核能安全地在用户态执行信号处理函数并恢复原始上下文。下一章实现管道和 I/O 重定向，构建进程间通信的基础设施。

Chapter 23

管道与重定向

23.1 本章目标

- 理解 Unix 管道原理与进程间通信（IPC）分类
- 设计可插拔 `ipc_ops_t` 接口（匿名管道/命名管道/共享内存可扩展）
- 实现匿名管道后端（内核环形缓冲区 + 阻塞读写）
- 实现 `dup2()` 文件描述符复制
- Shell 集成管道 `|` 和重定向 `>`

23.2 概念：进程间通信

23.2.1 dup2 与 I/O 重定向

23.3 可插拔接口：`ipc_ops_t`

23.4 匿名管道后端

23.5 验证

23.6 本章小结

管道通过可插拔 `ipc_ops_t` 接口实现进程间单向通信。配合 `dup2` 的 fd 重定向能力，Shell 获得了管道 `|` 和重定向 `>` 的支持。下一章实现 `mmap`，让用户态能直接映射内存和文件到地址空间。

Chapter 24

用户态 mmap

24.1 本章目标

- 理解 mmap 的用途与语义（匿名映射 / 文件映射）
- 实现 mmap 与 VMA 子系统的集成（复用里程碑 C 的可插拔 VMA 后端）
- 实现匿名映射后端（`MAP_ANONYMOUS | MAP_PRIVATE`）
- 实现文件映射后端（进阶，`MAP_PRIVATE` 文件映射）
- 按需分页（demand paging）与 Page Fault 处理
- 通过 `KCONFIG_MMAP_FILE` 开关控制文件映射

24.2 概念：mmap 内存映射

24.2.1 与 VMA 的关系

24.3 匿名映射后端

24.4 文件映射后端（进阶）

24.5 验证

24.6 本章小结

mmap 将虚拟地址映射与 VMA 子系统深度集成，实现了 demand paging 的按需分配。匿名映射为用户态 `malloc` 的大块分配提供基础，文件映射为动态库和高效 I/O 铺路。下一章实现用户态 libc，让用户程序能用标准 C 函数编程。

Chapter 25

用户态 libc

25.1 本章目标

- 理解 libc 在用户程序与内核之间的桥梁角色
- 对比 musl / glibc / newlib，选择合适的策略
- 实现 C 运行时启动代码（`crt0.o`、`_start` → `main`）
- 实现精简 libc 核心函数（printf/malloc/fopen/string.h）
- 验证用户态程序链接 libc 并正常运行

25.2 概念：libc 的角色

25.2.1 C 运行时启动流程

25.3 syscall wrapper 层

25.4 核心函数实现

25.5 验证

25.6 本章小结

精简 libc 为用户程序提供了标准 C 编程接口，屏蔽了 syscall 的底层细节。crt0.o + syscall wrapper + 核心函数三层结构让用户程序能用熟悉的 printf/malloc 编程。下一章实现用户态 Shell，替代内核内置的 shell，迈向真正的多用户系统。

Chapter 26

用户态 Shell

26.1 本章目标

- 理解用户态 shell 与内核内置 shell 的本质区别
- 实现用户态 `/bin/sh`（`fork+exec` 命令执行模型）
- 支持环境变量、`PATH` 查找、命令行解析
- 支持 job control：前台/后台进程、`Ctrl+C`/`Ctrl+Z` 信号转发
- 集成管道 `|` 和重定向 `>`
- 里程碑 F 集成测试

26.2 概念：用户态 Shell

26.3 命令行解析

26.4 环境变量与 PATH

26.5 Job Control

26.6 验证

26.7 本章小结

用户态 Shell 替代了内核内置 shell,成为用户与操作系统交互的真正入口。`fork+exec` 命令执行模型、环境变量、PATH 查找、job control 构成了完整的交互体验。至此里程

碑 F（POSIX 兼容层）全部完成。下一部分搭建交叉编译工具链，向移植 GCC 与 Vim 进发。

Part VII

移植 GCC 与 Vim

Chapter 27

交叉编译工具链

27.1 本章目标

- 理解交叉编译原理与 GCC 构建三元组（build / host / target）
- 定义 `i686-szy` 目标平台（OS target triplet）
- 在宿主机上构建 `i686-szy-gcc` + binutils 交叉编译器
- 配置 sysroot，使交叉编译器能找到 SZY-KERNEL 的头文件和 libc

27.2 概念：交叉编译

27.3 定义 i686-szy 目标

27.4 构建步骤

27.5 验证

27.6 本章小结

交叉编译工具链是移植 GCC 和 Vim 的前提。`i686-szy-gcc` 让我们能在宿主机上编译 SZY-KERNEL 的用户态程序。下一章实现终端子系统（termios + PTY），为 Vim 等交互式程序提供终端环境。

Chapter 28

终端子系统

28.1 本章目标

- 理解终端的历史演进（物理终端 → 虚拟终端 → 伪终端）
- 设计可插拔 `tty_ops_t` 接口（raw / canonical 模式可切换）
- 实现 termios 行规程（行缓冲、回显、特殊字符）
- 实现伪终端 PTY（master/slave 配对）
- 实现 VT100/ANSI 转义序列解析（光标/颜色/清屏）
- 通过 `KCONFIG_TTY_BACKEND` 切换（basic / pty）

28.2 概念：终端

28.3 可插拔接口：`tty_ops_t`

28.4 termios 实现

28.5 PTY + VT100

28.6 验证

28.7 本章小结

终端子系统通过可插拔 `tty_ops_t` 接口，支持 basic 和 PTY 两种模式。termios 行规程和 VT100 解析为 Vim 等交互式程序提供了必要的终端环境。下一章开始移植

GCC，让 SZY-KERNEL 能自己编译程序。

Chapter 29

移植 GCC

29.1 本章目标

- 分析 GCC 运行时依赖（syscall 子集 + libc 函数 + 文件系统需求）
- 让 GCC 能在 SZY-KERNEL 上编译并运行简单 C 程序
- 验证自举：在 OS 上用 GCC 编译 hello world 并执行

29.2 概念：GCC 运行时依赖

29.3 移植步骤

29.4 验证

29.5 本章小结

在 SZY-KERNEL 上运行 GCC 是自举的里程碑——OS 能编译自己的程序。下一章移植 Vim，让用户能在 OS 上交互式编辑代码。

Chapter 30

移植 Vim

30.1 本章目标

- 分析 Vim 运行时依赖（termios / PTY / libc / 文件系统 / 信号 / mmap）
- 确定最小功能集编译选项（`--with-features=tiny`）
- 在 SZY-KERNEL 上编译并运行 Vim
- 验证完整流程：`vim test.c` → 编辑 → `:wq` → 文件保存成功

30.2 概念：Vim 依赖分析

30.3 移植步骤

30.4 验证

30.5 本章小结

在 SZY-KERNEL 上运行 Vim 标志着里程碑 G 完成——OS 既能编译程序（GCC），又能编辑代码（Vim）。下一部分进入网络——实现网卡驱动、TCP/IP 协议栈和 Socket API，让 OS 连接外部世界。

Part VIII

网络

Chapter 31

网卡驱动

31.1 本章目标

- 理解网络分层模型（OSI / TCP-IP）与以太网帧结构
- 设计可插拔 `netdev_ops_t` 接口，解耦网卡驱动
- 实现 PCI 设备枚举与 MMIO 映射
- 实现 Intel E1000 驱动后端（QEMU 默认网卡）
- 了解 virtio-net 备选方案
- 通过 `KCONFIG_NETDEV_BACKEND` 一键切换

31.2 概念：网络分层

31.3 可插拔接口：`netdev_ops_t`

31.4 PCI 设备枚举

31.5 后端一：E1000 驱动

31.6 后端二：virtio-net（备选）

31.7 验证

31.8 本章小结

网卡驱动通过可插拔 `netdev_ops_t` 接口，让 E1000 和 virtio-net 可以一键切换。E1000 的 TX/RX 描述符环 + DMA 是理解现代网卡驱动的基础。下一章在驱动之上构建 TCP/IP 协议栈，让 OS 能进行真正的网络通信。

Chapter 32

TCP/IP 协议栈

32.1 本章目标

- 理解协议栈分层架构与数据封装/解封
- 设计可插拔 `proto_ops_t` 接口 + 协议注册表
- 设计 `sk_buff` 网络缓冲区
- 实现 ARP + IPv4 + ICMP（能 ping 通 QEMU 网关）
- 实现 UDP + TCP（三次握手 / 数据传输 / 四次挥手）

32.2 概念：协议栈分层

32.3 可插拔接口：`proto_ops_t`

32.4 ARP + IPv4 + ICMP

32.5 UDP + TCP

32.6 验证

32.7 本章小结

TCP/IP 协议栈通过可插拔 `proto_ops_t` 接口，让协议实现可独立扩展。ARP + IP + ICMP 构成基本网络通信能力，TCP + UDP 提供可靠和不可靠传输选择。下一章实现 BSD Socket API，将网络能力暴露给用户态程序。

Chapter 33

Socket API

33.1 本章目标

- 理解 BSD Socket 抽象模型（地址族 / Socket 类型）
- 设计可插拔 `socket_ops_t` 接口（AF_INET / AF_UNIX 可扩展）
- 实现 INET Socket 后端（TCP + UDP）
- 将 Socket fd 纳入 VFS 文件描述符体系
- 验证 echo server

33.2 概念：BSD Socket

33.3 可插拔接口：`socket_ops_t`

33.4 INET Socket 后端

33.5 验证

33.6 本章小结

Socket API 通过可插拔 `socket_ops_t` 接口，将网络能力暴露给用户态程序。INET Socket 后端桥接了 BSD Socket 语义和底层 TCP/UDP 协议栈。下一章实现用户态网络工具——ping 和 HTTP client，完成 OS 联网的最后一步。

Chapter 34

网络工具

34.1 本章目标

- 实现用户态 `/bin/ping`（ICMP Echo Request/Reply）
- 实现简易 HTTP client `/bin/wget`（TCP + HTTP/1.0 GET）
- 里程碑 H 集成测试：应用层 → Socket → TCP/IP → 网卡 → 网络全路径

34.2 用户态 ping

34.3 简易 HTTP client

34.4 验证

34.5 本章小结

用户态网络工具是整个网络栈的顶层验证。ping 证明了 ICMP 全路径通畅，wget 证明了 TCP + HTTP 的完整闭环。至此里程碑 H（网络）全部完成，SZY-KERNEL 的所有规划目标均已覆盖：

- 自举 GCC 编译器
- 运行 Vim 编辑器
- TCP/IP 网络通信

Part IX

附录

附录 A

工具链速查

A.1 构建命令

命令	用途
`make iso`	编译内核 + 打包 GRUB ISO
`make run`	QEMU 启动 ISO
`make debug`	QEMU -S 等待 GDB（需 `DEBUG=1`）
`make gdb`	启动 GDB 并连接 QEMU
`make clean`	清理构建产物
`make compdb`	生成 `compile_commands.json`

A.2 QEMU 常用选项

选项	含义
`-serial stdio`	串口输出到终端
`-m 256`	分配 256MiB 内存
`-S`	启动时暂停 CPU
`-s`	开启 gdbstub（端口 1234）
`-no-reboot`	Triple Fault 时不自动重启
`-d int`	输出中断日志

A.3 GDB 常用命令

命令	用途
`b kmain`	在 kmain 设断点
`c`	继续运行
`n / s`	单步（不进入/进入函数）
`si / ni`	指令级单步
`info reg`	查看寄存器
`bt`	调用栈回溯
`x/10i $eip`	反汇编当前位置
`p/x var`	十六进制打印变量
`x/32wx $esp`	查看栈内存

A.4 Shell 命令速查

命令	用途
`cls`	清屏
`cmds`	列出所有命令
`free`	物理内存用量
`mmap`	Multiboot2 内存映射
`pmm state`	PMM 状态
`pmm alloc N`	分配 N 个物理页
`vmm state`	VMM 状态
`vmm lookup ADDR`	虚拟 → 物理地址翻译
`heap status`	堆统计
`heap test`	堆 selftest
`vma list`	列出所有 VMA
`vma find ADDR`	查找地址所属 VMA
`vma test`	VMA selftest
`shutdown`	关机

附录 B

内核测试框架

操作系统内核运行在裸机之上，没有标准库、没有 `assert.h`、没有单元测试框架。但这不意味着我们不需要测试——恰恰相反，内核代码的 bug 会直接导致 triple fault 或数据损坏，调试成本极高。本附录介绍 SZY-KERNEL 的测试策略：如何在没有任何操作系统支持的环境下验证物理内存分配器、内核堆和虚拟内存区域管理等关键子系统的正确性。

B.1 测试架构概览

SZY-KERNEL 采用**三层测试体系**：

1. **Boot-time selftest**——子系统初始化时自动运行（如 PMM 在注册后立即分配 / 释放几个页面验证基本功能），不需要人工干预。
2. **Shell 交互式 selftest**——通过内核 Shell 命令 (`pmm test`、`heap test`、`vma test`) 手动或脚本触发，覆盖更多边界条件。
3. **QEMU 自动化脚本**——`scripts/test.sh` 启动 QEMU、注入命令、抓取串口日志、用正则断言关键标记，实现 CI 级别的回归测试。

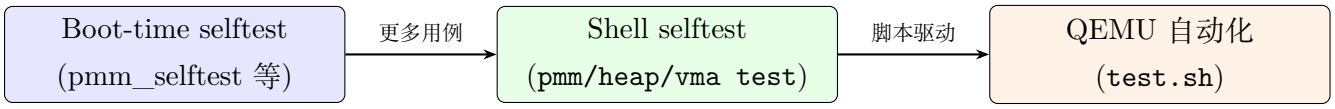

图 B.1: 三层测试体系

B.1.1 为什么不用标准测试框架？

内核代码运行在 Ring 0，没有 `libc`、没有 `exit()`、没有文件系统。常见的 C 测试框架（CUnit、Unity、Check）都依赖标准库。我们的做法是：

- 用 printk() 替代 printf() 输出结果到串口
- 用固定格式的标记字符串（如 [pmm-test] === ALL PASS ===）替代返回码，方便脚本 grep 断言
- 每个测试子命令自行管理分配/释放，确保测试结束后不泄漏资源

B.2 PMM 测试：物理内存分配器

物理内存分配器(PMM)是整个内存子系统的地基。它的接口很简洁——pmm_alloc_page() 返回一个 4KiB 物理页地址，pmm_free_page() 归还。我们需要验证的核心属性是：

- 分配后空闲计数正确减少，释放后恢复
- 返回的地址满足 4KiB 对齐
- 连续分配不会返回相同页面
- 大批量分配/释放后计数器保持一致（无泄漏）
- 分配的页面物理可写可读（通过内核虚拟地址访问）

B.2.1 测试代码详解

src/kernel/cmds/cmd_pmm.c —cmd_pmm_test()

```
static int cmd_pmm_test(void) {
    printk("[pmm-test] === PMM selftest ===\n");
    int pass = 1;
```

pass 标志贯穿所有测试。任何一个子测试失败都会将其置为 0，但不会提前退出——这样可以一次看到所有失败项。

测试 1：alloc/free 往返

```
    /* --- 测试 1: 基本 alloc/free 往返 --- */
    unsigned free_before = pmm_free_pages();
    void* p1 = pmm_alloc_page();
    if (!p1) {
        printk("[pmm-test] FAIL: pmm_alloc_page returned NULL\n");
        return 0;
    }
    unsigned free_after_alloc = pmm_free_pages();
    if (free_after_alloc != free_before - 1) {
```

```
        printk("[pmm-test] FAIL: free count %u -> %u\n",
               free_before, free_after_alloc);
        pass = 0;
    }
    pmm_free_page(p1);
    unsigned free_after_free = pmm_free_pages();
    if (free_after_free != free_before) {
        printk("[pmm-test] FAIL: free count not restored\n");
        pass = 0;
    }
```

原理：这是最基本的”不变量检查”——分配一页后 `free_pages()` 应该恰好减 1，释放后恢复原值。如果 bitmap 的位翻转逻辑有 off-by-one，这里立刻就能抓到。

测试 2：页对齐验证

```
    #define PMM_TEST_ALIGN_N 8
    void* align_pages[PMM_TEST_ALIGN_N];
    for (int i = 0; i < PMM_TEST_ALIGN_N; i++) {
        align_pages[i] = pmm_alloc_page();
        uint32_t addr = (uint32_t)(uintptr_t)align_pages[i];
        if (addr & 0xFFFu) { // 低 12 位非零 => 未对齐
            printk("[pmm-test] FAIL: page %d not 4KiB aligned\n", i);
            align_ok = 0;
        }
    }
    for (int i = 0; i < PMM_TEST_ALIGN_N; i++)
        pmm_free_page(align_pages[i]);
```

原理：x86 分页要求页帧地址低 12 位为 0。检查方法很直接——用 `addr & 0xFFF` 掩码。如果 PMM 的 `page_addr(index)` 计算公式有误（比如忘记乘以 4096），这里会立即暴露。

测试 3：唯一性验证

```
    #define PMM_TEST_UNIQUE_N 16
    void* unique_pages[PMM_TEST_UNIQUE_N];
    for (int i = 0; i < PMM_TEST_UNIQUE_N; i++)
        unique_pages[i] = pmm_alloc_page();

    for (int i = 0; i < PMM_TEST_UNIQUE_N; i++) {
```

```
        for (int j = i + 1; j < PMM_TEST_UNIQUE_N; j++) {
            if (unique_pages[i] == unique_pages[j]) {
                printk("[pmm-test] FAIL: duplicate [%d]==[%d]\n", i, j);
                unique_ok = 0;
            }
        }
    }
```

原理：$O(n^2)$ 两两比较。16 个页面只需 120 次比较，开销可忽略。这个测试能抓到 bitmap `set_bit` / `clear_bit` 的逻辑 bug——比如 `free` 时没有正确清除位标记，导致同一个页被分配两次。

测试 4：批量压力

```
    unsigned free_start = pmm_free_pages();
    #define PMM_TEST_BATCH_N 32
    void* batch_pages[PMM_TEST_BATCH_N];
    int alloc_count = 0;
    for (int i = 0; i < PMM_TEST_BATCH_N; i++) {
        batch_pages[i] = pmm_alloc_page();
        if (!batch_pages[i]) break; // OOM: 可以接受
        alloc_count++;
    }
    // 验证: free_mid == free_start - alloc_count
    for (int i = 0; i < alloc_count; i++)
        pmm_free_page(batch_pages[i]);
    // 验证: free_end == free_start
```

原理：一次性分配 32 页（128 KiB）再一次性释放。这验证了分配器在连续操作下计数器的一致性。如果 buddy 分配器的分裂/合并有 bug，连续分配大量页面后计数器会出现偏移。

测试 5：写读验证

```
    if (vmm_is_ready()) {
        void* pg = pmm_alloc_page();
        uint32_t* virt = (uint32_t*)PHYS_TO_VIRT(pg);
        for (unsigned i = 0; i < 4096 / sizeof(uint32_t); i++)
            virt[i] = 0xC0FFEE00u + i;
        for (unsigned i = 0; i < 4096 / sizeof(uint32_t); i++) {
            if (virt[i] != 0xC0FFEE00u + i) {
```

```
            printk("[pmm-test] FAIL: mismatch at word %u\n", i);
            rw_ok = 0;
            break;
        }
    }
    pmm_free_page(pg);
}
```

原理：分配一个物理页后，通过 `PHYS_TO_VIRT()` 将其转换为内核虚拟地址（`phys + 0xC0000000`），然后写入 1024 个 `uint32_t` 魔数并逐一回读。这同时验证了三件事：

1. PMM 返回的物理页确实是可用 RAM（不是 MMIO 或保留区）
2. VMM 的直接映射（direct mapping）正确覆盖了该物理地址
3. 整页 4096 字节都可写可读，无 DRAM 故障

注意必须判断 `vmm_is_ready()`——如果在分页未开启前调用 `PHYS_TO_VIRT` 会直接 triple fault。

B.3 Heap 测试：内核堆分配器

内核堆（`kmalloc/kfree`）建立在 PMM + VMM 之上，提供字节级动态内存分配。测试的关键属性：

- 分配返回非 NULL 指针，可写可读
- 多个同时存活的分配不会互相覆盖
- 全部释放后 `alloc_count == 0`（无泄漏）
- 释放后的空间可被重新分配（复用）
- 返回指针满足 8 字节对齐
- 碎片化场景下仍能正常分配
- 不同大小（1B ~ 4KiB）均能正确处理

B.3.1 测试代码详解

`src/kernel/cmds/cmd_heap.c` —do_test()

测试 1–4：基础功能

前四个测试覆盖最核心的功能循环：

1. **基本 alloc/free**——分配 64 字节，逐字节写入 `0x00..0x3F` 并回读验证，然后 `kfree`。
2. **多大小不重叠**——同时分配 32、128、256、1024 字节四块内存，每块首字写入不同魔数（`0xAA550000 + i`），分配完成后逐一验证魔数未被后续分配覆盖。
3. **Stats 一致性**——四块全部释放后，检查 `kheap_get_stats().alloc_count == 0`。
4. **复用**——释放后重新 `kmalloc(64)`，验证指针有效且可写。

测试 5：对齐验证

```
unsigned align_sizes[] = { 1, 3, 7, 13, 33, 100, 255, 512 };
for (int i = 0; i < align_n; i++) {
    align_ptrs[i] = kmalloc(align_sizes[i]);
    uintptr_t addr = (uintptr_t)align_ptrs[i];
    if (addr & 0x7u) { // 低 3 位非零 => 未 8 字节对齐
        printk("FAIL: not 8-byte aligned\n");
        align_ok = 0;
    }
}
```

原理：内核代码经常需要访问 `uint64_t` 或 `double`，x86 虽然不强制要求对齐但未对齐会导致性能损失。更重要的是，某些 CPU 指令（如 SSE）要求 16 字节对齐。我们至少保证 8 字节。故意选择「刁难」的奇数大小（1、3、7、13 字节）来测试分配器的内部 round-up 逻辑。

测试 6：碎片化压力

```
#define FRAG_N 8
void* frag[FRAG_N];
// 步骤 1: 分配 8 块，每块 64 字节
for (int i = 0; i < FRAG_N; i++) {
    frag[i] = kmalloc(64);
    ((uint32_t*)frag[i])[0] = 0xF0F00000u + i;
}
// 步骤 2: 释放偶数位置 (0, 2, 4, 6) — 制造空洞
```

```
    for (int i = 0; i < FRAG_N; i += 2)
        kfree(frag[i]);
    // 步骤 3: 验证奇数位置数据完好
    for (int i = 1; i < FRAG_N; i += 2)
        assert(((uint32_t*)frag[i])[0] == 0xF0F00000u + i);
    // 步骤 4: 重新分配偶数位（碎片回收）
    for (int i = 0; i < FRAG_N; i += 2)
        frag[i] = kmalloc(64);
    // 步骤 5: 验证所有数据正确
```

原理：这是经典的”瑞士奶酪”碎片化场景。堆内存布局变成：

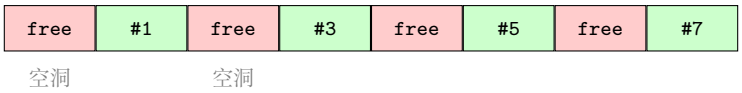

释放偶数位后，四个空洞散布在已用块之间。此时重新 `kmalloc(64)` 必须能找到并利用这些空洞，而不会破坏相邻奇数位置的数据。这验证了 first-fit / slab 分配器的空闲块管理和合并逻辑。

测试 7：递增大小

```
    unsigned inc_sizes[] = { 1, 2, 4, 8, 16, 32, 64,
                             128, 256, 512, 1024, 2048 };
    for (int i = 0; i < inc_n; i++) {
        void* p = kmalloc(inc_sizes[i]);
        uint8_t pattern = (uint8_t)(inc_sizes[i] & 0xFF);
        // 写满整个分配区域
        for (unsigned j = 0; j < inc_sizes[i]; j++)
            ((uint8_t*)p)[j] = pattern;
        // 逐字节回读验证
        for (unsigned j = 0; j < inc_sizes[i]; j++)
            assert(((uint8_t*)p)[j] == pattern);
        kfree(p);
    }
```

原理：从 1 字节到 2048 字节逐级测试，覆盖分配器内部的 round-up 边界。对于 slab 分配器，不同大小会命中不同 cache 级别（32B、64B、128B……2048B）；对于 first-fit，大小变化会导致不同的空闲链表分裂模式。每次分配后**写满**而不是只写一个字——这能检测到空间实际可用量不足（分配器声称给了 N 字节但实际可写区域不到 N 字节）的 bug。

测试 8：大块分配

```
void* big = kmalloc(4096);
uint32_t* wp = (uint32_t*)big;
for (unsigned i = 0; i < 4096 / sizeof(uint32_t); i++)
    wp[i] = 0xCAFE0000u + i;
for (unsigned i = 0; i < 4096 / sizeof(uint32_t); i++)
    assert(wp[i] == 0xCAFE0000u + i);
kfree(big);
```

原理：4096 字节恰好是一个物理页的大小。对于 slab 分配器，这超出了最大 cache 级别（2048B），需要回退到整页分配路径。对于 first-fit，需要找到至少 4096 + header 大小的连续空闲块。写满 1024 个 `uint32_t` 并验证，同时检查 `alloc_count` 统计是否一致。

B.4 VMA 测试：虚拟内存区域管理

VMA（Virtual Memory Area）子系统跟踪内核地址空间中每一段虚拟地址的用途和权限。它的接口是 `vma_add(start, end, flags, name)` / `vma_remove(start)` / `vma_find(addr)`，后端可以是 sorted-array、红黑树或 Maple Tree。测试需要验证的属性：

- 添加的区域能被正确查找到
- 区间外地址查找返回 NULL
- 重叠区域被拒绝
- 移除后不再可查找
- 边界语义正确（半开区间 $[\text{start}, \text{end})$）
- 相邻但不重叠的区域互不干扰
- 批量操作正确
- `count()` 与实际增删一致

B.4.1 测试地址选择

所有测试使用 `0xF1000000` 附近的地址。这个区域位于内核虚拟地址空间高端（`KHEAP_END = 0xF0000000` 之上），不会和内核堆、直接映射区或 VMA 自身的内部区域冲突。

B.4.2 测试代码详解

src/kernel/cmds/cmd_vma.c —cmd_vma_test()

测试 1–4：核心 CRUD

1. **add + find**——添加 [0xF1000000, 0xF1010000)，然后 find(start + 0x100) 验证命中且 start/end 正确。
2. **find outside**——find(start - 0x1000) 应返回 NULL （不属于该区域）。
3. **overlap 拒绝**——尝试添加 [start+0x1000, end+0x1000) （与现有区域部分重叠），vma_add 应返回 −1。
4. **remove + find**——vma_remove(start) 后再 find 应返回 NULL。

测试 5：边界语义

```
vma_add(test_start, test_end, VMA_READ, "_test_bound");

// find(start) -> 应命中
v = vma_find(test_start);
assert(v && v->start == test_start);

// find(end - 1) -> 应命中（半开区间的最后一个字节）
v = vma_find(test_end - 1);
assert(v && v->start == test_start);

// find(end) -> 应 miss（半开区间，end 不包含在内）
v = vma_find(test_end);
assert(!v || v->start != test_start);
```

原理：VMA 使用半开区间 [start, end)，这是 Linux 内核的标准约定。end 地址本身不属于该 VMA。这个测试专门验证边界条件——off-by-one 是 VMA 后端实现中最容易出错的地方，尤其是二分查找的 left/right 边界。

测试 6：相邻区域

```
const uint32_t a_start = 0xF1020000u;
const uint32_t a_end = 0xF1030000u;
const uint32_t b_start = 0xF1030000u; // == a_end
const uint32_t b_end = 0xF1040000u;

```

```
vma_add(a_start, a_end, VMA_READ, "_adj_a");
vma_add(b_start, b_end, VMA_READ | VMA_WRITE, "_adj_b");

// 两个区域各自独立可查找
assert(vma_find(a_start + 0x100)->start == a_start);
assert(vma_find(b_start + 0x100)->start == b_start);

// flags 互不影响：A 只读，B 可写
v = vma_find(a_start);
assert(!(v->flags & VMA_WRITE));
```

原理：两个 VMA 首尾相接（A 的 end == B 的 start）。由于半开区间，它们不重叠：A 覆盖 0xF1020000..0xF102FFFF，B 覆盖 0xF1030000..0xF103FFFF。这验证了后端的排序和查找逻辑不会将相邻区域错误合并或混淆。

测试 7：批量操作

```
#define VMA_BATCH_N 8
for (int i = 0; i < VMA_BATCH_N; i++) {
    uint32_t base = 0xF1050000u + i * 0x10000u;
    vma_add(base, base + 0x10000u, VMA_READ, "_batch");
}
// 逐一查找中间地址
for (int i = 0; i < VMA_BATCH_N; i++) {
    v = vma_find(bases[i] + 0x8000);
    assert(v && v->start == bases[i]);
}
// 清理
for (int i = 0; i < VMA_BATCH_N; i++)
    vma_remove(bases[i]);
```

原理：一次添加 8 个 64KiB 区域（总跨度 512KiB）。对于 sorted-array 后端，这会触发多次有序插入和数组移动；对于红黑树，触发多次旋转和重着色；对于 Maple Tree，可能触发叶节点分裂。这是一个轻量级的”规模测试”，验证后端在多条目下仍然正确。

测试 8–9：负面路径与 count

8. **移除不存在的 VMA**——vma_remove(0xF1FF0000) 应返回错误码 −1 而不是崩溃或静默操作。

9. **count 一致性**——记录当前 vma_count()，添加一个 VMA 后 count 应加 1，移除后恢复原值。

这两个测试验证了 VMA 子系统的”健壮性”——即使调用者传入无效参数，也不会导致内部状态损坏。

B.5 QEMU 自动化测试脚本

手动在 Shell 中输入命令适合开发阶段，但不能保证回归。`scripts/test.sh` 实现了完全自动化的测试流程。

B.5.1 工作原理

1. `make clean && make iso`——从干净状态构建
2. 启动 QEMU，串口输出到文件（`-serial file:...`），超时后自动终止
3. 对日志文件做 `grep` 断言：检查引导标记、命令输出等
4. 需要注入命令时，改用 `-serial stdio` + `printf` 管道

B.5.2 Smoke 测试（始终运行）

```
require_fixed "[init] gdt ok"     "gdt init"
require_fixed "[init] idt ok"     "idt init"
require_fixed "[mb2] magic=36d76289" "multiboot2 magic"
require_regex "\\[mb2\\] info @ 0x[0-9a-fA-F]+" "mb2 info header"
require_fixed "[mb2] end tag"     "mb2 end tag"
```

这五项检查确保内核能完成最基本的引导：GDT/IDT 初始化、Multiboot2 magic 正确、内存映射标签完整。

B.5.3 命令注入测试

以 PMM 测试为例，脚本通过延时管道向 QEMU 的 `-serial stdio` 注入命令：

```
({
  sleep 1                # 等待 Shell 就绪
  printf 'pmm state\n'
  sleep 0.1
  printf 'pmm alloc 3\n'
  sleep 0.1
  printf 'pmm state\n'
  sleep 0.1
  printf 'pmm freeall\n'
```

```
  sleep 0.1
  printf 'pmm state\n'
}) | timeout 8s qemu-system-i386 \
  -cdrom kernel.iso -serial stdio -display none
```

然后用 awk 提取三次 pmm state 输出中的空闲页数，验证 free0 - free1 == 3（分配了 3 页）且 free2 == free0（全部归还）。

B.5.4 使用方式

```
# 仅 smoke 测试（默认）
make test

# 启用所有命令测试
TEST_PMM=1 TEST_HEAP=1 TEST_VMA=1 TEST_PMM_TEST=1 make test

# 自定义超时（低配机器）
QEMU_TIMEOUT_SEC=10 TEST_HEAP=1 make test
```

B.5.5 测试标志一览

环境变量	注入命令	断言标记
TEST_MMAP=1	mmap	Available RAM: 0x...
TEST_PMM=1	pmm state/alloc/freeall	free 计数 ±3
TEST_HEAP=1	heap test	[heap-test] === ALL PASS ===
TEST_VMA=1	vma test	[vma-test] === ALL PASS ===
TEST_PMM_TEST=1	pmm test	[pmm-test] === ALL PASS ===

B.6 测试设计原则

总结 SZY-KERNEL 测试框架遵循的设计原则：

资源自清理 每个测试函数负责分配和释放自己使用的所有资源。测试失败时也要尽量释放（在 for 循环中逐一 free），避免泄漏的页/VMA 影响后续测试。

不变量检查 利用 free_pages() / alloc_count / vma_count() 等查询接口，在操作前后验证计数器变化符合预期。这比单纯检查返回值更可靠。

魔数写入 分配内存后立即写入唯一的魔数模式（如 `0xC0FFEE00 + i`、`0xAA550000 + i`），然后在适当时機回读。如果两个分配互相覆盖，魔数会被破坏，测试立即报告 FAIL。

边界覆盖 专门测试 off-by-one 易错点：页对齐的最低位、半开区间的 `end`、最小分配大小 1 字节、最大 cache 级别边界等。

负面路径 不仅测试正常功能，还验证异常输入：移除不存在的 VMA、重叠添加、分配 0 字节等。正确的行为是返回错误码，而非崩溃。

标记输出 每个测试打印固定格式的 `PASS/FAIL/ALL PASS`，方便自动化脚本 `grep` 断言。这是裸机环境下 `assert` 的替代方案。

附录 C

x86 架构速查

C.1 寄存器

C.1.1 通用寄存器（32 位）

寄存器	惯用用途	调用约定
EAX	累加器、返回值	caller-saved
EBX	基址	callee-saved
ECX	计数器	caller-saved
EDX	数据、I/O	caller-saved
ESI	源索引	callee-saved
EDI	目的索引	callee-saved
EBP	栈帧基指针	callee-saved
ESP	栈指针	特殊

C.1.2 段寄存器

寄存器	用途
CS	代码段选择子（隐含 CPL）
DS	默认数据段
SS	栈段
ES	附加数据段
FS / GS	通用附加段（Linux 用 GS 做 per-CPU / TLS）

C.1.3 控制寄存器

寄存器	关键位
CR0	bit 0 (PE): 保护模式
	bit 31 (PG): 开启分页
CR2	Page Fault 时的故障虚拟地址
CR3	页目录物理地址
CR4	bit 4 (PSE): 4MiB 大页支持
	bit 7 (PGE): 全局页

C.2 GDT 条目格式

C.3 IDT 条目格式

C.4 PDE / PTE 格式

bit 0 P (Present) —1= 有效，0= 访问触发 #PF

bit 1 R/W —1= 读写，0= 只读

bit 2 U/S —1= 用户态可访问，0= 仅内核

bit 3 PWT —写透缓存策略

bit 4 PCD —禁用缓存

bit 5 A (Accessed) —CPU 访问后自动置 1

bit 6 D (Dirty) —CPU 写入后自动置 1（仅 PTE）

bit 7 PS/PAT —PDE: 4MiB 大页; PTE: PAT

bit 8 G (Global) —TLB 不随 CR3 切换而刷新

bit 9--11 AVL —软件可用位

bit 12--31 页帧物理地址高 20 位

C.5 Page Fault 错误码

bit 0 P —0= 页不存在，1= 权限违规

bit 1 W/R —0= 读操作，1= 写操作

bit 2 U/S —0= 内核态，1= 用户态

bit 3 RSVD —页表条目保留位被置位

bit 4 I/D —取指令引起

C.6 中断向量分配

向量	名称	说明
0	#DE	除零
3	#BP	断点（int3）
6	#UD	无效操作码
8	#DF	Double Fault
13	#GP	General Protection
14	#PF	Page Fault
32–47	IRQ0–15	硬件中断（PIC remap 后）
128	—	系统调用（int 0x80）